Министерство образования Республики Беларусь
Учреждение образования
«Белорусский государственный университет
информатики и радиоэлектроники»

Факультет компьютерных систем и сетей

Кафедра электронных вычислительных машин

Д. Ю. Перцев, Д. В. Куприянова

ЦИФРОВАЯ ОБРАБОТКА СИГНАЛОВ И ИЗОБРАЖЕНИЙ. ЛАБОРАТОРНЫЙ ПРАКТИКУМ

Рекомендовано УМО по образованию в области информатики и радиоэлектроники в качестве пособия для специальности 6-05-0611-05 «Компьютерная инженерия»

Минск БГУИР 2025

УДК 004.42:004.383.3
ББК 32.972.1я73
З81

Рецензенты:
кафедра физики
Белорусского национального технического университета
(протокол №5 от 15.12.2025);

системный архитектор
ИООО «ЭПАМ Системз»
Д. Н. Марченков

Перцев, Д. Ю.

З81 Цифровая обработка сигналов и изображений. Лабораторный практикум : пособие / Д. Ю. Перцев, Д. В. Куприянова. – Минск : БГУИР, 2025. − 90 с. : ил.

ISBN _____.

Содержит минимальные необходимые теоретические сведения и задания, которые рекомендуется выполнить на лабораторных работах, по дисциплине «Цифровая обработка сигналов и изображений».

УДК 004.42:004.383.3
ББК 32.972.1я73

ISBN _____

© Перцев Д.Ю., Куприянова Д. В., 2025
© УО «Белорусский государственный университет информатики и радиоэлектроники», 2025

СОДЕРЖАНИЕ

Введение.....5
РАЗДЕЛ 1. ЦИФРОВАЯ ОБРАБОТКА СИГНАЛОВ.....6
Теоретические сведения.....6
Понятие «сигнал», группы сигналов.....6
Основные дискретные последовательности.....7
Основные операции и задачи цифровой обработки сигналов.....9
Достоинства и недостатки цифровой обработки сигнала.....9
Ортогональные функции..... 10
Анализ и синтез сигнала..... 11
Мгновенное значение, амплитуда, мощность и энергия дискретного сигнала 12
Контрольные вопросы..... 12
Лабораторная работа №1 Алгоритмы цифровой обработки сигналов..... 14
1. Цель работы..... 14
2. Теоретические сведения..... 14
Ряд Фурье..... 14
Семейство преобразований Фурье..... 16
Дискретное преобразование Фурье..... 17
Быстрое преобразование Фурье..... 20
Алгоритм БПФ с прореживанием по времени..... 23
Алгоритм БПФ с прореживанием по частоте..... 25
Свертка и корреляция..... 27
Теорема корреляции..... 29
Теорема свертки..... 30
Матричное представление корреляции и свертки..... 30
Амплитудный и фазовый спектры сигнала..... 32
3. Задание..... 33
4. Контрольные вопросы..... 33
Лабораторная работа №2 Проектирование цифровых фильтров..... 35
1. Цель работы..... 35
2. Теоретические сведения..... 35
Основные характеристики фильтров..... 35
Амплитудно- и фазо-частотная характеристика..... 36
Классификация фильтров..... 36
Однородные фильтр (фильтры скользящего среднего)..... 37
КИХ-фильтры..... 38
БИХ-фильтры..... 39
3. Задание..... 47

4. Контрольные вопросы 47
Лабораторная работа №3 Алгоритмы обработки аудиосигнала 49
1. Цель работы 49
2. Теоретические сведения 49
Основы цифровой обработки аудиосигнала 49
Базовые алгоритмы, используемые для анализа аудиосигнала 50
Спектральные признаки аудиосигнала 52
Способы оценки качества звука (метрики) 60
Объективные методы оценки качества звука 60
3. Задание 73
4. Контрольные вопросы 74
Лабораторная работа №4 Преобразование текста в речь 76
1. Цель работы 76
2. Теоретические сведения 76
Основные компоненты голоса 76
Общая архитектура системы преобразования текста в речь 76
Развитие алгоритмов синтеза аудиосигнала 77
Проект CosyVoice 79
Преобразование голоса 81
Проект kNN-VC 82
3. Задание 85
4. Контрольные вопросы 85
Список использованных источников 87

ВВЕДЕНИЕ

Учебно-методическое пособие является вспомогательным учебным материалом для студентов специальности 6-05-0611-05 «Компьютерная инженерия» по дисциплине «Цифровая обработка сигналов и изображений» и соответствует разделу «Цифровая обработка сигналов» в действующей учебной программе.

Комплекс работ предполагает последовательное изучение материала с последующим практическим применением в формате – от основ на примере простейших периодических сигналов к сложным многошаговым методам для анализа стохастических сигналов на примере музыкальных файлов и речи. Для достижения данной цели студенту предлагается выполнить четыре лабораторные работы, в рамках которых он:

– познакомится с основами цифровой обработки сигналов, особенностями их оцифровки, фундаментальными алгоритмами (сверткой, корреляцией и преобразованием Фурье);

– на практике получит опыт проектирования цифровых КИХ- и БИХ-фильтров;

– познакомится с методами анализа стохастических сигналов на примере музыкальных файлов и речи, способами их графической визуализации, научится выделять характерные признаки и интерпретировать результат, оценивать качество звука;

– познакомится с современными методами преобразования текста в голос и наоборот голоса в текст.

Каждая лабораторная работа включает постановку цели работы, теоретические сведения, необходимые для выполнения задания, а также само задание и контрольные вопросы.

РАЗДЕЛ 1. ЦИФРОВАЯ ОБРАБОТКА СИГНАЛОВ.

Теоретические сведения

Понятие «сигнал», группы сигналов.

Сигнал – это физический процесс или явление, которое несет в себе информацию о каком-либо событии, состоянии объекта или передает команды управления и оповещения.

Если классифицировать сингал, можно выделить следующие группы:

– по принадлежности к различным группам физических процессов:

  – механические;

  – электромагнитные;

  – акустические и др.;

– по закону изменения во времени:

  – постоянные;

  – переменные, которые, в свою очередь, делятся на случайные и *детерминированные*.

С другой стороны, любой сигнал можно разделить на четыре группы:

– аналоговые;

– дискретные;

– квантованные;

– цифровые.

Большинство сигналов, которые присутствуют в окружающем пространстве, являются *аналоговыми*, т.е. описываются непрерывной функцией времени. В свою очередь, *дискретному* сигналу свойственно изменение сигнала через некоторые, как правило, равномерные, промежутки времени, называемые *интервалом дискретизации* Δt. Для того, чтобы была возможность корректно восстановить аналоговый сигнал по его дискретным отсчетам, применяется *теорема Котельникова (Найквиста-Шеннона)*: непрерывный сигнал с ограниченным спектром (то есть с максимальной частотой $\mathrm{f_{max}}$) может быть полностью восстановлен из своих дискретных отсчётов, если частота дискретизации f_d превышает максимальную частоту более чем в два раза ($f_d > 2f_{max}$). Иначе говоря, чтобы без потерь перейти от аналогового сигнала к цифровому, необходимо брать отсчёты не реже, чем с интервалом в $\frac{f_{max}}{2}$ секунд.

Квантованный сигнал принимает ряд конечных значений из диапазона дискретных величин (как правило, квантование выполняется по амплитуде). Пример аналогового, дискретного и квантованного сигналов представлен на рисунке 1.

Цифровой сигнал формируется из аналогового с помощью операции дискретизации и квантования по уровню путем присвоения кодового слова или набора символов.

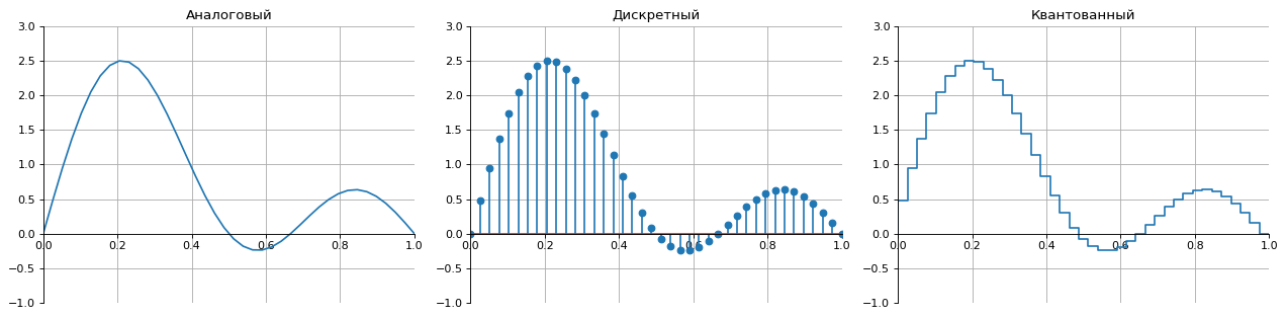

Рисунок 1 – Графическое отображение аналогового, дискретного и квантованного сигнала $x(t) = sin(\pi t) + sin(2\pi t) + sin(3\pi t)$

Основные дискретные последовательности.

Дискретный единичный импульс (δ-функция Дирака) – простейшая дискретная последовательность (рисунок 2), которая равна единице при $n = 0$ и нулю при всех остальных значениях n, определяется по формуле:

$$\delta[n] = \begin{cases} 0, \text{если } n \neq 0 \\ 1, \text{если } n = 0 \end{cases}. \quad (1)$$

На практике дельта-функция в цифровой обработке сигналов используется для:

– представления сигналов, т.к. любой дискретный сигнал может быть представлен как сумма смещённых во времени и масштабированных дельта-функций;

– анализа систем (описания поведения системы);

– дискретизации непрерывных сигналов.

Например, идеальную дискретизацию можно представить как модуляцию непрерывного сигнала $x(t)$, когда «несущей» является непрерывная последовательность единичных мгновенных импульсов:

$$\delta_{\Delta t}(t) = \sum_{n=-\infty}^{\infty} \delta(t - n\Delta t)\,. \quad (2)$$

В этом случае функция $x^*(t)$ образуется в результате умножения входного сигнала $x(t)$ на последовательность $\delta_{\Delta t}(t)$:

$$x^*(t) = x(t) \cdot \delta_{\Delta t}(t) = \sum_{n=0}^{\infty} x(n\Delta t) \cdot \delta(t - n\Delta t)\,. \quad (3)$$

Дискретная функция Хевисайда (данная функция также известна как *единичная последовательность*, *единичный скачок*) – дискретная последовательность (рисунок 2), которая принимает нулевые значения в отрицательной области времени и единичные значения в положительной, определяется по формуле:

$$\sigma[n] = \begin{cases} 0, \text{если } n < 0 \\ 1, \text{если } n \geq 0 \end{cases}. \tag{4}$$

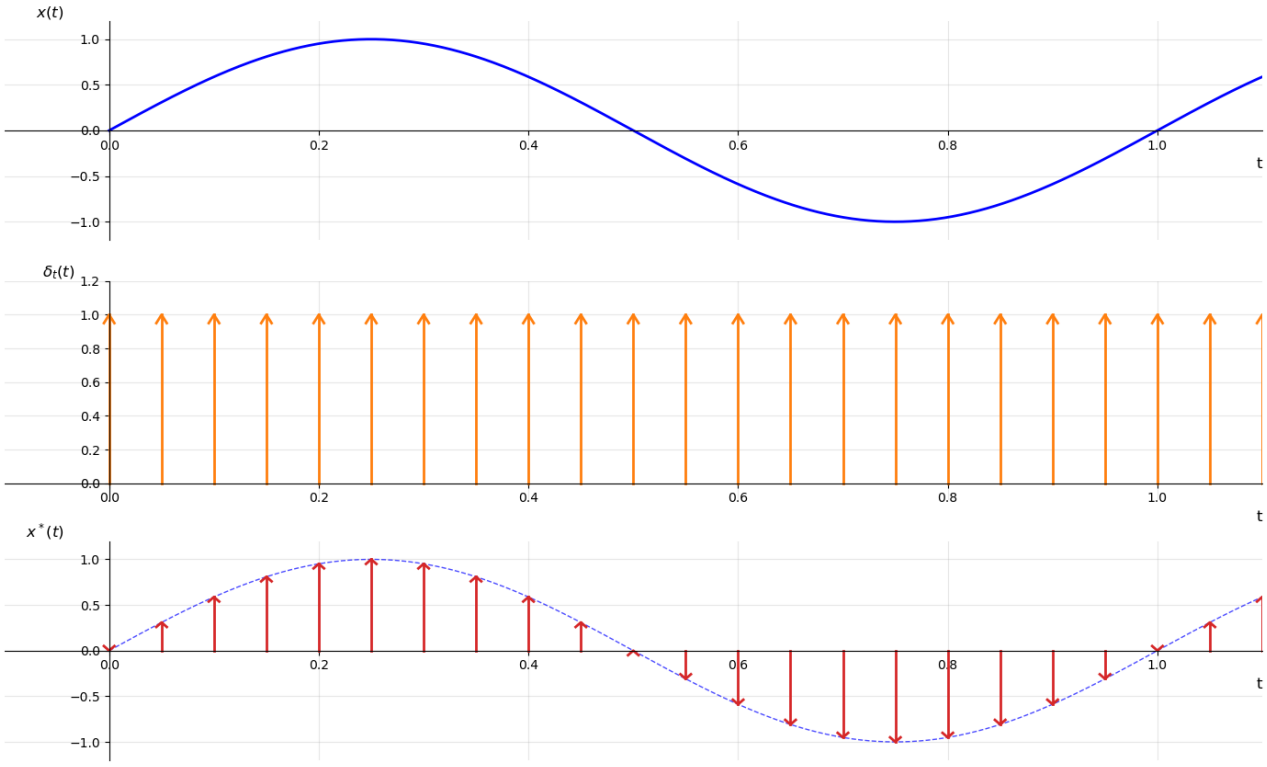

Рисунок 2 – Представление дискретной последовательности в виде дискретной функции времени

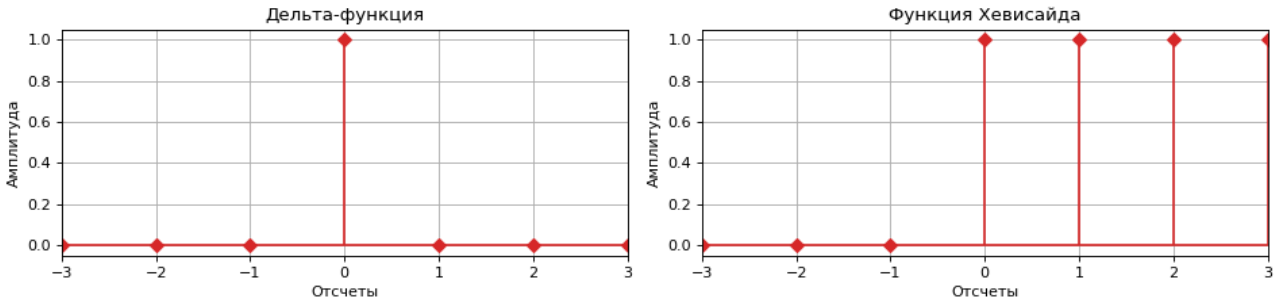

Рисунок 3 – Графическое отображение дискретной дельта-функции и функции Хевисайда

На практике функция Хевисайда в цифровой обработке сигналов используется для:

– описания сигнала (его моделирования), который внезапно «включается» в определенный момент времени (например, для описания начала передачи сигнала);

– анализа переходных характеристик;

– построения более сложных сигналов, вырезания или ограничения частей сигналов.

Основные операции и задачи цифровой обработки сигналов.

К ключевым *операциям*, часто используемым в ЦОС, относятся:

– линейная фильтрация (Digital Filtering), в результате которой выполняется изменение спектра сигнала для удаления нежелательных частотных компонентов (например, шума) или выделения определенных диапазонов;

– свертка (Convolution), описывающая, как форма одного сигнала изменяется под воздействием другого (например, как входной сигнал проходит через систему);

– преобразование Фурье (Fourier Transform), в результате которого выполняется преобразование сигнала из временной или пространственной области в частотную область (спектр).

Среди основных *задач* ЦОС можно выделить:

– спектральный анализ, задачей которого является определение частотных компонентов, присутствующих в сигнале, с использованием преобразования Фурье;

– частотно-временной анализ, который позволяет определить, как частотный состав сигнала меняется со временем (например, с использованием вейвлет-преобразования);

– многоскоростная обработка, предполагающая изменение частоты дискретизации сигнала с помощью операций интерполяции (увеличение) и децимации (уменьшение) при обработке сигнала, часто применяется в телекоммуникациях и аудиосистемах;

– адаптивная фильтрация, задачей которой является фильтрация сигнала, параметры которой автоматически настраиваются для оптимальной работы в меняющихся условиях (например, для подавления эха или шума);

– обнаружение и распознавание сигналов, при котором выполняется выделение полезного сигнала на фоне шума и помех, а также распознавание его типа.

Достоинства и недостатки цифровой обработки сигнала.

К *достоинствам* цифровой обработки относится:

– цифровые системы могут оперировать с отсчетами с очень высокой разрядностью, что обеспечивает минимальные ошибки вычислений;

– результат обработки не зависит от дрейфа параметров компонентов (температуры, старения), как это происходит в аналоговых схемах (где характеристики резисторов, конденсаторов и транзисторов меняются);

– функцию цифрового процессора или фильтра можно изменить, просто обновив программное обеспечение, не меняя физическую аппаратуру;

– позволяет реализовать очень сложные алгоритмы, которые практически невозможно или экономически нецелесообразно реализовать с помощью аналоговой техники (например, адаптивные фильтры, алгоритмы сжатия данных, сложные модуляторы/демодуляторы);

– цифровой сигнал более устойчив к шуму, искажениям и помехам, поскольку он представлен дискретными уровнями (например, «0» и «1»);

– возможно применение алгоритмов обнаружения и коррекции ошибок, что значительно повышает надёжность передачи данных на большие расстояния;

– цифровые данные можно копировать и воспроизводить бесконечное число раз без ухудшения качества (в отличие от аналоговых записей, которые теряют качество с каждым копированием).

Из *недостатков* выделим следующие:

– для работы с реальными, физическими сигналами (звук, радиоволны) всегда требуются дополнительные аналоговые компоненты (аналого-цифровые и цифро-аналоговые преобразователи (АЦП и ЦАП соответственно), восстанавливающие аналоговые фильтры и др.);

– процессы дискретизации, квантования, а также само время выполнения алгоритма процессором вносят задержку в обработку. Это может быть критично для систем, требующих работы в реальном времени (например, в системах управления или высокочастотных радарах);

– максимальная частота дискретизации современных высокоскоростных АЦП и ЦАП определяет верхний предел частотного диапазона, в котором система может работать. В очень высокочастотных приложениях (например, СВЧ-диапазон) аналоговая обработка часто остается единственным вариантом;

– для выполнения сложных алгоритмов на высоких скоростях требуются мощные процессоры, которые могут потреблять больше энергии, чем пассивные аналоговые схемы. Это становится проблемой для портативных устройств с ограниченным ресурсом батареи;

– при квантовании всегда происходит потеря информации и возникает шум квантования, что является необратимым процессом.

Ортогональные функции.

Для лучшего понимания вопроса о рядах Фурье дадим определение ортогональным функциям. Множество непрерывных функций действительной переменной $\{U_n(t)\} = \{U_0(t), U_1(t), \dots\}$ называется ортогональным на интервале $[t_0, t_0 + T]$, если

$$\int_{t_0}^{t_0+T} U_m(t)U_n(t)dt = \begin{cases} c, \text{ при } m = n \\ 0, \text{ при } m \neq n \end{cases}. \quad (5)$$

При $c = 1$ множество $U_n(t)$ называется ортонормированным.

Анализ и синтез сигнала.

Анализ и синтез цифрового сигнала – это ключевые процессы в цифровой обработке сигналов.

Анализ – это процесс извлечения информации и характеристик из уже существующего цифрового сигнала $s(t)$. Основной целью является понять, из чего состоит сигнал, какие у него свойства, и как он меняется во времени или частоте.

Синтез – это процесс создания (генерации) нового цифрового сигнала с заданными свойствами или процесс модификации (фильтрации, кодирования) существующего сигнала для придания ему новых, желаемых характеристик.

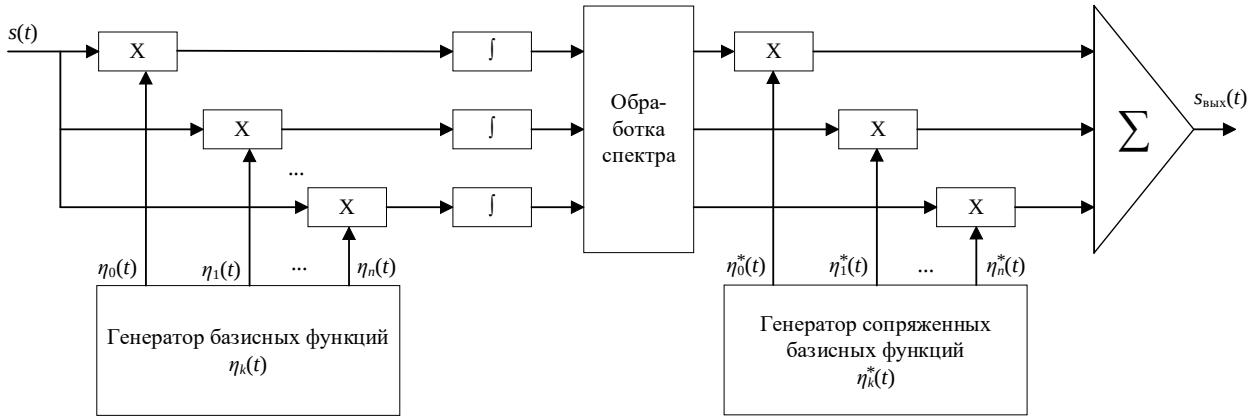

Рисунок 4 – Структурная схема задачи анализа и синтеза сигналов

На рисунке 4 представлена структурная схема, иллюстрирующая обобщенный процесс спектрального анализа и синтеза сигнала $s(t)$ с использованием разложения по ортогональным базисным функциям $\eta_k(t)$. Левая часть схемы выполняет анализ. Предварительно создается набор ортогональных базисных функций $\eta_1(t)$, $\eta_2(t)$, …, $\eta_n(t)$ с заведомо известными характеристиками (например, синусоиды (для Фурье), вейвлеты, функции Хаара и т.д.). Затем выполняется попарное умножение входного сигнала $s(t)$ на каждую из базисных функций $\eta_k(t)$ и интегрирование (или суммирование для дискретного сигнала) по всему интервалу анализа:

$$\int s(t) \cdot \eta_k(t) dt.$$

В результате описанной последовательности действий формируется набор спектральных коэффициентов C_k, описывающих спектр сигнала $s(t)$. Блок обработки спектра отвечает за его модификацию и, по-сути, является основным этапом обработки сигнала. В результате формируется набор модифицированных спектральных коэффициентов C_k^*.

Правая часть схемы выполняет синтез (восстановление) модифицированного сигнала $S_{\text{вых}}(t)$ из обработанных спектральных коэффициентов C_k^*. Вначале создается набор сопряженных базисных функций $\eta_1^*(t)$, $\eta_2^*(t)$, …, $\eta_n^*(t)$. Затем выполняется умножение каждого модифицированного коэффициента C_k^* на соответствующую сопряженную базисную функцию $\eta_k^*(t)$ с последующим суммированием результата:

$$S_{\text{вых}}(t) = \sum_{k=1}^{n} C_k^* \cdot \eta_k^*(t).$$

Структура, представленная на рисунке 4, лежит в основе таких ключевых областей ЦОС, как анализ изображений (JPEG), сжатие аудио (MP3), обработка речи и многих других.

Мгновенное значение, амплитуда, мощность и энергия дискретного сигнала.

Мгновенное значение сигнала $s(n)$ – это величина (ордината) одного конкретного отсчета (или выборки) сигнала в определенный момент времени n.

Амплитуда – максимальное абсолютное значение среди всех отсчетов сигнала: $\max\limits_{n}|s(n)|$.

Для сигнала, который является периодическим с периодом N, *средняя мощность* P определяется как:

$$P = \frac{1}{N}\sum_{n=0}^{N-1}|s(n)|^2\,, \tag{6}$$

где $|s(n)|^2$ – это мгновенная мощность в момент времени n; N – число отсчетов, по которым производится усреднение (период).

Для сигнала $s(n)$, который существует лишь конечное число отсчетов, полная *энергия* E определяется по формуле:

$$E = \sum_{n=-\infty}^{\infty}|s(n)|^2\,. \tag{7}$$

Контрольные вопросы

1. Дайте определение понятию «сигнал» и перечислите основные группы сигналов по физической природе и по закону изменения во времени.

2. В чем заключается принципиальное отличие между аналоговым, дискретным, квантованным и цифровым сигналами? Опишите процесс формирования цифрового сигнала из аналогового.

3. Сформулируйте теорему Котельникова (Найквиста-Шеннона). Какое условие должно выполняться для частоты дискретизации, чтобы аналоговый сигнал можно было восстановить без потерь?

4. Что такое интервал дискретизации (Δt) и как он связан с максимальной частотой спектра сигнала?

5. Дайте определение дискретного единичного импульса (δ-функции Дирака). Запишите формулу и изобразите её график.

6. Перечислите основные сферы применения дельта-функции в цифровой обработке сигналов. Как с её помощью можно представить процесс идеальной дискретизации?

7. Что такое дискретная функция Хевисайда (единичный скачок)? Запишите её математическое определение и назовите области её применения.

8. Дайте определение ортогональным и ортонормированным функциям. Какое математическое условие должно выполняться для их ортогональности на интервале?

9. Напишите формулы для расчета средней мощности периодического сигнала и полной энергии сигнала конечной длительности. Поясните входящие в них переменные.

10. Перечислите основные задачи цифровой обработки сигналов. В чем суть спектрального и частотно-временного анализа?

11. Опишите обобщенную схему анализа и синтеза сигнала. Как используются базисные и сопряженные функции на этапах получения спектральных коэффициентов и восстановления сигнала?

12. Назовите не менее 5 достоинств цифровой обработки сигналов по сравнению с аналоговой. Почему цифровые системы считаются более гибкими и помехоустойчивыми?

13. Какие существуют недостатки и физические ограничения у цифровой обработки сигналов? Объясните проблему задержки обработки и влияния частоты дискретизации АЦП/ЦАП на рабочий диапазон.

ЛАБОРАТОРНАЯ РАБОТА №1
АЛГОРИТМЫ ЦИФРОВОЙ ОБРАБОТКИ СИГНАЛОВ

1. Цель работы

Формирование системного представления о математических методах анализа сигналов во временной и частотной областях, а также приобретение практических навыков программной реализации, верификации и сравнительного анализа вычислительной эффективности алгоритмов дискретного преобразования Фурье (ДПФ), быстрого преобразования Фурье (БПФ), свертки и корреляции.

2. Теоретические сведения

Ряд Фурье.

В 1807 году французский математик и физик Жан Батист Жозеф Фурье показал, что любой периодический сигнал $x(t)$ с периодом $2T$ на интервале $[-T, T]$, удовлетворяющий условиям Дирихле (непрерывный и имеет конечное число экстремумов и точек разрыва I рода), можно представить в виде бесконечной суммы синусоидальных и косинусоидальных членов и одного постоянного члена. Это представление называется *рядом Фурье* и задается следующим выражением:

$$x(t) \sim a_0 + \sum_{n=1}^{\infty} a_n \cos(n\omega_0 t) + \sum_{n=1}^{\infty} b_n \sin(n\omega_0 t)\,, \tag{8}$$

где t – независимая переменная (например, время); ω_0 (рад/с) – основная угловая частота, которая связана с периодом T функции соотношением $T = \frac{2\pi}{\omega_0}$. Частоты $n\omega_0$ называют *гармониками*, так как они кратны основной частоте ω_0.

Коэффициенты a_0, a_n, b_n из формулы (8) на периоде T можно вычислить следующим образом:

$$a_0 = \frac{1}{T}\int_{-\frac{T}{2}}^{\frac{T}{2}} x(t)dt\,; \tag{9}$$

$$a_n = \frac{2}{T}\int_{-\frac{T}{2}}^{\frac{T}{2}} x(t)\cos(n\omega_o t)\,dt\,; \tag{10}$$

$$b_n = \frac{2}{T}\int_{-\frac{T}{2}}^{\frac{T}{2}} x(t)\sin(n\omega_o t)\,dt\,. \tag{11}$$

Амплитуда A_n и фаза ψ_n n-ой гармоники связаны с величинами a_n и b_n соотношениями

$$A_n = \sqrt{a_n^2 + b_n^2}; \tag{12}$$

$$\psi_n = arctg\left(\frac{b_n}{a_n}\right). \tag{13}$$

В некоторых задачах удобнее представить ряд Фурье в комплексной форме, к которой легко перейти, если выразить тригонометрические функции через показательные, воспользовавшись формулой Эйлера:

$$e^{ix} = \cos(x) + isin(x), \tag{14}$$

где $i = \sqrt{-1}$.

Из (14) можно показать, что

$$\cos(n\omega_0 t) = \frac{e^{in\omega_0 t} + e^{-in\omega_0 t}}{2}, \tag{15}$$

$$sin(n\omega_0 t) = \frac{e^{in\omega_0 t} - e^{-in\omega_0 t}}{2i}. \tag{16}$$

Подставим значения в формулу (8):

$$x(t) = a_0 + \sum_{n=1}^{\infty}\left(a_n \cdot \frac{e^{in\omega_0 t} + e^{-in\omega_0 t}}{2}\right) + \sum_{n=1}^{\infty}\left(b_n \cdot \frac{e^{in\omega_0 t} - e^{-in\omega_0 t}}{2i}\right) =$$

$$= a_0 + \frac{1}{2}\sum_{n=1}^{\infty}\{a_n\,(e^{in\omega_0 t} + e^{-in\omega_0 t}) - ib_n(e^{in\omega_0 t} - e^{-in\omega_0 t})\} =$$

$$= a_0 + \frac{1}{2}\sum_{n=1}^{\infty}\{(a_n - ib_n)\,e^{in\omega_0 t} + (a_n + ib_n)e^{-in\omega_0 t}\}.$$

Значения $(a_n - ib_n)$ и $(a_n + ib_n)$ являются комплексно-сопряженными. Введем следующие обозначения:

$C_0 = a_0$, $C_n = \frac{a_n - ib_n}{2}$ и $C_{-n} = C_n^* = \frac{a_n + ib_n}{2}$.

Тогда ряд (8) может быть представлен в виде:

$$x(t) = \sum_{n=-\infty}^{\infty} C_n \, e^{in\omega_0 t}. \qquad (17)$$

Также можно показать, что любая четная функция может быть разложена в ряд Фурье, состоящий из суммы косинусов, а любая нечетная функция – из суммы синусов. Для некоторых функций ряд Фурье может состоять лишь из нечетных гармоник.

В целом, любая полная система ортогональных функций может быть применена для разложения в ряды, которые соответствуют рядам Фурье. Например, часто используется разложение в ряды по функциям Уолша, Хаара, Лагерра, Бесселя и т.д.

Семейство преобразований Фурье.

Преобразование Фурье (англ. Fourier transform) – это разложение функций на синусоиды (далее косинусные функции также будем называть синусоидами, т.к. они отличаются от «настоящих» синусоид только фазой) и позволяет сопоставить сигналу, заданному во временной области, его эквивалентное представление в частотной области. Обратно, если известна частотная характеристика сигнала, обратное преобразование Фурье позволяет определить соответствующий сигнал во временной области.

Семейство преобразований Фурье включает преобразование Фурье, ряды Фурье, дискретные ряды Фурье и дискретное преобразование Фурье и представлено на рисунках 5-8.

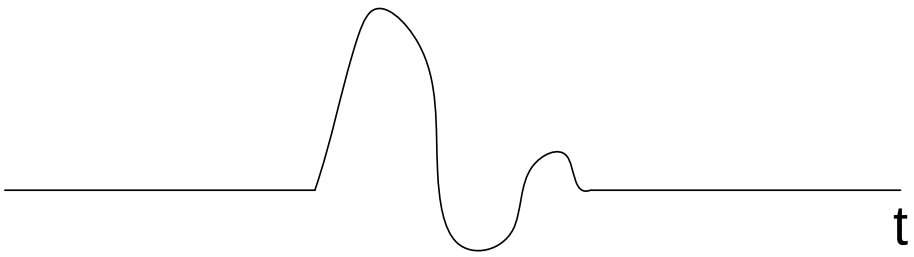

Рисунок 5 – Преобразование Фурье: сигнал непрерывный и апериодический

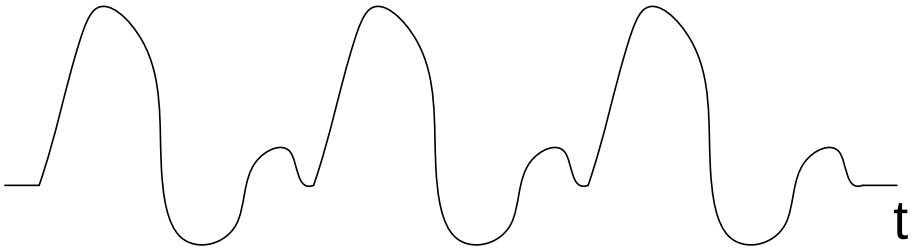

Рисунок 6 – Ряды Фурье: сигнал непрерывный и периодический

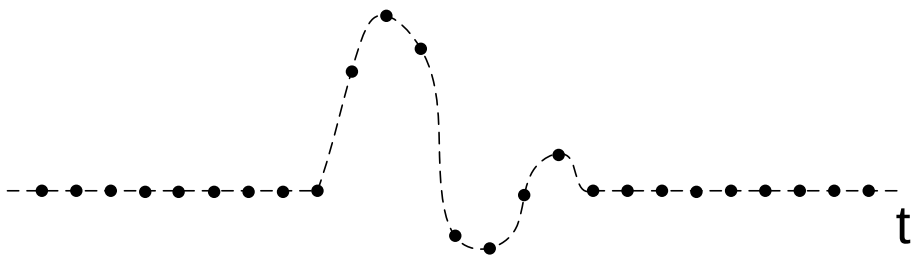

Рисунок 7 – Дискретные ряды Фурье: сигнал дискретный и апериодический

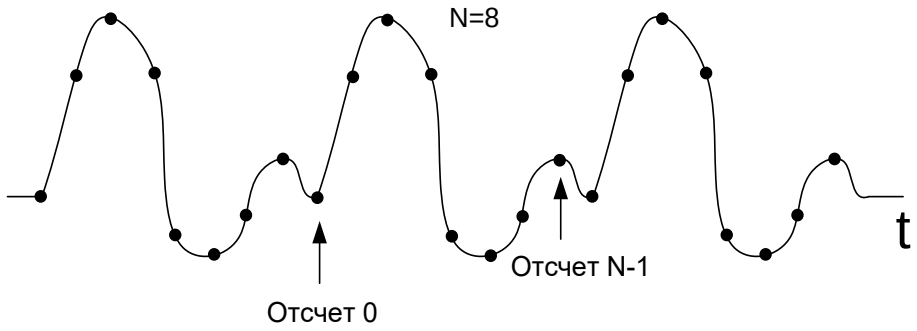

Рисунок 8 – Дискретное преобразование Фурье:
сигнал дискретный и периодический

Дискретное преобразование Фурье (англ. Discrete Fourier Transform, ДПФ).

Если $x(m)$ означает последовательность конечных действительных или комплексных чисел, где $m = \overline{0, N-1}$, дискретное преобразование Фурье этой последовательности определяется следующим образом:

$$X(k) = \sum_{m=0}^{N-1} x(m) W^{km}, \tag{18}$$

$$x(m) = \frac{1}{N} \sum_{k=0}^{N-1} X(k) W^{-km}, \tag{19}$$

где $k = \overline{0, N-1}$, $W = e^{-i\frac{2\pi}{N}}$, $i = \sqrt{-1}$.

Выражения (18) и (19) являются прямым и обратным преобразованием соответственно и составляют *пару преобразований Фурье*.

Следует отметить, функции W^{km} являются N-периодическими и обладают двумя свойствами:

– симметричность – $W^{k+N/2} = -W^{k}$;

– периодичность – $W^{k+N} = W^{k}$.

Рассмотрим *основные свойства дискретного преобразования Фурье:*

а) теорема линейности: если $x(m) \leftrightarrow X(k)$, $y(m) \leftrightarrow Y(k)$ и $z(m) = a \cdot x(m) + b \cdot y(m)$, тогда $Z(k) = a\mathrm{X}(k) + b\mathrm{Y}(k)$;

Доказательство. Рассмотрим ДПФ для линейной комбинации $z(m)$:

$$Z(k) = \sum_{m=0}^{N-1} z(m)W^{km} = \sum_{m=0}^{N-1} \big(a \cdot x(m) + b \cdot y(m)\big)W^{km} =$$

$$= a \cdot \sum_{m=0}^{N-1} x(m)W^{km} + b \cdot \sum_{m=0}^{N-1} y(m)W^{km} = a\mathrm{X}(k) + b\mathrm{Y}(k).$$

б) теорема комплексной сопряженности: если $x = x_0, x_1, \dots, x_{N-1}$ – такая последовательность действительных чисел, что $N/2$ – целое число и $x(m) \leftrightarrow X(k)$, то

$$X\left(\frac{N}{2} + l\right) = X^*\left(\frac{N}{2} - l\right), \forall l = \overline{0, N/2} \tag{20}$$

Доказательство. Подставим в (18) вместо k значение $\left(N/2 + l\right)$, тогда

$$X\left(\frac{N}{2} + 1\right) = \sum_{m=0}^{N-1} x(m)\, W^{\left(\frac{N}{2}+l\right)m} = \sum_{m=0}^{N-1} x(m)\, W^{-\left(\frac{N}{2}-l\right)m} W^{Nm} = X^*\left(\frac{N}{2} - l\right),$$

т.к. $W^{Nm} = e^{-i2\pi m} \equiv -1$.

в) теорема сдвига (по времени): если $y(m) \leftrightarrow Y(k)$ и $y(m) = x(m + h)$, $h = \overline{0, N-1}$, то

$$Y(k) = W^{-kh}X(k). \tag{21}$$

Доказательство. Подставим $y(m) = x(m + h)$ в (18), тогда

$$Y(k) = \sum_{m=0}^{N-1} x(m + h)W^{km}.$$

Введем новую переменную суммирования – $r = m + h$, и рассмотрим крайние значения:

– $m = r - h$;

– при $m = 0$: $r = h$;

– при $m = N - 1$: $r = N + h - 1$.

Подставим данные выражение в соотношение выше:

$$Y(k) = W^{-kh}\left\{\sum_{r=h}^{N+h-1} x(r)W^{kr}\right\}.$$

Поскольку сигнал $x(m)$ является периодическим с периодом N, для любых p и q, удовлетворяющих условию $|p-q| = N-1$, справедливы следующие выражения:

$$\sum_{m=p}^{q} X(m)W^{km} = \sum_{m=0}^{N-1} X(m)W^{km},$$

$$\sum_{m=p}^{q} X(k)W^{-km} = \sum_{m=0}^{N-1} X(k)W^{-km}.$$

Соответственно,

$$Y(k) = W^{-kh}\left\{\sum_{r=h}^{N+h-1} x(r)W^{kr}\right\} = W^{-kh}\left\{\sum_{r=0}^{N-1} x(r)W^{kr}\right\} = W^{-kh}X(k),$$

что и требовалось доказать.

Аналогично можно показать, при у$(m) = x(m-h)$ ДПФ будет иметь вид $Y(k) = W^{kh}X(k)$.

Можно выделить следующие области применения ДПФ:

– цифровой спектральный анализ:
  – анализаторы спектра;
  – обработка речи;
  – обработка изображений;
  – распознавание образов;
– проектирование фильтров:
  – вычисление импульсной характеристики по частотной;
  – вычисление частотной характеристики по импульсной.

Быстрое преобразование Фурье (англ. Fast Fourier Transform, БПФ).

Быстрое преобразование Фурье, предложенное в 1965 году Джеймсом В. Кули и Джоном Тьюки [5], является алгоритмом для ускоренного вычисления ДПФ путем сокращения требуемого числа операций умножения и сложения, а также объема памяти. Данный алгоритм основан на свойствах симметрии и периодичности коэффициентов поворота W.

При вычислении N-точечного ДПФ требуется $O(N^2)$ вычислений с комплексными числами, а при реализации N-точечного БПФ $O\left(N\log_2(N)\right)$ вычислений с комплексными числами. Вычислительная эффективность БПФ по сравнению с ДПФ становится весьма существенной, когда количество точек БПФ увеличивается до нескольких тысяч (таблица 1).

Таблица 1 – Эффективность БПФ

N	**Умножений при ДПФ**	**Умножений при БПФ**	**Эффективность БПФ**
256	65 536	1 024	64 : 1
512	262 144	2 304	114 : 1
1 024	1 048 576	5 120	205 : 1
2 048	4 194 304	11 264	372 : 1
4 096	16 777 216	24 576	683 : 1

Рассмотрим случай, когда $N = 8$ значений в последовательности $\{x(m)\}$:

$$X(k) = \sum_{m=0}^{7} x(m)W^{km}, k = \overline{0, N-1}, W = e^{-i\frac{2\pi}{8}} = e^{-i\frac{\pi}{4}}.$$

В матричном виде данное выражение можно представить в виде $\bar{X} = F\bar{x}$, где матрица F имеет вид:

$$F = \begin{bmatrix} W^0 & W^0 & W^0 & W^0 & W^0 & W^0 & W^0 & W^0 \\ W^0 & W^1 & W^2 & W^3 & W^4 & W^5 & W^6 & W^7 \\ W^0 & W^2 & W^4 & W^6 & W^8 & W^{10} & W^{12} & W^{14} \\ W^0 & W^3 & W^6 & W^9 & W^{12} & W^{15} & W^{18} & W^{21} \\ W^0 & W^4 & W^8 & W^{12} & W^{16} & W^{20} & W^{24} & W^{28} \\ W^0 & W^5 & W^{10} & W^{15} & W^{20} & W^{25} & W^{30} & W^{35} \\ W^0 & W^6 & W^{12} & W^{18} & W^{24} & W^{30} & W^{36} & W^{42} \\ W^0 & W^7 & W^{14} & W^{21} & W^{28} & W^{35} & W^{42} & W^{49} \end{bmatrix}.$$

Из свойства периодичности экспоненциальных функций следует, что $W^{k+8} = W^k$, т.е.

$$F = \begin{bmatrix} W^0 & W^0 & W^0 & W^0 & W^0 & W^0 & W^0 & W^0 \\ W^0 & W^1 & W^2 & W^3 & W^4 & W^5 & W^6 & W^7 \\ W^0 & W^2 & W^4 & W^6 & W^0 & W^2 & W^4 & W^6 \\ W^0 & W^3 & W^6 & W^1 & W^4 & W^7 & W^2 & W^5 \\ W^0 & W^4 & W^0 & W^4 & W^0 & W^4 & W^0 & W^4 \\ W^0 & W^5 & W^2 & W^7 & W^4 & W^1 & W^6 & W^3 \\ W^0 & W^6 & W^4 & W^2 & W^0 & W^6 & W^4 & W^2 \\ W^0 & W^7 & W^6 & W^5 & W^4 & W^3 & W^2 & W^1 \end{bmatrix}.$$

Из свойства симметрии следует, что $W^{k+4} = -W^k$, где $k = \overline{0, N/2-1}$, т.е. $W^4 = -W^0$, $W^5 = -W^1$, $W^6 = -W^2$ и $W^7 = -W^3$. Тогда матрица F будет иметь вид

$$F = \begin{bmatrix} W^0 & W^0 & W^0 & W^0 & W^0 & W^0 & W^0 & W^0 \\ W^0 & W^1 & W^2 & W^3 & -W^0 & -W^1 & -W^2 & -W^3 \\ W^0 & W^2 & -W^0 & -W^2 & W^0 & W^2 & -W^0 & -W^2 \\ W^0 & W^3 & -W^2 & W^1 & -W^0 & -W^3 & W^2 & -W^1 \\ W^0 & -W^0 & W^0 & -W^0 & W^0 & -W^0 & W^0 & -W^0 \\ W^0 & -W^1 & W^2 & -W^3 & -W^0 & W^1 & -W^2 & W^3 \\ W^0 & -W^2 & -W^0 & W^2 & W^0 & -W^2 & -W^0 & W^2 \\ W^0 & -W^3 & -W^2 & -W^1 & -W^0 & W^3 & W^2 & W^1 \end{bmatrix}.$$

Пронумеруем строки матрицы F, начиная с 0, и используем бинарную инверсию для номеров строк: (0, 1, 2, 3, 4, 5, 6, 7) → (0, 4, 2, 6, 1, 5, 3, 7). Поменяем очередность в соответствии с новой последовательностью и умножим на вектор $\bar{x}$ дискретных отсчетов:

$$\overline{X^*} = \begin{bmatrix} W^0 & W^0 & W^0 & W^0 & W^0 & W^0 & W^0 & W^0 \\ W^0 & -W^0 & W^0 & -W^0 & W^0 & -W^0 & W^0 & -W^0 \\ W^0 & W^2 & -W^0 & -W^2 & W^0 & W^2 & -W^0 & -W^2 \\ W^0 & -W^2 & -W^0 & W^2 & W^0 & -W^2 & -W^0 & W^2 \\ W^0 & W^1 & W^2 & W^3 & -W^0 & -W^1 & -W^2 & -W^3 \\ W^0 & -W^1 & W^2 & -W^3 & -W^0 & W^1 & -W^2 & W^3 \\ W^0 & W^3 & -W^2 & W^1 & -W^0 & -W^3 & W^2 & -W^1 \\ W^0 & -W^3 & -W^2 & -W^1 & -W^0 & W^3 & W^2 & W^1 \end{bmatrix} \cdot \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \\ x_6 \\ x_7 \end{bmatrix} =$$

$$= \begin{bmatrix} A_1^1 & A_1^1 \\ B_1^1 & -B_1^1 \end{bmatrix} \bar{x} = \begin{matrix} A_1^1 \begin{Bmatrix} x_0 + x_4 \\ x_1 + x_5 \\ x_2 + x_6 \\ x_3 + x_7 \end{Bmatrix} \\ B_1^1 \begin{Bmatrix} x_0 - x_4 \\ x_1 - x_5 \\ x_2 - x_6 \\ x_3 - x_7 \end{Bmatrix} \end{matrix}, \tag{22}$$

где $A_1^1 = \begin{bmatrix} W^0 & W^0 & W^0 & W^0 \\ W^0 & -W^0 & W^0 & -W^0 \\ W^0 & W^2 & -W^0 & -W^2 \\ W^0 & -W^2 & -W^0 & W^2 \end{bmatrix}$, $B_1^1 = \begin{bmatrix} W^0 & W^1 & W^2 & W^3 \\ W^0 & -W^1 & W^2 & -W^3 \\ W^0 & W^3 & -W^2 & W^1 \\ W^0 & -W^3 & -W^2 & -W^1 \end{bmatrix}$.

По аналогии матрицы A_1^1 и B_1^1 также можно разложить на подматрицы более низкого порядка:

$$A_1^1 = \begin{vmatrix} A_1^2 & A_1^2 \\ A_2^2 & -A_2^2 \end{vmatrix}; \quad B_1^1 = \begin{vmatrix} B_1^2 & W_2 B_1^2 \\ B_2^2 & -W_2 B_2^2 \end{vmatrix}. \tag{23}$$

Подставляя выражения для A_1^1 и B_1^1 в (22), получим

$$\begin{matrix} A_1^2 \begin{Bmatrix} (x_0 + x_4) + (x_2 + x_6) \\ (x_1 + x_5) + (x_3 + x_7) \end{Bmatrix} \\ A_2^2 \begin{Bmatrix} (x_0 + x_4) - (x_2 + x_6) \\ (x_1 + x_5) - (x_3 + x_7) \end{Bmatrix} \\ B_1^2 \begin{Bmatrix} (x_0 - x_4) + W_2(x_2 - x_6) \\ (x_1 - x_5) + W_2(x_3 - x_7) \end{Bmatrix} \\ B_2^2 \begin{Bmatrix} (x_0 - x_4) - W_2(x_2 - x_6) \\ (x_1 - x_5) - W_2(x_3 - x_7) \end{Bmatrix} \end{matrix} \tag{24}$$

Наконец, на последнем шаге получим

$$\overline{X^*} = \begin{matrix} [(x_0 + x_4) + (x_2 + x_6)] + [(x_1 + x_5) + (x_3 + x_7)] \\ [(x_0 + x_4) + (x_2 + x_6)] - [(x_1 + x_5) + (x_3 + x_7)] \\ [(x_0 + x_4) - (x_2 + x_6)] + W_2[(x_1 + x_5) - (x_3 + x_7)] \\ [(x_0 + x_4) - (x_2 + x_6)] - W_2[(x_1 + x_5) - (x_3 + x_7)] \\ [(x_0 - x_4) + W_2(x_2 - x_6)] + W_1[(x_1 - x_5) + W_2(x_3 - x_7)] \\ [(x_0 - x_4) + W_2(x_2 - x_6)] - W_1[(x_1 - x_5) + W_2(x_3 - x_7)] \\ [(x_0 - x_4) - W_2(x_2 - x_6)] + W_3[(x_1 - x_5) - W_2(x_3 - x_7)] \\ [(x_0 - x_4) - W_2(x_2 - x_6)] - W_3[(x_1 - x_5) - W_2(x_3 - x_7)] \end{matrix}. \tag{25}$$

Описанный алгоритм удобно представить графически (рисунок 9).

Следует отметить, при реализации БПФ возможно несколько вариантов организации вычислений в зависимости от способа деления последовательности отсчетов на части (прореживание по времени либо по частоте) и от того, на сколько фрагментов выполняется разбиение последовательности на каждом шаге (основание БПФ).

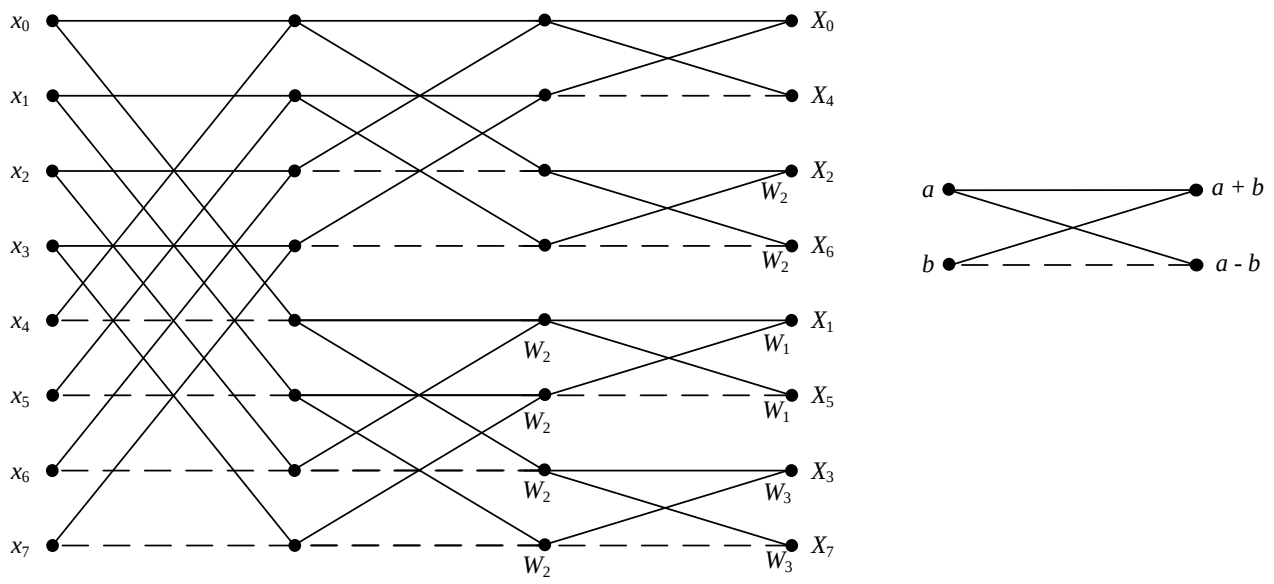

Рисунок 9 – Граф-схема быстрой процедуры вычисления коэффициентов преобразования Фурье

Алгоритм БПФ с прореживанием по времени (англ. Decimation In Time).

На рисунках 10 и 11 представлены граф-схема и операция «бабочка» для алгоритма БПФ с прореживанием по времени соответственно.

Алгоритм быстрого преобразования Фурье с прореживанием по времени можно описать следующим образом (a – коэффициенты Фурье-преобразования, полученные на текущей итерации, N –число отсчетов, $dir = \{-1,1\}$ определяет прямое или обратное Фурье-преобразования соответственно):

АЛГОРИТМ БПФ(*a, N, dir*)

{

1. Если длина вектора равна 1, вернуть a.
2. Разбить вектор a на четную часть $a^{\text{чет}} = (a_0, a_2, \dots, a_{N-2})$ и нечетную $a^{\text{нечет}} = (a_1, a_3, \dots, a_{N-1})$.
3. Рекурсивно вызвать БПФ на каждой из частей
$$b^{\text{чет}} = \text{БПФ}(a^{\text{чет}})$$
$$b^{\text{нечет}} = \text{БПФ}(a^{\text{нечет}})$$
4. Объединение результатов.

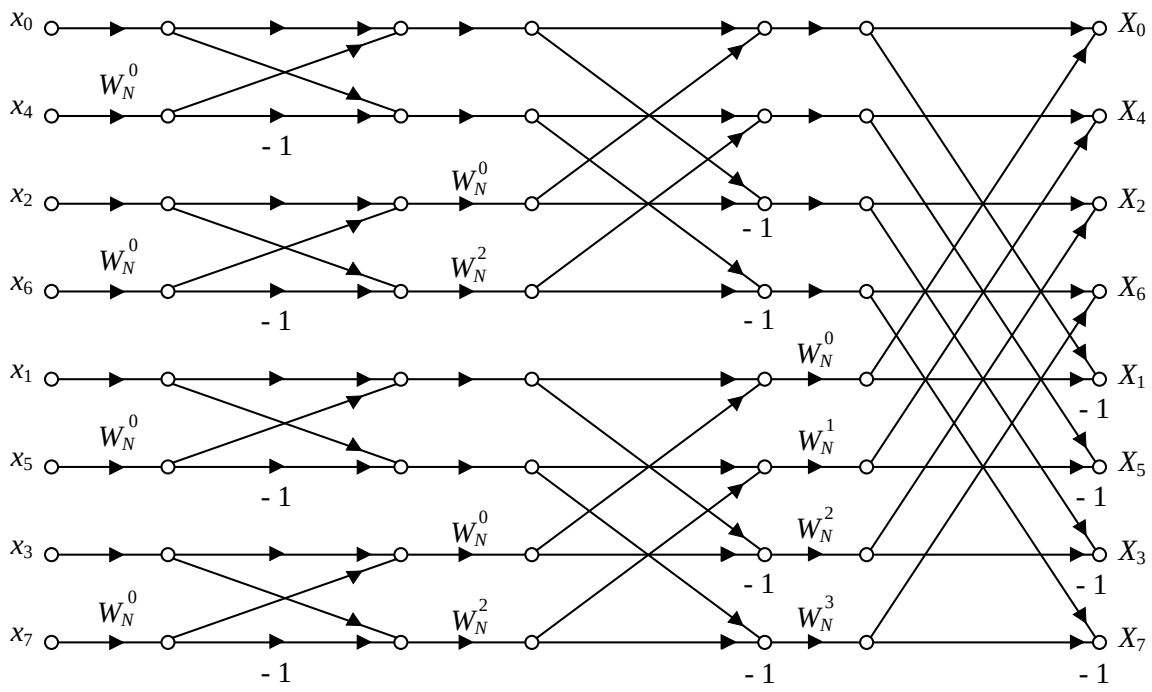

Рисунок 10 – Граф-схема алгоритма БПФ с прореживанием по времени

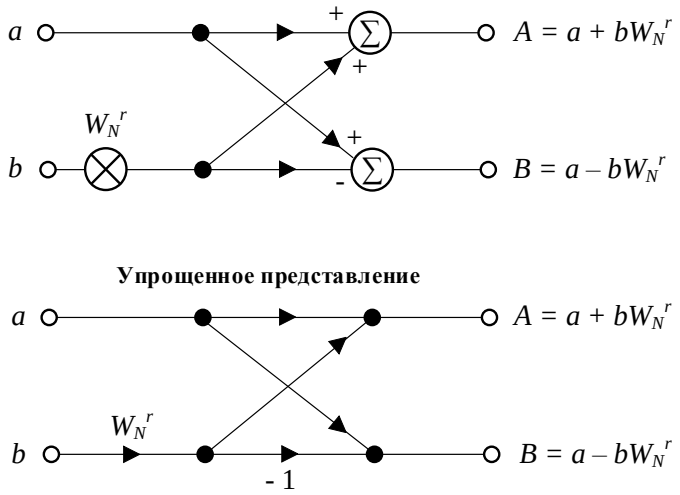

Рисунок 11 – Операция «бабочка» в алгоритме БПФ
с прореживанием по времени

a. (инициализация) Присвоить ω_N значение главного комплексного корня N-й степени из единицы

$$\omega_N = e^{\frac{2\pi i}{N}} = \cos\frac{2\pi}{N} + dir \cdot i\sin\left(\frac{2\pi}{N}\right)$$

b. (инициализация) Присвоить $\omega = 1$
c. В цикле вычислить левую и правую часть одновременно:
for (j=0; j < N/2; j++) {

$$y_j = b_j^{\text{чет}} + \omega b_j^{\text{нечет}}$$
$$y_{j+N/2} = b_j^{\text{чет}} - \omega b_j^{\text{нечет}}$$
$$\omega = \omega \cdot \omega_N$$

}

5. Вернуть вектор y.

}

При реализации алгоритма БПФ с прореживанием по времени вектор разбивается на две части – четную и нечетную, после чего выполняется операция бабочка.

На рисунке 12 изображено дерево рекурсий, описывающее данное разложение. Каждый уровень, начиная снизу, соответствует проходу алгоритма по всему вектору и объединению сначала одиночных элементов в пары, затем пар в четверки и так далее до конца. Обратите внимание на то, что порядок индексов на верхнем уровне не соответствует нижнему. Это естественно, если учесть, что нечетные индексы после бабочки идут в правую половину вектора, а четные – в левую.

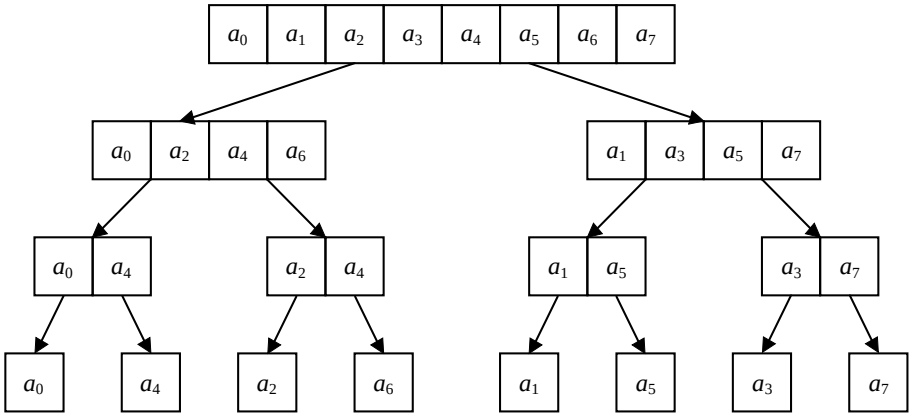

Рисунок 12 – Дерево рекурсий для 8 элементов

Алгоритм БПФ с прореживанием по частоте (англ. Decimation In Frequency).

При реализации алгоритма БПФ с прореживанием по частоте вначале выполняется операция бабочка, затем вектор разбивается на две части («верхнюю» и «нижнюю»).

На рисунках 13 и 14 представлены граф-схема и операция «бабочка» для алгоритма БПФ с прореживанием по частоте соответственно.

Алгоритм быстрого преобразования Фурье с прореживанием по частоте можно описать следующим образом.

АЛГОРИТМ БПФ(*a, N, dir*)

{

1. Если длина вектора равна 1, вернуть a.
2.

✓ Присвоить ω_N значение главного комплексного корня N-й степени из единицы $\omega_N = e^{i\frac{2\pi}{N}} = \cos\frac{2\pi}{N} + dir \cdot i\sin\frac{2\pi}{N}$

✓ Присвоить $\omega = 1$

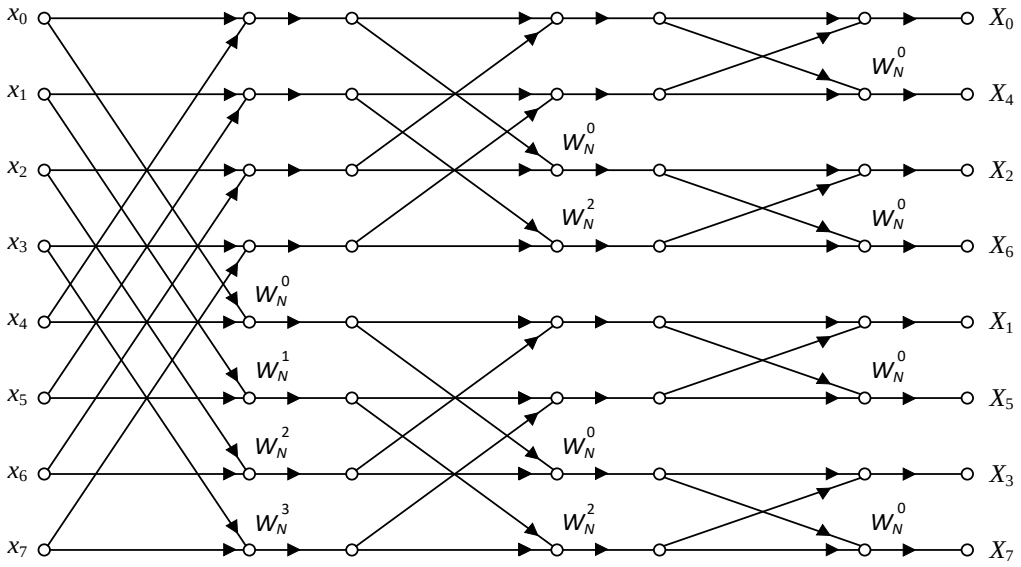

Рисунок 13 – Граф-схема алгоритма БПФ с прореживанием по частоте

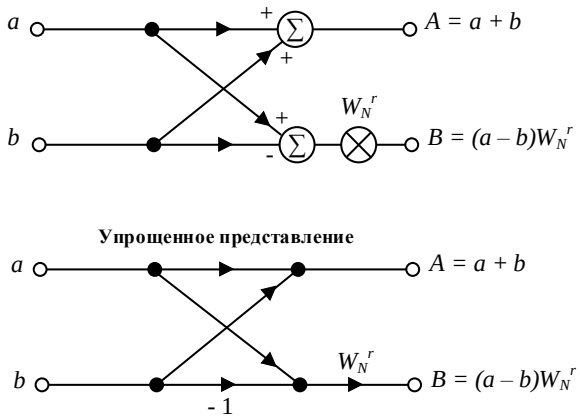

Рисунок 14 – Операция «бабочка» в алгоритме БПФ с прореживанием по частоте

for(j=0; j < N/2; j++) {

$b_j = a_j + a_{j+N/2}$

$c_{j+N/2} = (a_j - a_{j+N/2})\omega$

$\omega = \omega \cdot \omega_N$

}

3. Рекурсивно вызвать БПФ на каждой из частей

y = БПФ(b)
y = БПФ(c)

4. Объединение результатов.
5. Вернуть вектор y.

}

Свертка и корреляция.

Свертка – это фундаментальная математическая операция в ЦОС, описывающая, как форма одного сигнала изменяется под воздействием другого. На практике различают линейную и циклическую свертки.

Линейная свертка двух сигналов $x(n)$, $n = \overline{0, N-1}$, и $y(n)$, $n = \overline{0, M-1}$, описывается уравнением:

$$s(n) = x * y = \sum_{m=0}^{n} x(m) \cdot y(n-m), \tag{26}$$

где $n = \overline{0, N+M-1}$ – число дискретных отсчетов в выходном сигнале s; N и M – число дискретных отсчетов в сигнале x и y соответственно.

Алгоритм вычисления линейной свертки сводится к следующим действиям:

– дополняется нулями слева сигнал x до длины $N + M - 1$;

– инвертируется во времени сигнал y и дополняется нулями справа до длины $N + M - 1$;

– в цикле от 0 до $N + M - 2$ сигнал y сдвигается вправо (или сигнал x влево);

– на каждом шаге цикла вычисляется произведение элементов и подсчитывается сумма произведений.

Основные свойства свертки:

– коммутативность: $x * y = y * x$;

– дистрибутивность: $x * (y + z) = x * y + x * z$;

– ассоциативность: $x * (y * z) = (x * y) * z = (x * z) * y$.

Примеры практического применения линейной свертки будут рассмотрены в следующей лабораторной работе.

В случае *циклической свертки* предполагается, что дискретные сигналы $x(n)$ и $y(n)$ – периодические с одинаковым периодом, равным N отсчетов. Если данное условие нарушается, возникает эффект наложения (aliasing) во временной области. Циклической сверткой сигналов $x(n)$ и $y(n)$ называется сигнал вида:

$$s(n) = \sum_{m=0}^{N-1} x(m) \cdot y\big((n-m) \bmod N\big), \tag{27}$$

где $n = \overline{0, N-1}$ – число дискретных отсчетов в выходном сигнале s; $a\ mod\ N$ – операция, вычисляющая остаток от деления a на N.

Алгоритм вычисления циклической свертки сводится к следующим действиям:

– инвертируется сигнал y;

– в цикле от 0 до $N-1$ выполняется сдвиг сигнала y вправо (или сигнала x влево);

– на каждом шаге цикла вычисляется произведение элементов и подсчитывается сумма произведений.

На практике циклическая свертка используется для эффективного вычисления свертки во временной области через умножение в частотной области (см. теорему о свертке далее).

Корреляция – это операция, которая измеряет степень сходства одного сигнала с временными сдвигами другого сигнала и используется для обнаружения сигналов, синхронизации и измерения задержки.

Различают два основных типа корреляции:

– автокорреляцию;

– взаимную корреляцию.

Взаимная корреляция $r_{xy}(m)$ двух сигналов $x(n)$ и $y(n)$ определяет сходство $x(n)$ с сигналом $y(n)$, сдвинутым на m отсчетов:

$$r_{xy}(m) = \sum_{n=0}^{N-1} x(n) \cdot y(n+m). \tag{28}$$

На практике взаимная корреляция может использоваться для определения временной задержки между двумя одинаковыми, но разнесенными во времени сигналами (например, в эхолокации и радиолокации). Кроме того, пик функции взаимной корреляции соответствует величине задержки m, при которой сигналы $x(n)$ и $y(n)$ наиболее похожи.

Автокорреляция $r_{xx}(m)$ – это частный случай корреляции, когда сигнал сравнивается сам с собой, сдвинутым на m отсчетов:

$$r_{xx}(m) = \sum_{n=0}^{N-1} x(n) \cdot x(n+m). \tag{29}$$

На практике используется для обнаружения периодичности в сигнале (например, определения основного тона в речевом сигнале) и в анализе случайных процессов. Кроме того, если сигнал периодичен, функция автокорреляции также будет периодична.

Примечание. При вычислении свертки и корреляции дополнительно может использоваться нормировочный коэффициент $^1/_N$.

Теорема корреляции.

Если $x(m)$ и $y(m)$ – последовательности действительных чисел, для которых $x(m) \leftrightarrow X(k)$, $y(m) \leftrightarrow Y(k)$, а их функция корреляции определяется соотношением

$$\hat{z}(m) = \sum_{h=0}^{N-1} x(h)y(m+h)\,, \tag{30}$$

$m = \overline{0, N-1}$, то $\hat{Z}(k) = X^*(k)\mathrm{Y}(k)$, где $X^*(k)$ – комплексно-сопряженное $X(k)$.

Доказательство. По определению прямого ДПФ имеем (формула 18):

$$\hat{Z}(k) = \sum_{m=0}^{N-1} \hat{z}(m)W^{km}\,. \tag{31}$$

Подставляя (30) в (31) и меняя порядок суммирования, получаем

$$\hat{Z}(k) = \sum_{m=0}^{N-1} \sum_{h=0}^{N-1} x(h)y(m+h)\,W^{km} =$$

$$= \sum_{h=0}^{N-1} x(h)\left\{\sum_{m=0}^{N-1} y(m+h)W^{km}\right\}.$$

Применим теорему сдвига (формула 21):

$$\sum_{m=0}^{N-1} y(m+h)W^{km} = Y(k)\cdot W^{-kh}.$$

Тогда

$$\hat{Z}(k) = Y(k)\left\{\sum_{h=0}^{N-1} x(h)W^{-kh}\right\}.$$

Так как $X(k) = \sum_{h=0}^{N-1} x(h)W^{kh}$, то $\sum_{h=0}^{N-1} x(h)W^{-kh} = X^*(k)$.

Таким образом, $\hat{Z}(k) = X^*(k)\mathrm{Y}(k)$.

Таким образом, схема вычислений корреляции с использованием БПФ будет иметь вид, представленный на рисунке 15.

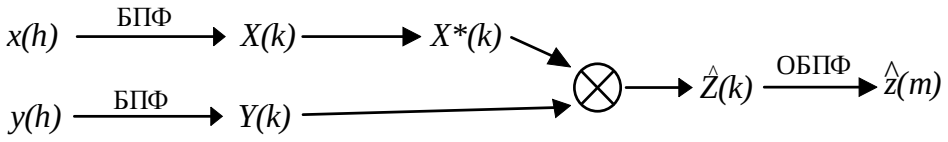

Рисунок 15 – Схема вычисления корреляции

Теорема свертки.

Если $x(n)$ и $y(n)$ – последовательности действительных чисел, для которых $x(n) \leftrightarrow X(k)$, $y(n) \leftrightarrow Y(k)$, и линейная свертка этих последовательностей определяется как

$$z(m) = \sum_{m=0}^{N-1} x(m) \cdot y\big((n-m)\ mod\ N\big), \tag{32}$$

тогда $Z(k) = X(k)Y(k)$.

Доказательство выполняется по аналогии теореме корреляции и предлагается выполнить студентам самостоятельно.

Эта теорема утверждает, что свертка временных последовательностей эквивалентна умножению их коэффициентов, полученных после дискретного преобразования Фурье. Таким образом, схема вычислений свертки с использованием БПФ будет иметь вид, представленный на рисунке 16.

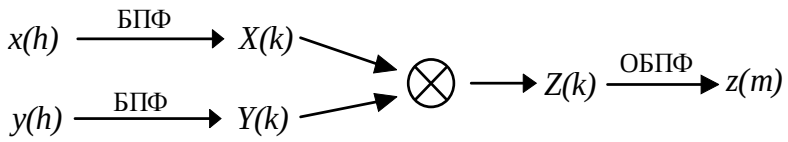

Рисунок 16 – Схема вычисления свертки

Матричное представление корреляции и свертки.

Пусть $N = 4$, операция корреляции в этом случае будет иметь вид:

$$4\hat{z}(0) = x(0)y(0) + x(1)y(1) + x(2)y(2) + x(3)y(3);$$
$$4\hat{z}(1) = x(0)y(1) + x(1)y(2) + x(2)y(3) + x(3)y(0);$$
$$4\hat{z}(2) = x(0)y(2) + x(1)y(3) + x(2)y(0) + x(3)y(1);$$
$$4\hat{z}(3) = x(0)y(3) + x(1)y(0) + x(2)y(1) + x(3)y(2).$$

В матричном виде это эквивалентно:

$$\begin{bmatrix} \hat{z}(0) \\ \hat{z}(1) \\ \hat{z}(2) \\ \hat{z}(3) \end{bmatrix} = \frac{1}{4} \begin{bmatrix} x(0) & x(1) & x(2) & x(3) \\ x(3) & x(0) & x(1) & x(2) \\ x(2) & x(3) & x(0) & x(1) \\ x(1) & x(2) & x(3) & x(0) \end{bmatrix} \begin{bmatrix} y(0) \\ y(1) \\ y(2) \\ y(3) \end{bmatrix}.$$

В общем виде корреляцию двух последовательностей можно записать как

$$\begin{bmatrix} \hat{z}(0) \\ \hat{z}(1) \\ \hat{z}(2) \\ \vdots \\ \hat{z}(N-2) \\ \hat{z}(N-1) \end{bmatrix} = \frac{1}{N} \begin{bmatrix} x(0) & x(1) & x(2) & \cdots & x(N-1) \\ x(N-1) & x(0) & x(1) & \cdots & x(N-2) \\ x(N-2) & x(N-1) & x(0) & \cdots & x(N-3) \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ x(2) & x(3) & x(4) & \cdots & x(1) \\ x(1) & x(2) & x(3) & \cdots & x(0) \end{bmatrix} \begin{bmatrix} y(0) \\ y(1) \\ y(2) \\ \vdots \\ y(N-2) \\ y(N-1) \end{bmatrix}.$$

Аналогично свертка при $N = 4$ будет иметь вид:

$$4z(0) = x(0)y(0) + x(1)y(-1) + x(2)y(-2) + x(3)y(-3);$$
$$4z(1) = x(0)y(1) + x(1)y(0) + x(2)y(-1) + x(3)y(-2);$$
$$4z(2) = x(0)y(2) + x(1)y(1) + x(2)y(0) + x(3)y(-1);$$
$$4z(3) = x(0)y(3) + x(1)y(2) + x(2)y(1) + x(3)y(0).$$

Так как $[y(k)]_{\mathrm{mod}N} = y(k-N)$ при $k > 0$,
$[y(k)]_{\mathrm{mod}N} = y(k+N)$ при $k < 0$, то

$$\begin{bmatrix} z(0) \\ z(1) \\ z(2) \\ z(3) \end{bmatrix} = \frac{1}{4} \begin{bmatrix} x(0) & x(1) & x(2) & x(3) \\ x(1) & x(2) & x(3) & x(0) \\ x(2) & x(3) & x(0) & x(1) \\ x(3) & x(0) & x(1) & x(2) \end{bmatrix} \begin{bmatrix} y(0) \\ y(3) \\ y(2) \\ y(1) \end{bmatrix}.$$

В свою очередь, соотношение свертки можно записать в общем виде как

$$\begin{bmatrix} z(0) \\ z(1) \\ z(2) \\ \vdots \\ z(N-2) \\ z(N-1) \end{bmatrix} = \frac{1}{N} \begin{bmatrix} x(0) & x(1) & x(2) & \cdots & x(N-1) \\ x(1) & x(2) & x(3) & \cdots & x(0) \\ x(2) & x(3) & x(4) & \cdots & x(1) \\ \vdots & \vdots & \vdots & \cdots & \vdots \\ x(N-2) & x(N-1) & x(0) & \cdots & x(N-3) \\ x(N-1) & x(0) & x(1) & \cdots & x(N-2) \end{bmatrix} \begin{bmatrix} y(0) \\ y(N-1) \\ y(N-2) \\ \vdots \\ y(2) \\ y(1) \end{bmatrix}.$$

Амплитудный и фазовый спектры сигнала.

Поскольку результат преобразования Фурье $X(\omega)$ является комплексным числом, т.е. $X(\omega) = \mathrm{Re}(\omega) + j \cdot \mathrm{Im}(\omega)$, его можно представить в полярной форме:

$$X(\omega) = |X(\omega)| \cdot e^{j \cdot \arg(X(\omega))},$$

где модуль $|X(\omega)|$ определяет *амплитудный спектр*, аргумент $\arg(X(\omega))$ определяет *фазовый спектр*.

Амплитудный спектр – график зависимости амплитуды каждой гармонической составляющей от ее частоты, показывающий, какие частоты присутствуют в сигнале и насколько они сильны:

$$A(\omega) = |X(\omega)|.$$

Он является наиболее распространенным представлением спектра и часто используется для анализа полосы пропускания, обнаружения гармоник и фильтрации. Например, если сигнал представляет собой музыкальный аккорд, амплитудный спектр покажет, какие ноты (частоты) и с какой громкостью (амплитудой) его составляют.

Фазовый спектр – график зависимости начальной фазы каждой гармонической составляющей от ее частоты, показывающий взаимное расположение гармонических составляющих во времени:

$$\Phi(\omega) = \arg(X(\omega)) = \arctan\left(\frac{\mathrm{Im}(\omega)}{\mathrm{Re}(\omega)}\right).$$

Он содержит информацию о том, как смещены во времени (относительно начального момента $t = 0$) разные частотные компоненты сигнала. Изменение фазового спектра, даже при сохранении амплитудного, может радикально изменить форму сигнала во временной области, влияя на его восприятие (например, в звуке) или функциональность (например, в передаче данных).

3. Задание

1. Ознакомиться с теоретической частью.

2. Для заданных дискретных сигналов $x(t)$ и $y(t)$ (либо специально подобранных музыкальных файлов) выполнить следующие задания (в соответствии с заданным вариантом, выданным преподавателем):

– реализовать операцию свертки двух сигналов;

– реализовать операцию корреляции двух сигналов;

– для сигналов $x(t)$ и $y(t)$, а также результата выполнения операции свертки выполнить прямое и обратное преобразование Фурье;

– построить графики амплитудного и фазового спектра сигналов;

– построить графики сигналов во временной области;

– экспериментально проверить корректность схем вычисления свертки и корреляции (в соответствии с рисунками 15 и 16).

3. Сравнить полученные результаты при разных значениях N, оценить эффективность алгоритмов в зависимости от N.

Примечание. Прямое и обратное преобразования Фурье, вычисление операций свертки и корреляции должны быть представлены в двух вариантах – реализованные студентом самостоятельно и с использованием Open Source библиотек.

4. Оформить итоговый отчет с указанием исходных данных, результатов работы, построенных графиков, выводами о результатах работы.

4. Контрольные вопросы

1. Сформулируйте условия Дирихле, которым должен удовлетворять сигнал для разложения в ряд Фурье.

2. В чем заключается физический смысл амплитудного и фазового спектров сигнала?

3. Запишите аналитические выражения для прямого и обратного дискретного преобразования Фурье.

4. Какими двумя основными свойствами обладают коэффициенты W_N в алгоритме ДПФ?

5. Как изменится спектр сигнала при его сдвиге во временной области?

6. В чем заключается свойство комплексной сопряженности спектра ДПФ для действительных последовательностей?

7. Сравните асимптотическую сложность алгоритмов ДПФ и БПФ. За счет чего достигается ускорение вычислений в БПФ?

8. Объясните суть алгоритма БПФ с прореживанием по времени. Как происходит разделение входной последовательности?

9. Нарисуйте и объясните элементарную операцию «бабочка», используемую в алгоритмах БПФ.

10. Чем отличается линейная свертка сигналов от циклической?

11. Какой эффект возникает при вычислении свертки через ДПФ, если не дополнить исходные сигналы нулями до необходимой длины?

12. Опишите алгоритм вычисления взаимной корреляции двух сигналов с использованием БПФ.

13. Какую информацию можно получить, анализируя пик функции взаимной корреляции двух сигналов?

14. Сформулируйте теорему о свертке. Какому действию в частотной области соответствует свертка во временной области?

15. Как связана автокорреляция периодического сигнала с его периодичностью?

ЛАБОРАТОРНАЯ РАБОТА №2
ПРОЕКТИРОВАНИЕ ЦИФРОВЫХ ФИЛЬТРОВ

1. Цель работы

Изучить теоретические основы и методы проектирования цифровых фильтров (КИХ и БИХ); приобрести практические навыки программной реализации алгоритмов цифровой фильтрации (сглаживающие фильтры, оконный метод, билинейное преобразование) и провести сравнительный анализ их амплитудно-частотных характеристик и влияния на реальные аудиосигналы.

2. Теоретические сведения

Цифровой фильтр – это система, которая обрабатывает дискретный сигнал с целью изменения его характеристик, таких как амплитуда, частота или фаза. Фильтры используются для подавления шума, выделения определённых частот, сглаживания сигнала или коррекции амплитудно-частотной характеристики (АЧХ).

Основные характеристики фильтров.

К основным характеристикам фильтра относится (на рисунке 17 показан пример характеристик для фильтра нижних частот):

– полоса пропускания, определяющая диапазон частот, который фильтр пропускает с минимальным затуханием;

– полоса подавления, определяющая диапазон частот, который фильтр подавляет;

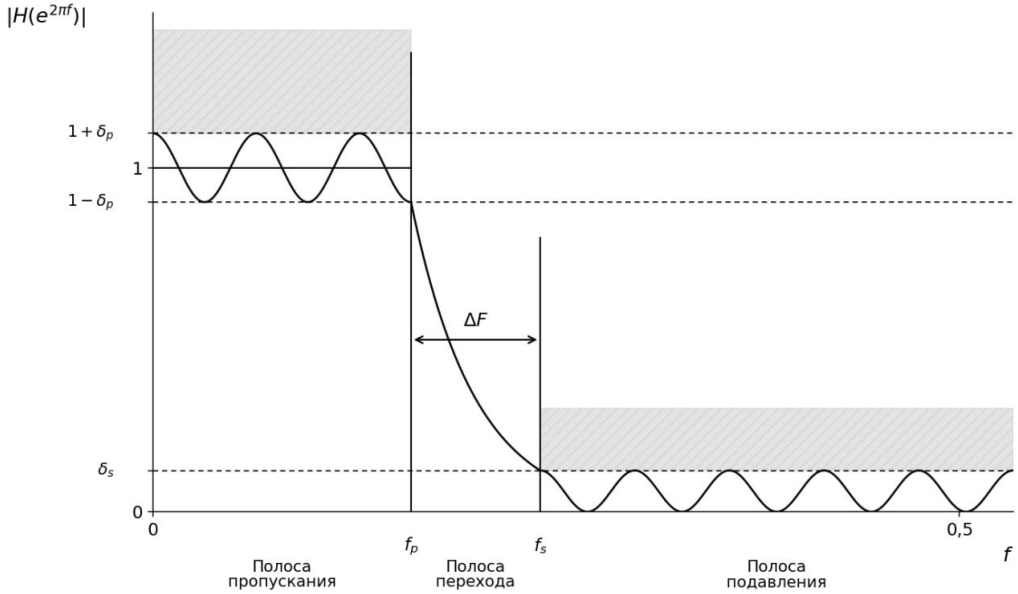

Рисунок 17 – Основные характеристики на примере фильтра нижних частот

– полоса перехода, определяющая переходную область между полосой пропускания и полосой подавления;

– отклонение амплитуды в полосе пропускания и подавления;

– частота среза, определяющая частоту, на которой амплитуда сигнала уменьшается на заданный уровень;

– затухание в полосе подавления: $A_s = -20 \cdot \lg(\delta_s)$;

– неравномерность в полосе пропускания: $A_p = 20 \cdot \lg(1 + \delta_p)$.

Амплитудно- и фазо-частотная характеристика.

Амплитудно-частотная характеристика (АЧХ) и фазо-частотная характеристика (ФЧХ) являются двумя основными способами описания частотной характеристики динамической системы (например, фильтра, усилителя).

АЧХ (англ. Amplitude-Frequency Response) показывает, как изменяется амплитуда установившихся колебаний выходного сигнала некоторой системы от частоты ω её входного гармонического (синусоидального) сигнала. На практике применяется для определения полосы пропускания устройства, его избирательных свойств и способности передавать разные частоты без искажения их амплитуд.

ФЧХ (англ. Phase-Frequency Response) показывает, как изменяется сдвиг фазы выходного сигнала (в радианах) относительно входного гармонического сигнала в зависимости от частоты ω. На ее основе можно определить, на какой угол сдвигается фаза выходного сигнала по сравнению с фазой входного сигнала на данной частоте, что эквивалентно задержке сигнала в системе, а также для анализа фазовых искажений (например, в аудиосистемах) и для оценки устойчивости систем автоматического управления.

Классификация фильтров.

По *области применения* фильтры делятся на:

– фильтры временной области, которые используются для сглаживания, устранения постоянной составляющей во временной области (например, однополюсные фильтры);

– фильтры частотной области, которые выполняют частотную селекцию (при этом выделяются низкочастотные, высокочастотные, полосовые и режекторные фильтры);

– специальные фильтры, в которых выполняется коррекция АЧХ и/или оптимальная фильтрация (например, фильтры Чебышева).

По *внутренней структуре* фильтры делятся на:

– КИХ-фильтры;

– БИХ-фильтры.

Классификация фильтров по рабочей области и структуре построения представлены в таблице 1.

Таблица 1. Классификация фильтров [4]

По **области применения**	По **внутренней структуре**	
	На основе свертки (КИХ-фильтры)	С рекурсивной структурой (БИХ-фильтры)
Фильтры временной области (сглаживание, устранение постоянной составляющей)	Однородные фильтры	Однополюсные рекурсивные фильтры
Фильтры частотной области (частотная селекция)	Оконные фильтры	Фильтры Чебышева
Специальные фильтры (коррекция АЧХ, оптимальная фильтрация)	Специальные КИХ-фильтры	Фильтры с итеративной структурой

Кроме того, *КИХ-фильтры* (рисунок 18) можно разделить на:
– низкочастотный: пропускает низкие частоты, подавляет высокие;
– высокочастотный: пропускает высокие частоты, подавляет низкие;
– полосовой: пропускает определённый диапазон частот;
– режекторный: подавляет определённый диапазон частот.

Однородные фильтр (фильтры скользящего среднего).

Однородный не рекурсивный фильтр – фильтр, основанный на усреднении некоторого множества отсчетов входного сигнала:

$$y(n) = \frac{1}{M}\sum_{j=0}^{M-1} x(n+j)\,, \tag{33}$$

где $x(n)$ и $y(n)$ – входной и выходной сигналы соответственно, M – число усредняемых отсчетов.

Следует отметить, что формула (33) описывает фильтр, в котором все используемые отсчеты расположены по одну сторону от результирующего выходного отсчета. Однако, в общем случае, при нечетном значении M может быть выполнено центрирование и отсчеты для вычислений будут браться симметрично относительно текущего значения.

Однородный рекурсивный фильтр – однородный фильтр, оптимизирующий процесс вычисления не рекурсивного варианта:

$$y(n) = y(n-1) + x(n+p) - x(n-q), \tag{34}$$

где $p = \frac{M-1}{2}$, $q = p + 1$.

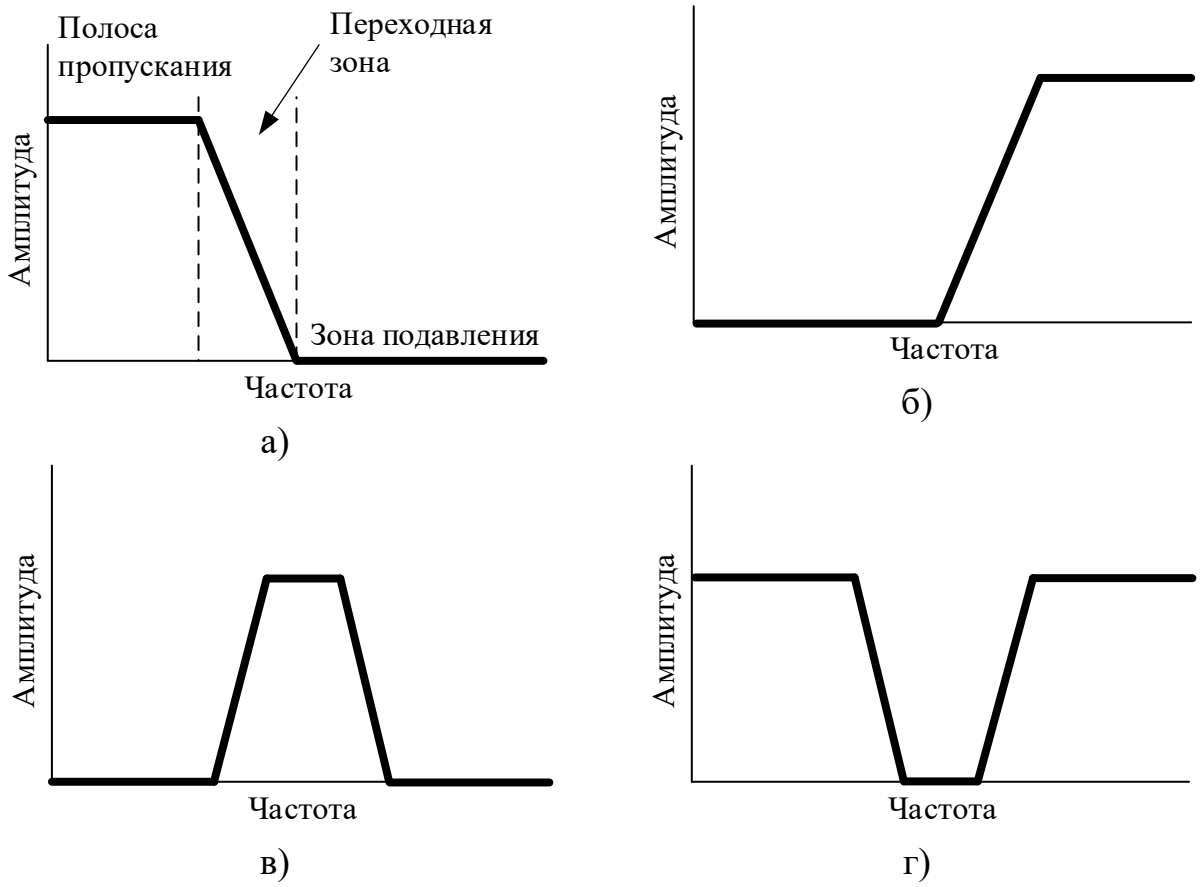

Рисунок 18 – Амплитудно-частотная характеристика основных типов фильтра:
а) низкочастотный; *б*) высокочастотный *в*) полосовой *г*) режекторный

КИХ-фильтры (англ. Finite Impulse Response, FIR).

КИХ-фильтры – это фильтры с конечной импульсной характеристикой, т.е. их выходной сигнал зависит только от ограниченного числа входных отсчётов. На практике данный тип фильтров реализуется с помощью свёртки входного сигнала с импульсной характеристикой фильтра.

Выходной сигнал $y(n)$ КИХ-фильтра определяется как:

$$y(n) = \sum_{k=0}^{N-1} h(k) \cdot x(n-k)\,, \tag{35}$$

где $x(n)$ – входной сигнал в момент времени n, $h(k)$ – импульсная характеристика фильтра (коэффициенты фильтра), N – размерность фильтра.

Передаточная функция КИХ-фильтра, необходимая для его анализа и проектирования:

$$H(z) = \sum_{k=0}^{N-1} h(k) z^{-k}. \quad (36)$$

где z^{-k} – задержка последовательности на k отсчетов.

Метод взвешивания при проектировании КИХ-фильтра. Для того, чтобы спроектировать КИХ-фильтр методом взвешивания необходимо выполнять 4 этапа.

Этап 1. Задать «идеальную» или желаемую частотную характеристику фильтра $H_D(\omega)$.

Этап 2. Получить импульсную характеристику $h_D(n)$ желаемого фильтра, найдя для этого Фурье-образ частотной характеристики. Готовые выражения для $h_D(n)$ стандартных частотно-избирательных фильтров приведены в таблице 2 (в таблице $\omega_c = 2\pi f_c$).

Таблица 2. Идеальные импульсные характеристики стандартных частотно-избирательных фильтров

Тип фильтра	**Идеальная частотная характеристика**, $h_D(n)$	
	$h_D(n), n \neq 0$	$h_D(0)$
Фильтр нижних частот	$2f_c \frac{\sin(n\omega_c)}{n\omega_c}$	$2f_c$
Фильтр верхних частот	$-2f_c \frac{\sin(n\omega_c)}{n\omega_c}$	$1 - 2f_c$
Полосовой фильтр	$2f_2 \frac{\sin(n\omega_2)}{n\omega_2} - 2f_1 \frac{\sin(n\omega_1)}{n\omega_1}$	$2(f_2 - f_1)$
Режекторный фильтр	$2f_1 \frac{\sin(n\omega_1)}{n\omega_1} - 2f_2 \frac{\sin(n\omega_2)}{n\omega_2}$	$1 - 2(f_2 - f_1)$

Этап 3. Выбрать весовую функцию, которая удовлетворяет требованиям к полосе пропускания или затуханию, а затем определить число коэффициентов фильтра, использовав подходящее выражение для связи длины фильтра с шириной перехода $\triangle f$ (таблица 3).

Этап 4. Получить значения выбранной весовой функции $w(n)$ и значения коэффициентов реального КИХ-фильтра $h(n)$, умножив $h_D(n)$ на $w(n)$:

$$h(n) = h_D(n) \cdot w(n).$$

Выбор окна влияет на ширину полосы перехода и уровень подавления.

БИХ-фильтры (Infinite Impulse Response, IIR).

БИХ-фильтр относится к группе рекурсивных, т.е. выходной сигнал зави-

сит как от текущих и предыдущих входных отсчётов, так и от предыдущих выходных отсчётов:

$$y(n) = \sum_{k=0}^{\infty} h(k)x(n-k) = \sum_{k=0}^{N} a_k x(n-k) + \sum_{k=1}^{M} b_k y(n-k)\,,$$

где $h(k)$ – импульсная характеристика фильтра, длительность которой теоретически бесконечна; a_k и b_k – весовые коэффициенты прямой и обратной связей.

Разностное уравнение БИХ-фильтра можно выразить через передаточную функцию $H(z)$ в Z-области:

$$H(z) = \frac{Y(z)}{X(z)} = \frac{\sum_{k=0}^{N} a_k z^{-k}}{1 + \sum_{k=1}^{N} b_k z^{-k}}\,.$$

Для проектирования и реализации фильтра необходимо определить коэффициенты b_k и a_k.

Однополюсный рекурсивный фильтр. Это простейший тип БИХ-фильтров, полностью повторяющий свойства аналогового фильтра, построенного на основе RC-цепи. Для расчета весовых коэффициентов однополюсного фильтра можно воспользоваться следующими уравнениями:

Однополюсный НЧ-фильтр

$$a_0 = 1 - \alpha$$
$$b_1 = \alpha$$

Однополюсный ВЧ-фильтр

$$a_0 = \frac{1+\alpha}{2}$$
$$a_1 = -\frac{1+\alpha}{2}$$
$$b_1 = \alpha$$

где $\alpha = e^{-\frac{1}{d}} = e^{-2\pi f_c}$ – коэффициент, определяющий относительное затухание на интервале между соседними отсчетами ($0 < \alpha < 1$); d – постоянная времени, соответствующая интервалу времени в RC-цепи, через которое отклонение амплитуда входного сигнала от установившегося значения сокращается в ходе переходного процесса до 36,8% от первоначальной величины; f_c – частота среза фильтра, определяемая на уровне -3 дБ, $0 < f_c < 0{,}5$.

Аналогично для 4-каскадного НЧ-фильтра можно воспользоваться следующими уравнениями (при этом значение $\alpha = e^{-14{,}445 f_c}$):

$$a_0 = (1-\alpha)^4 \qquad b_2 = -6\alpha^2 \qquad b_4 = -\alpha^4$$
$$b_1 = 4\alpha \qquad b_3 = 4\alpha^3$$

Таблица 3. Примеры окон, используемые при фильтрации [4]

Название окна	**Ширина перехода $\triangle f$, Гц**	**Неравномерность в полосе пропускания, дБ**	**Главный лепесток относительно бокового лепестка**	**Затухание в полосе подавления**	**Функция**
Прямоугольное окно	$\frac{0,9}{N}$	0,7416	13	21	$w[n] = \begin{cases} 1, & 0 \le n \le N-1 \\ 0, & \text{иначе} \end{cases}$
Окно Ханна (Hanning)	$\frac{3,1}{N}$	0,0546	31	44	$w[n] = 0,5\left[1 - \cos\left(\frac{2\pi n}{N-1}\right)\right]$
Окно Хэмминга	$\frac{3,3}{N}$	0,0194	41	53	$w[n] = 0,54 - 0,46\cos\left(\frac{2\pi n}{N-1}\right)$
Окно Блэкмана	$\frac{5,5}{N}$	0,0017	57	75	$w[n] = 0,42 - 0,5\cos\left(\frac{2\pi n}{N-1}\right) + 0,08\cos\left(\frac{4\pi n}{N-1}\right)$

Узкополосный рекурсивный фильтр. Данный тип фильтров используется, когда необходимо выделить узкую полосу частот в исходном широкополосном сигнале (например, отделить тональные сигналы в телефонной сети). Для этого используются фильтры двух типов: полосовые и режекторные.

Чтобы рассчитать весовые коэффициенты фильтра, необходимо задать два параметра, измеряемые относительно частоты дискретизации и, следовательно, принимающие значения в диапазоне 0…0,5:

– центральную частоту f;

– ширину полосы пропускания BW.

Затем вычисляются промежуточные коэффициенты R и K:

$$R = 1 - 3BW,$$

$$K = \frac{1 - 2R \cdot \cos 2\pi f + R^2}{2 - 2\cos(2\pi f)}.$$

Весовые коэффициенты фильтров могут быть определены с помощью следующих систем уравнений:

Полосовой узкополосный фильтр	Режекторный узкополосный фильтр
$a_0 = 1 - K$	$a_0 = K$
$a_1 = 2(K - R)\cos(2\pi f)$	$a_1 = 2K\cos(2\pi f)$
$a_2 = R^2 - K$	$a_2 = K$
$b_1 = 2R \cdot \cos(2\pi f)$	$b_1 = 2R \cdot \cos(2\pi f)$
$b_2 = -R^2$	$b_2 = -R^2$

Фильтр Чебышева I типа. Для данного типа фильтров допускается наличие колебаний АЧХ только в полосе пропускания. Для того, чтобы получить весовые коэффициенты можно воспользоваться методом Чебышева-Баттерворта, в основе которого переход от карты нулей и полюсов аналогового фильтра к цифровому. Блок-схема метода представлена на рисунке ___.

Входные параметры:

– f_c – нормированная частота среза, $0 < f_c \leq 0.5$;

– P_R – неравномерность АЧХ в полосе пропускания, $0\% \leq P_R \leq 29\%$;

– N_P – количество полюсов (порядок фильтра), четное число от 2 до 20;

– P – индекс текущей пары полюсов (от 1 до $N_P/2$).

Шаг 1. Вычислить на S-плоскости координаты полюсов НЧ-фильтра Баттерворта с частотой среза $\omega = 1$.

Частота среза ω выбрана равной единице, поскольку соответствует окружности единичного радиуса. Пару полюсов можно представить в аналитической форме $\sigma \pm j\omega$, где

$$\sigma = -\cos\left(\frac{\pi}{2N_P} + (P-1)\frac{\pi}{N_P}\right);$$

$$\omega = \sin\left(\frac{\pi}{2N_P} + (P-1)\frac{\pi}{N_P}\right).$$

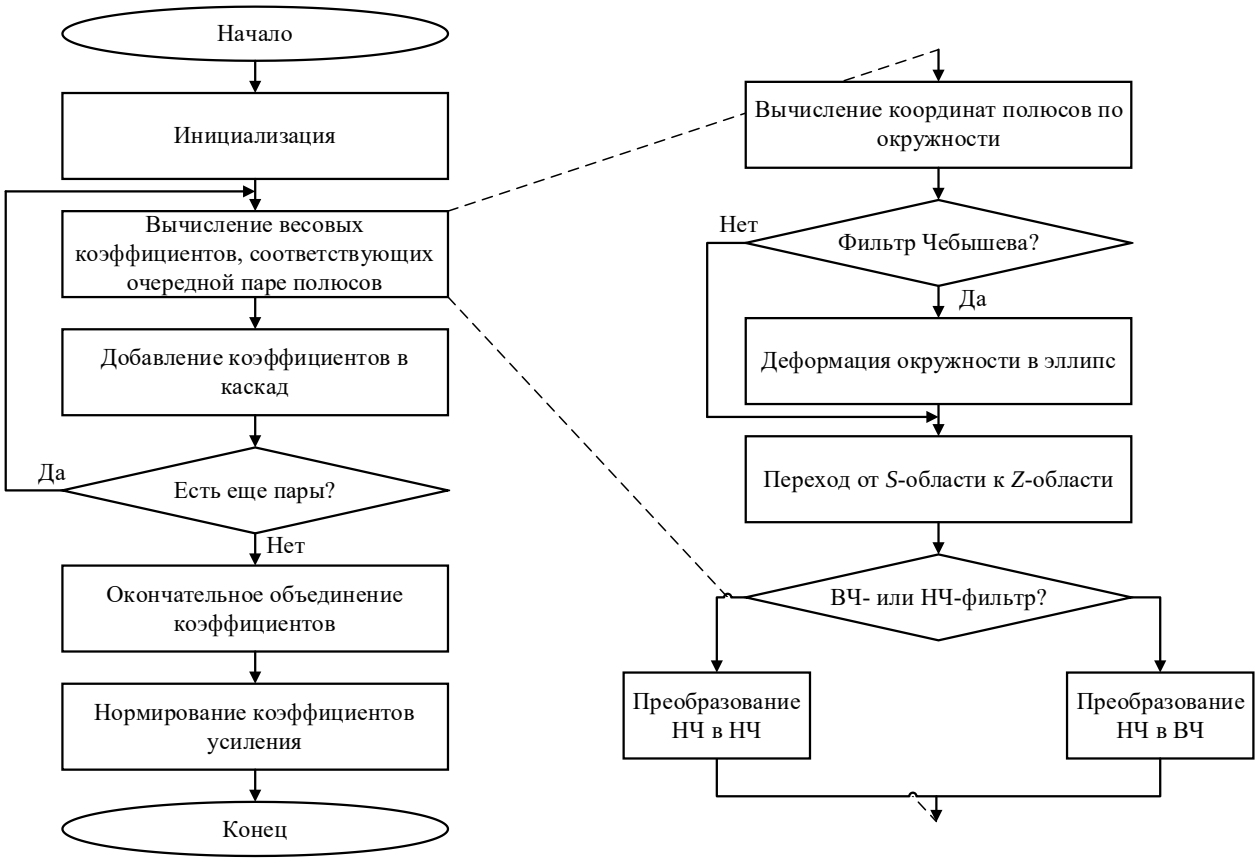

Рисунок 19 – Блок-схема метода Чебышева-Баттерворта

Шаг 2. Преобразовать окружность в эллипс, если проектируется фильтр Чебышева (параметр $P_R \neq 0$).

Для этого выполняется смещение координаты полюса с окружности на эллипс:

$$\sigma' = \sigma \cdot \frac{\sinh(v)}{k},$$

$$\omega' = \omega \cdot \frac{\cosh(v)}{k},$$

где коэффициенты v, k определяются по формулам:

$$v = \frac{\operatorname{arsh}(\frac{1}{\xi})}{N_P},$$

$$k = \cosh\left(\frac{1}{N_P}\operatorname{arch}\left(\frac{1}{\xi}\right)\right),$$

$$\xi = \sqrt{\left(\frac{100}{100 - P_R}\right)^2 - 1}.$$

Если используемая библиотека для вычисления гиперболического синуса или косинуса не поддерживает комплексные переменные, можно воспользоваться следующими формулами для преобразования:

$$\sinh(z) = \frac{e^z - e^{-z}}{2},$$

$$\cosh(z) = \frac{e^z + e^{-z}}{2},$$

$$\operatorname{arsh}(z) = \ln\left(\mathrm{z} + \sqrt{z^2 + 1}\right),$$

$$\operatorname{arch}(z) = \ln\left(\mathrm{z} + \sqrt{z^2 - 1}\right).$$

В результате выполнения шагов 1 и 2 формируется $N_P/2$ начальных координат полюса: (σ_0', ω_0'), (σ_1', ω_1'), …, $(\sigma_{N_P/2-1}', \omega_{N_P/2-1}')$.

Шаг 3. Преобразовать координаты из аналоговой S-области в дискретную Z-область с помощью билинейного преобразования.

При билинейном преобразовании выполняется переход от $H(s)$ к $H(z)$ в результате следующей замены:

$$s \to \frac{2(1 - z^{-1})}{T(1 + z^{-1})}, \tag{37}$$

где $T = 2\tan(0{,}5) \approx 1{,}093$.

Передаточная функция аналоговой системы с одной парой полюсов ($p_1 = \sigma + j\omega$ и $p_2 = \sigma - j\omega$) может быть записана в следующей форме:

$$H(s) = \frac{1}{(s - p_1)(s - p_2)}. \tag{38}$$

Тогда подставив выражение (37) получим передаточную функцию дискретной системы, содержащей два полюса:

$$H(z) = \frac{1}{\left(\frac{2(1-z^{-1})}{T(1+z^{-1})} - (\sigma + j\omega)\right)\left(\frac{2(1-z^{-1})}{T(1+z^{-1})} - (\sigma - j\omega)\right)}. \quad (39)$$

Применив ряд алгебраических преобразований, можно получить, что начальные коэффициенты для цифрового НЧ-фильтра с единичной частотой среза будут иметь вид:

$$a_0' = \frac{T^2}{D}, \qquad b_1' = \frac{8 - 2M \cdot T^2}{D},$$

$$a_1' = \frac{2T^2}{D}, \qquad b_2' = \frac{-4 - 4\sigma \cdot T - M \cdot T^2}{D}.$$

$$a_2' = \frac{T^2}{D},$$

где $M = \sigma^2 + \omega^2$, $D = 4 - 4\sigma \cdot T + M \cdot T^2$.

Шаг 4 Выполнить преобразование частоты среза к заданному значению и преобразование к заданному фильтру.

В общем случае, данная замена возможна, если известна передаточная функция рекурсивного НЧ-фильтра с единичной частотой среза. Тогда передаточную функцию НЧ-фильтра (ВЧ-фильтра) с частотой среза w можно получить путем замены z^{-1} следующим образом (по аналогии с билинейным преобразованием):

НЧ-фильтр с частотой среза $w = 0 \dots \pi$	ВЧ-фильтр с частотой среза $w = 0 \dots \pi$
$z^{-1} \to \frac{z^{-1} - k}{1 - kz^{-1}}$	$z^{-1} \to \frac{-z^{-1} - k}{1 + kz^{-1}}$
$k = \frac{\sin(1/2 - w/2)}{\sin(1/2 + w/2)}$	$k = -\frac{\cos(w/2 + 1/2)}{\cos(w/2 - 1/2)}$

Коэффициенты a_0, a_1, a_2, b_1, b_2 для текущего полюса определяются по формулам:

$$a_0 = \frac{a_0' - a_1'k + a_2'k^2}{D'}, \qquad a_2 = \frac{a_0'k^2 - a_1'k + a_2'}{D'},$$

$$a_1 = \frac{-2a_0'k + a_1' + a_1'k^2 - 2a_2'k}{D'}, \qquad b_1 = \frac{2k + b_1' + b_1'k^2 - 2b_2'k}{D'},$$

$$b_2 = \frac{-k^2 - b_1' K + b_2'}{D'},$$

где $D' = 1 + b_1' k - b_2' k^2$.

Кроме того, если проектируется ВЧ-фильтр, необходимо выполнить коррекцию коэффициентов: $a_1 = -a_1$ и $b_1 = -b_1$.

Шаг 5. Объединение Звеньев (Каскадная Реализация).

Общая передаточная функция $H(z)$ фильтра формируется как произведение передаточных функций $H_P(z)$ всех $N_P/2$ звеньев второго порядка:

$$H(z) = \frac{A_0}{1 + B_1 z^{-1} + B_2 z^{-2}} \cdot \frac{A_0' + A_1' z^{-1} + A_2' z^{-2}}{1 + B_1' z^{-1} + B_2' z^{-2}}$$

Шаг 5.1. Значения $TA[\cdot]$ и $TB[\cdot]$ инициализируются *текущими* значениями массивов $A[\cdot]$ и $B[\cdot]$ соответственно.

Шаг 5.2. Для всех элементов массива ($i = [2,22]$):

$$A[i] = A_0 \cdot TA[i] + A_1 \cdot TA[i-1] + A_2 \cdot TA[i-2],$$
$$B[i] = TB[i] - B_1 \cdot TB[i-1] - B_2 \cdot TB[i-2].$$

Шаги 2-5 выполняются для всех $N_P/2$ начальных координат полюса.

Шаг 6. Окончание объединения коэффициентов:

```
B[2] = 0;
for (i =0; i < 20; i++) {
        A[i] =  A[i+2];
        B[i] = -B[i+2];
}
```

Шаг 7. Вычислить нормирующий коэффициент усиления G по формуле:

$$\text{GAIN} = \frac{S_A}{1 - S_B},$$

где коэффициенты S_A и S_B определяются следующим образом:

$$S_A = \begin{cases} \sum_{i=0}^{20} a_i \cdot (-1)^i, & \text{если ВЧ-фильтр} \\ \sum_{i=0}^{20} a_i, & \text{если НЧ-фильтр} \end{cases}$$

$$S_B = \begin{cases} \sum_{i=0}^{20} b_i \cdot (-1)^i, & \text{если ВЧ-фильтр} \\ \sum_{i=0}^{20} b_i\,, & \text{если НЧ-фильтр} \end{cases}$$

Шаг 8. Нормировать коэффициенты a_i:

$$a_i = \frac{a_i}{\mathrm{GAIN}}.$$

Примечание. Для проверки корректности алгоритма рекомендуется сравнить полученные значения с представленными в таблицах 20.1, 20.2 и 20.4 в [4].

3. Задание

1. Ознакомьтесь с теоретической частью.

2. На основе лабораторной работы №1, реализовать однородный, КИХ и БИХ фильтр:

– параметры, необходимые для проектирования фильтра соответствующего типа, определяет преподаватель;

– рассчитать необходимые для реализации фильтра коэффициенты;

– изменить сигнал из лабораторной работы №1 так, чтобы экспериментально подтвердить правильность работы соответствующего фильтра

– построить графики входной функции, АЧХ спроектированных фильтров, графики сигнала после внесения искажений, графики по результатам работы однородного, КИХ и БИХ фильтров.

Примечание. В качестве входного сигнала по согласованию с преподавателем рекомендуется использовать музыкальный файл в формате WAV. В этом случае искаженный сигнал, результаты применения фильтров также рекомендуется сохранить в музыкальные файлы и оценить работу разработанных алгоритмов.

3. Оформить отчет с указанием исходных данных, расчётов необходимых для реализации фильтра коэффициентов, построенные графики, выводы о результатах работы.

4. Контрольные вопросы

1. В чем заключается принципиальное отличие между КИХ и БИХ фильтрами с точки зрения зависимости выходного сигнала от входных отсчетов?

2. Объясните физический смысл понятий «полоса пропускания» и «полоса подавления». Что происходит с сигналом в «полосе перехода»?

3. Как связаны импульсная характеристика фильтра и его частотная характеристика?

4. Какие типы фильтров выделяют по области применения, и в чем разница между фильтрами временной и частотной областей?

5. Зачем при проектировании КИХ-фильтра методом взвешивания используется оконная функция (например, окно Ханна или Хэмминга), а не просто обрезается идеальная импульсная характеристика?

6. Как выбор типа окна влияет на ширину полосы перехода и уровень подавления боковых лепестков? Приведите пример компромисса при выборе окна.

7. Почему идеальная импульсная характеристика фильтра нижних частот (функция $sinc$) не может быть реализована на практике без изменений?

8. В чем суть билинейного преобразования при проектировании цифровых фильтров? Из какой области в какую оно переводит координаты полюсов?

9. Что такое рекурсивный фильтр, и какие риски (например, устойчивость) связаны с наличием обратной связи, которых нет у нерекурсивных фильтров?

10. Объясните назначение параметра α в однополюсном рекурсивном фильтре. Как он влияет на «инерционность» фильтра?

11. В чем особенность фильтров Чебышева I типа по сравнению с фильтрами Баттерворта в контексте неравномерности АЧХ?

12. Что показывают амплитудно-частотная и фазо-частотная характеристики фильтра?

13. Как порядок фильтра (количество полюсов) влияет на крутизну спада АЧХ в переходной области?

14. Как интерпретировать понятие «частота среза» на графике АЧХ? На каком уровне (в дБ) она обычно определяется?

15. Для чего при реализации каскадного БИХ-фильтра применяется нормирующий коэффициент усиления?

ЛАБОРАТОРНАЯ РАБОТА №3
АЛГОРИТМЫ ОБРАБОТКИ АУДИОСИГНАЛА

1. Цель работы

Изучение теоретических основ и приобретение практических навыков цифровой обработки аудиосигналов, включающее реализацию алгоритмов частотно-временного анализа, извлечение информативных спектральных признаков, а также сравнительное исследование методов оценки качества звука (объективных и субъективных) применительно к задачам шумоподавления.

2. Теоретические сведения

Основы цифровой обработки аудиосигнала.

Аудиосигнал – это временной дискретный ряд $x[n]$, представляющий звук, оцифрованный с частотой дискретизации f Гц.

Основные этапы обработки аудиосигнала включают:

– предобработка (нормализация, фильтрация шума; может применяться как к аналоговому, так и цифровому сигналу);

– оконное преобразование (фрейминг) – разделение сигнала на фиксированные окна $x(m,n)$ длиной N с шагом H:

$$x(m,n) = x[n + mH] \cdot w[n], n = 0,1, \dots, N-1 \tag{40}$$

где $w[n]$ – некоторая оконная функция, обнуляющая сигнал за пределами анализируемого сегмента (примеры оконных функций были рассмотрены в лабораторной работе №2);

– к каждому окну $x(m,n)$ применяется преобразование Фурье для формирования спектра сигнала:

$$X(m,k) = \sum_{n=0}^{N-1} x(m,n) e^{-i\frac{2\pi}{N}kn} . \tag{41}$$

Последовательное применение формул (40) и (41) называется оконным преобразованием Фурье и позволяет получить информацию, какие частоты *в какой момент времени* присутствуют в сигнале.

Следует отметить, в некоторых задачах разбиение на кадры выполняется с перекрытием 50-75%. Шаг H подбирается исходя из предположения, что в течение короткого времени речевой сигнал является стационарным (как правило, 20-40 мс).

Базовые алгоритмы, используемые для анализа аудиосигнала.

Спектрограмма – это график, показывающий зависимость спектральной плотности мощности сигнала от времени и частоты:

$$S(\tau,\omega) = \left(X(\tau,\omega)\right)^2 \tag{42}$$

где $X(\tau,\omega)$ – оконное преобразование Фурье.

Следует отметить, что спектрограмма часто представляется в логарифмическом масштабе и измеряется в децибелах: $10log_{10}\left(S(\tau,\omega)\right)$.

По сути спектрограмма – это визуальный способ представления уровня или «громкости» сигнала во времени на различных частотах и отображается в виде тепловой карты, включающей три шкалы – зависимость времени от частоты и дополнительная шкала децибел, показывающая плотность мощности сигнала на определённой частоте в определённый промежуток времени. На рисунке 20 показан пример спектрограммы для музыкального файла Setuniman «Sweet Waltz», входящего в состав библиотеки LibROSA.

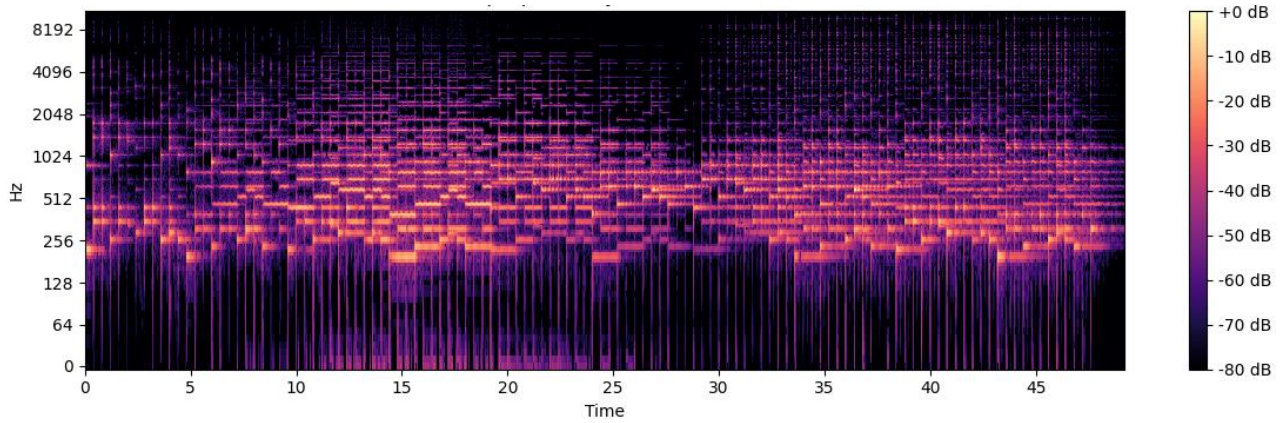

Рисунок 20 – Спектрограмма аудиофайла

Мел-шкала. *Высотой звука* называется частота его *основного тона*, то есть периодической составляющей с самой низкой частотой в сигнале. Однако несмотря на тесную связь высоты звука и частоты, они не являются эквивалентными.

Дело в том, что человеческое ухо воспринимают высоту звука нелинейно: на низких частотах разница в высоте звука ощущается более ясно, чем на высоких (например, если частота звука изменится со 100 Гц на 120 Гц, человек с высокой вероятностью заметит это изменение, однако изменение с 10000 Гц на 10020 Гц маловероятно).

В результате была введена новая единица измерения высоты звука – мел (сокращение от «мелодия»). Она основана на психофизиологическом восприятии звука человеком и логарифмически зависит от частоты (рисунок 21):

$$mel = 2595 \cdot \log_{10}\left(1 + \frac{freq}{700}\right) \tag{43}$$

Обратный переход от мелов к герцам выполняется по формуле:

$$freq = 700 \cdot \left(10^{\frac{mel}{2595}} - 1\right) \tag{44}$$

Обратите внимание, что разные библиотеки (LibROSA, Kaldi, HTK) могут использовать немного разные коэффициенты для перевода в мелы.

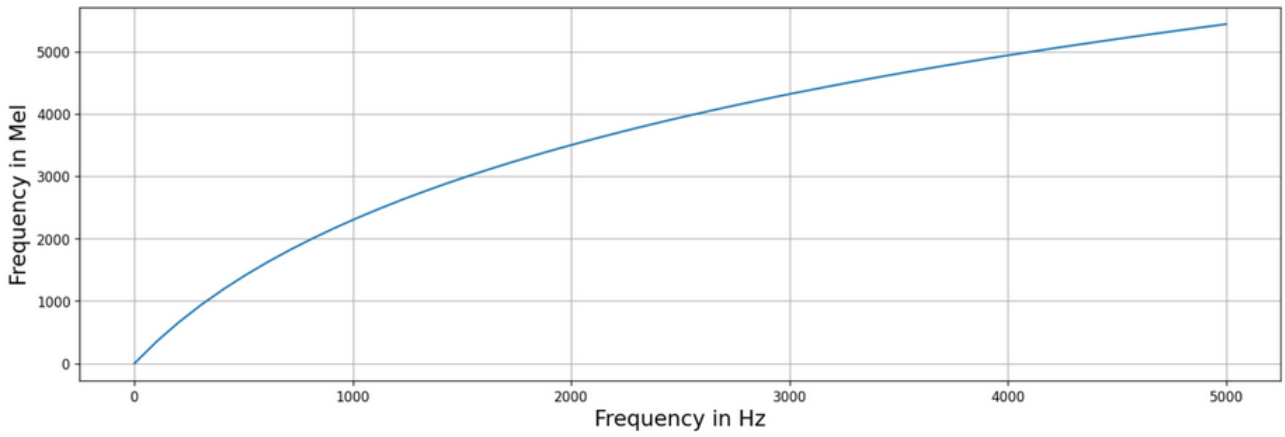

Рисунок 21 – График соотношения частоты в герцах к частоте в мелах

Мел-спектрограмма – это обычная спектрограмма, где частота выражена не в герцах, а в мелах. Следует отметить, именно этот тип спектрограмм часто используется в качестве входа для нейронных сетей.

Алгоритм вычисления мел-спектрограммы:

1. Построить спектрограмму $S(\tau, \omega)$ в соответствии с алгоритмом, представленным ранее.

2. Преобразовать частоту в мелы, применив к спектрограмме банк (набор) треугольных мел-фильтров $\Phi_m[k]$, равномерно распределенных по мел-шкале. Каждый фильтр Φ_m имеет центральную частоту $f_{\text{Мел},m}$:

$$M[i,m] = \sum_{k=0}^{N/2} S[i,k] \cdot \Phi_m[k]\,, \tag{45}$$

где $M[i,m]$ – энергия m-го мел-фильтра в i-м кадре.

3. Выполнить логарифмирование полученной шкалы:

$$\widetilde{M}[i,m] = \log(M[i,m])\,. \tag{46}$$

Для того, чтобы построить банк мел-фильтров $\Phi_m[k]$ необходимо:

1. Используя формулу (43), перевести максимальную и минимальную частоту сигнала в мелы.

2. Создать n равномерно расположенных точек (каждая точка – середина соответствующей мел-полосы).

3. Используя формулу (44), преобразовать соответствующее значение частоты каждой точки обратно в герцы и округлить до ближайшего отсчета частоты.

4. На полученных частотных полосах построить треугольные фильтры.

На рисунках 22 и 23 изображен пример из 10 мел-фильтров (отличия в оси X – частота в мелах и частота после преобразования в герцы).

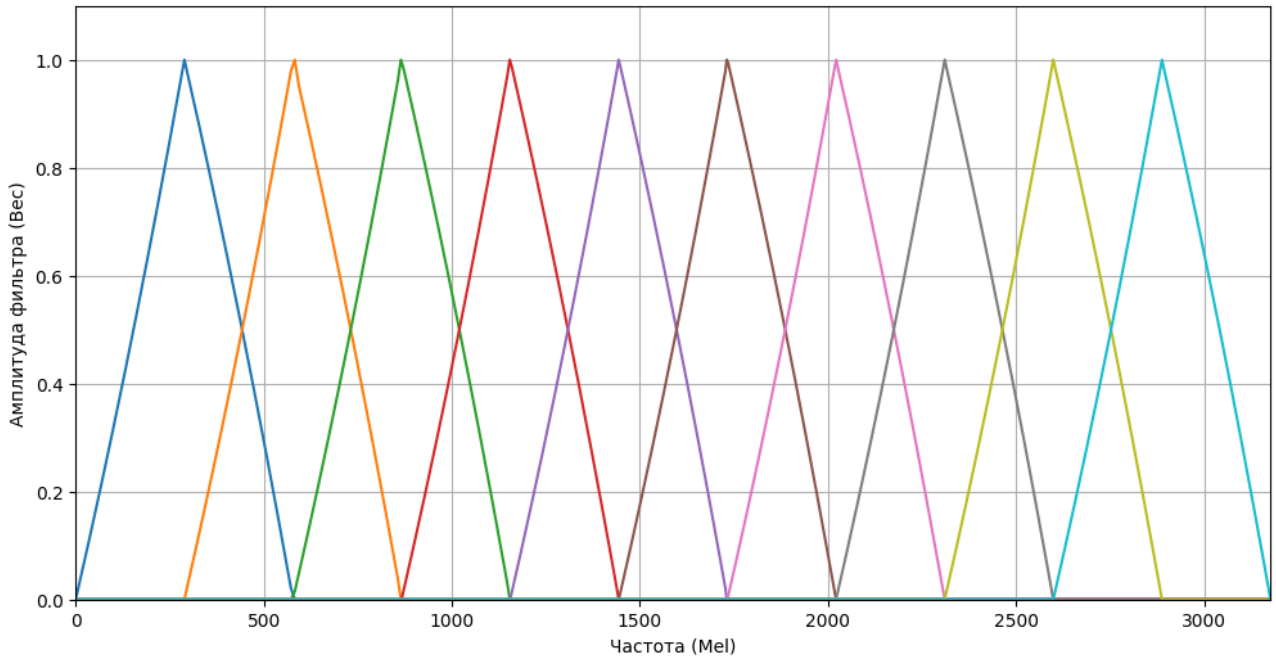

Рисунок 22 – Пример из 10 мел-фильтров

На рисунке 24 показан пример для музыкального файла Setuniman «Sweet Waltz» с банком, состоящим из 10 фильтров.

Спектральные признаки аудиосигнала.

Спектральные (частотные) *признаки* получаются путем преобразования временного сигнала в частотную область с помощью оконного преобразования Фурье и позволяют характеризовать любой аудиосигнал. К ним относятся:

– спектральный центроид;
– спектральный спад
– спектральная ширина;
– частота пересечения нуля;
– мел-частотные кепстральные коэффициенты;
– цветность и др.

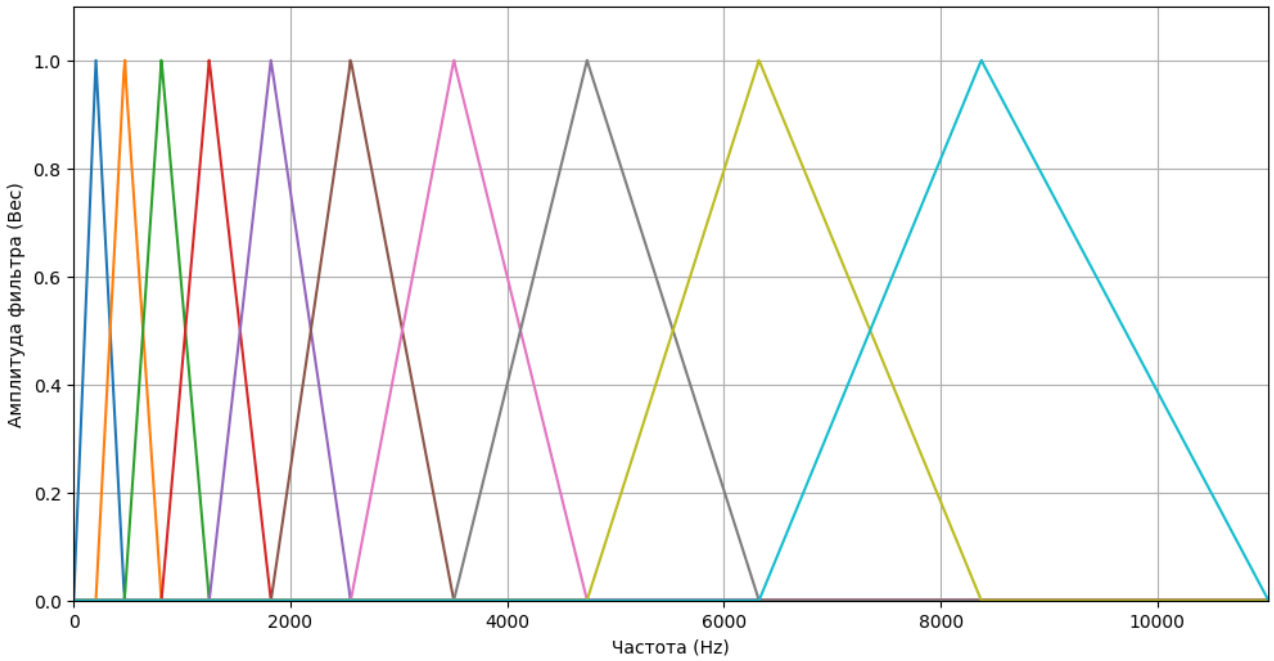

Рисунок 23 – Пример из 10 мел-фильтров после преобразования в частотную область

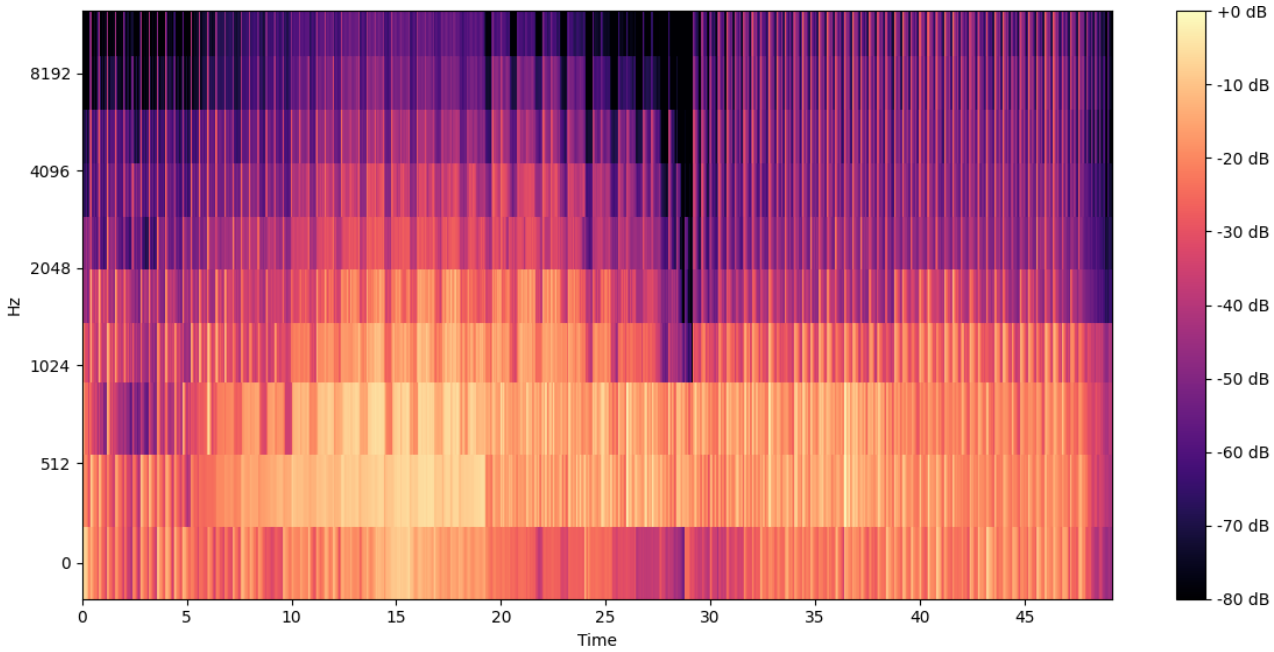

Рисунок 24 – Мел-спектрограмма с 10 фильтрами

1. Спектральный центроид (spectral centroid, SC) указывает, на какой частоте сосредоточена энергия спектра [6]:

$$SC = \frac{\sum_{k=0}^{M} S[k] f_k}{\sum_{k=0}^{M} S[k]},$$

где k – индекс частотного бина, полученного после выполнения преобразования Фурье; M – общее количество частотных бинов в рассматриваемом спектре (как правило, до частоты Найквиста); f_k – центральная частота в герцах для бина с индексом k; $S[k]$ – спектральная величина (амплитуда) для бина с индексом k (часто используется амплитудный спектр $|X(k)|$ или спектр мощности $|X(k)|^2$).

На практике высокое значение SC указывает на то, что большая асть энергии сосредоточена на высоких частотах, что характерно для ярких, звонких звуков (например, флейта, женский вокал). И наоборот, низкое значение характерно для тусклых, глубоких звуков (например, бас-гитара). На рисунке 25 показан пример спектрального центроида для музыкального файла Setuniman «Sweet Waltz».

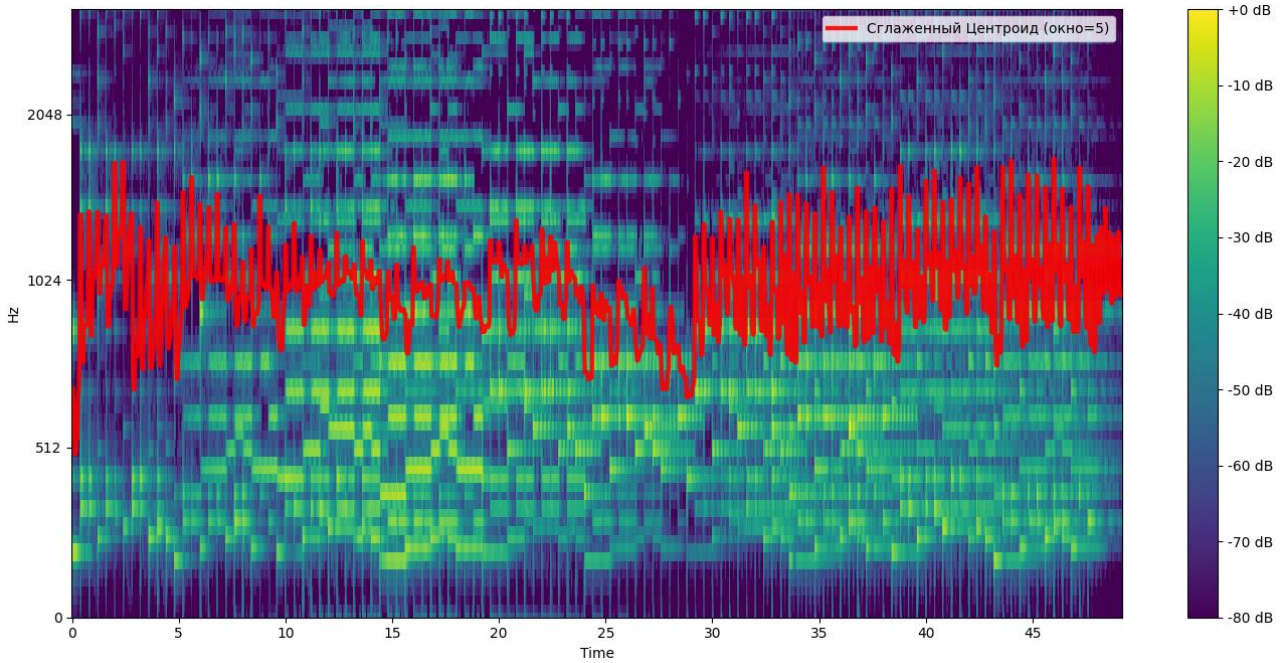

Рисунок 25 – Сглаженный спектральный центроид поверх мел-спектрограммы

2. Спектральный спад (spectral rolloff, SR) [7] – частота, ниже которой сосредоточено α (чаще всего рассматривается $\alpha = 85\%$ либо $\alpha = 90\%$) полной спектральной энергии. Соответственно, необходимо рассчитать долю элементов в спектре мощности, где $\alpha\%$ ее мощности находится на более низких частотах. Используется для определения «яркости» или наличия высокочастотных компонент.

В качестве результата выбирается такая точка $k_{rolloff}$, при которой выполняется условие:

$$\sum_{k=0}^{k_{rolloff}} S[k] = \alpha \sum_{k=0}^{N/2} S[k],$$

где f_{SR} – частота, соответствующая индексу $k_{rolloff}$.

Алгоритм вычисления сводится к следующей последовательности действий:

– вычисляется $\sum_{k=1}^{M} S_k$ – сумма энергии всех частотных бинов;

– рассчитывается пороговое значение энергии: к $\cdot \sum_{k=1}^{M} S_k$;

– энергия суммируется, начиная с самого низкочастотного бина ($k = 1$);

– индекс r – это первый бин, где накопленная сумма $\sum_{k=1}^{r} S_k$ становится больше или равна пороговому значению.

– частота, соответствующая бину r, является искомой частотой спектрального спада ($f_{\text{roll-off}}$).

На практике данный параметр показывает, где заканчивается основная часть энергии звука. Высокое значение параметра говорит о том, что больше энергии распределено по всему спектру, включая очень высокие частоты, что характерно для шума (например, бьющиеся тарелки, белый шум) и ярких, открытых звуков. Низкие значения параметра говорят о том, что высокочастотные компоненты быстро затухают, что характерно для тусклых, приглушенных звуков (например, бас, низкий гул), а также звуков после низкочастотной фильтрации. На рисунке 26 показан пример спектрального спада для музыкального файла Setuniman «Sweet Waltz».

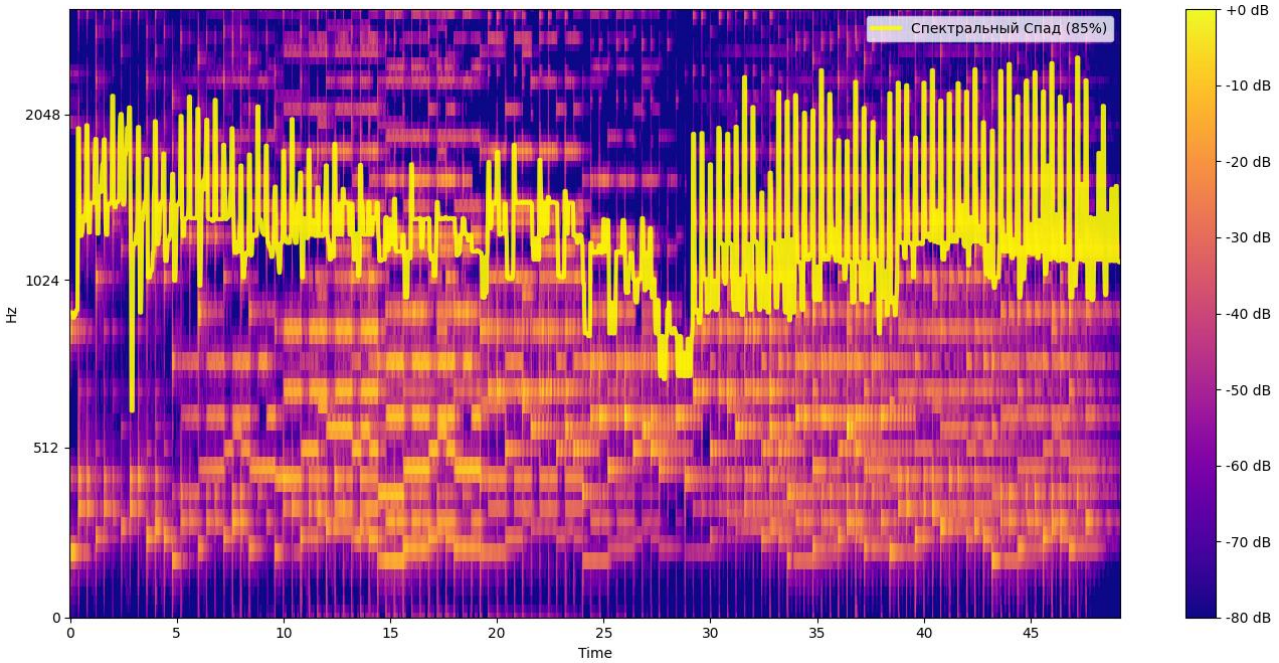

Рисунок 26 – Сглаженный спектральный спад поверх мел-спектрограммы

3. Спектральная ширина (spectral bandwidth, SB) – это взвешенное стандартное отклонение частот от спектрального центроида

:

$$SB = \sqrt{\frac{\sum_{k=0}^{M}(f_k - SC)^2 S[k]}{\sum_{k=0}^{M} S[k]}}.$$

На практике высокое значение спектральное ширины говорит о том, что спектр имеет много гармоник или шумовых компонентов, которые сильно удалены от среднего значения. Низкое значение говорит о том, что энергия сосредоточена в узком диапазоне частот, близко к центроиду, такой звук имеет чистый, простой тембр (например, синусоидальный тон, чистый свист, гласные звуки). На рисунке 27 показан пример спектральной ширины для музыкального файла Setuniman «Sweet Waltz».

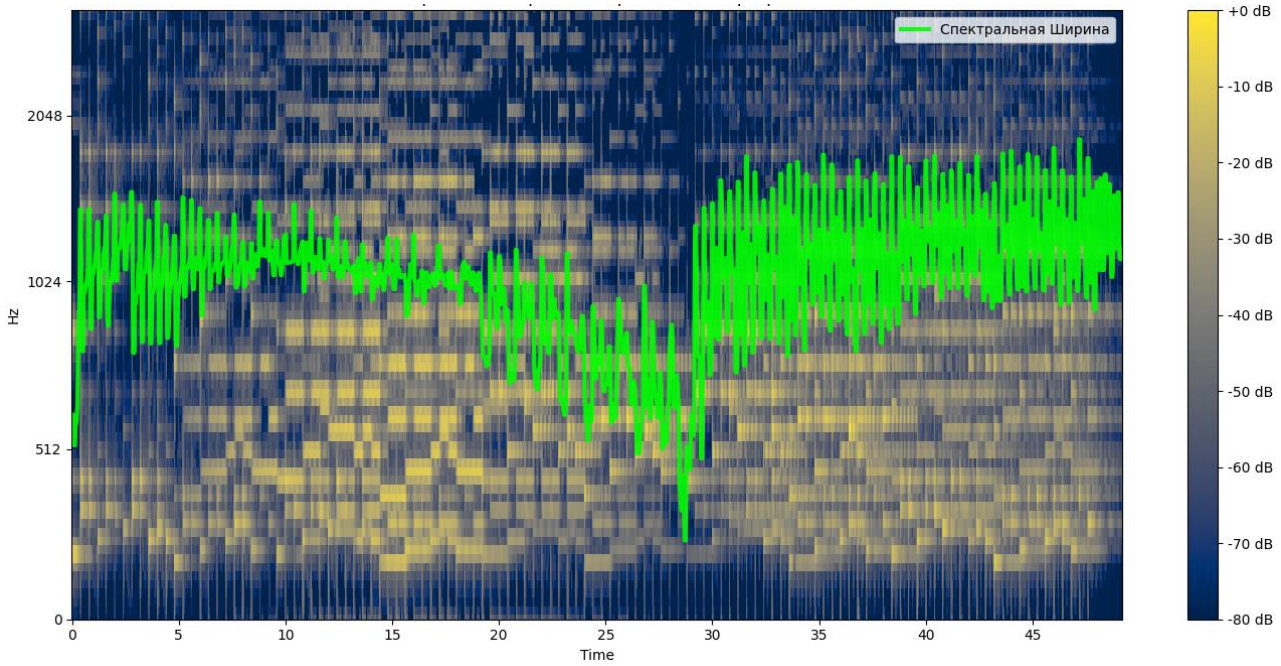

Рисунок 27 – Сглаженная спектральная ширина поверх мел-спектрограммы

4. Частота пересечения нуля (Zero Crossing Rate, ZCR) – это самый простой способ измерения гладкости сигнала – вычисление числа пересечений нуля в пределах сегмента этого сигнала:

$$ZCR = \frac{1}{N}\sum_{n=0}^{N-1} \mathrm{I}\{sign(x[n]) \,!= sign(x[n-1])\} < 0$$

где $sign(\cdot)$ – функция возврата знака числа, I{·} – индикаторная функция (равна 1, если условие истинно, и 0, если ложно).

На практике высокое значение ZCR характерно для шумных или высокочастотных сигналов (например, металл и рок), низкий ZCR – для тональных сигналов (например, речи). На рисунке 28 показан пример частоты пересечения нуля для музыкального файла Setuniman «Sweet Waltz».

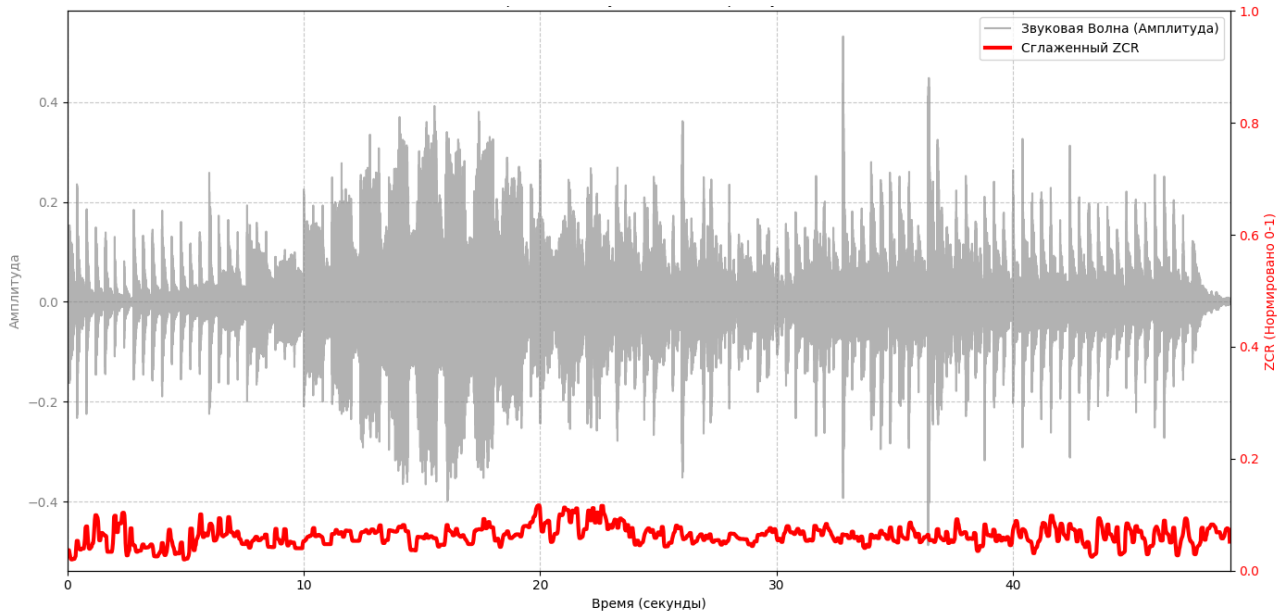

Рисунок 28 – График частоты пересечения нуля поверх звуковой волны

5. Мел-частотные кепстральные коэффициенты (MFCC).

Кепстр – это функция обратного преобразования Фурье от логарифма спектра мощности сигнала. По-сути кепстр является спектром от спектра сигнала.

Впервые термин «кепстр» (англ. cepstrum; анаграмма слова «спектр» – первые 4 буквы в нем расположены в обратном порядке, spectrum → cepstrum) был предложен в 1963 году в статье [8], в которой авторы заметили, что спектр имеет периодическую структуру, а значит, для его анализа можно использовать инструменты работы с периодическими сигналами – преобразование Фурье.

Алгоритм получения кепстра:

1. к дискретному сигналу $x[n]$ применить дискретное преобразование Фурье (следует отметить, для действительных сигналов используется оконное Фурье-преобразование, описанное ранее в лабораторной работе):

$$X(f) = \mathcal{F}\{x[n]\};$$

2. вычислить натуральный логарифм спектра мощности:

$$\ln\big(P(f)\big) = \ln\,(|X(f)|^2);$$

3. вычислить обратное преобразование Фурье от логарифма спектра мощности:

$$Cepstrum(\tau) = \mathcal{F}^{-1}\{\ln\big(P(f)\big)\},$$

где τ – кепстральное время (англ. quefrency, анаграмма от frequency).

Мел-частотные кепстральные коэффициенты (англ. Mel-Frequency Cepstral Coefficients, MFCC) [9] применяются для распознавания речи, для идентификации говорящего, классификации эмоциональной окраски и для множества других задач.

Алгоритм подсчета мел-кепстральных коэффициентов:

1. к сигналу $x[t]$ применить оконное дискретное преобразование Фурье и получить $X(m,k)$;

2. вычислить периодограмму для каждого кадра:

$$P(j,k) = \frac{|X(j,k)|^2}{N},$$

где j – номер кадра, N – число дискретных отсчетов.

3. вычислить блок мел-фильтров $\Phi_m[k]$;

4. полученные энергии логарифмировать:

$$S(j,k) = \ln\left(\sum_{k=0}^{M-1} P(j,k)\cdot\Phi_j[k]\right), 0 \le k < N,$$

где M – число мел-фильтров, N – количество извлекаемых мел-частотных кепстральных коэффициентов.

5. к мел-спектру применить дискретное косинусное преобразование:

$$c(j,n) = \sum_{m=0}^{M-1} S(j,m)\cos\,(\frac{\pi n(m+\frac{1}{2})}{M}), 0 \le n < M.$$

На рисунке 29 показан пример полученных мел-частотных кепстральных коэффициентов для музыкального файла Setuniman «Sweet Waltz». На рисунке ось X показывает, как коэффициенты изменяются с течением времени (то есть, как меняется тембр звука), ось Y представляет собой сжатые характеристики спектра:

– коэффициент C_1 представляет общую энергию или громкость в кадре. Часто исключается из анализа или используется отдельно;

– коэффициенты C_2-C_{13} описывают форму огибающей спектра (медленно меняющиеся компоненты спектра), которые фиксируют, как энергия распределена по различным мел-полосам, что тесно связано с тембром звука;

– коэффициенты выше C_{13} (при наличии) описывают мелкомасштабные детали в спектре (например, гармонические пики), которые часто менее важны для восприятия тембра и речи, и поэтому обычно отбрасываются.

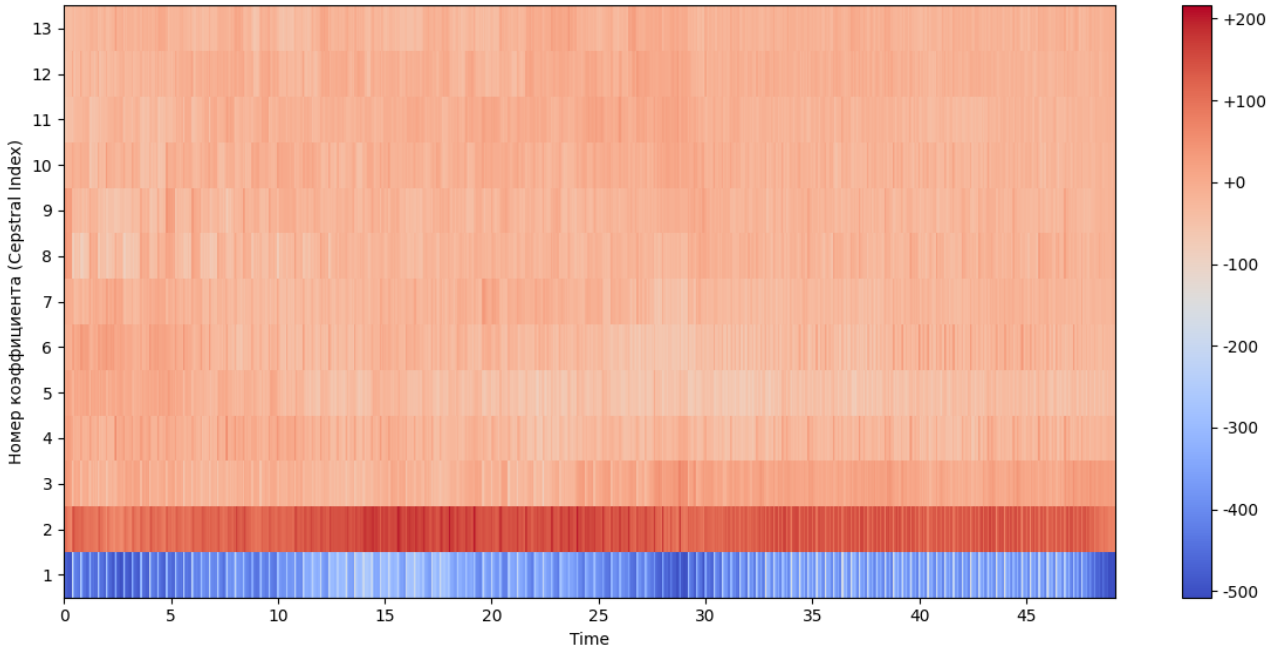

Рисунок 29 – Спектрограмма с использованием 13 мел-частотных кепстральных коэффициентов

6. Цветность (Chroma) или Хрома-вектор (Chroma Feature).

Цветность показывает распределение энергии сигнала по 12 музыкальным нотам (до (C), до-диез (C#), ре (D), ре-диез (D#), ми (E), фа (F), фа-диез (F#), соль (G), соль-диез (G#), ля (A), ля-диез (A#), си (B)) независимо от того, в какой октаве они звучат. Таким образом, данный параметр фокусируется исключительно на гармоническом содержании и игнорирует тембр и октаву. На практике часто используется для описания меры сходства между музыкальными произведениями, а также для автоматической транскрипции аккордов и обнаружения структуры музыкального произведения.

На рисунке 30 показан пример вычисления цветности для музыкального файла Setuniman «Sweet Waltz». На рисунке ось X показывает, как гармоническое содержание меняется с течением времени, ось Y отражает 12 полутонов хроматической гаммы. Интенсивность цвета показывает, насколько сильна энергия сигнала на данной ноте в данный момент времени.

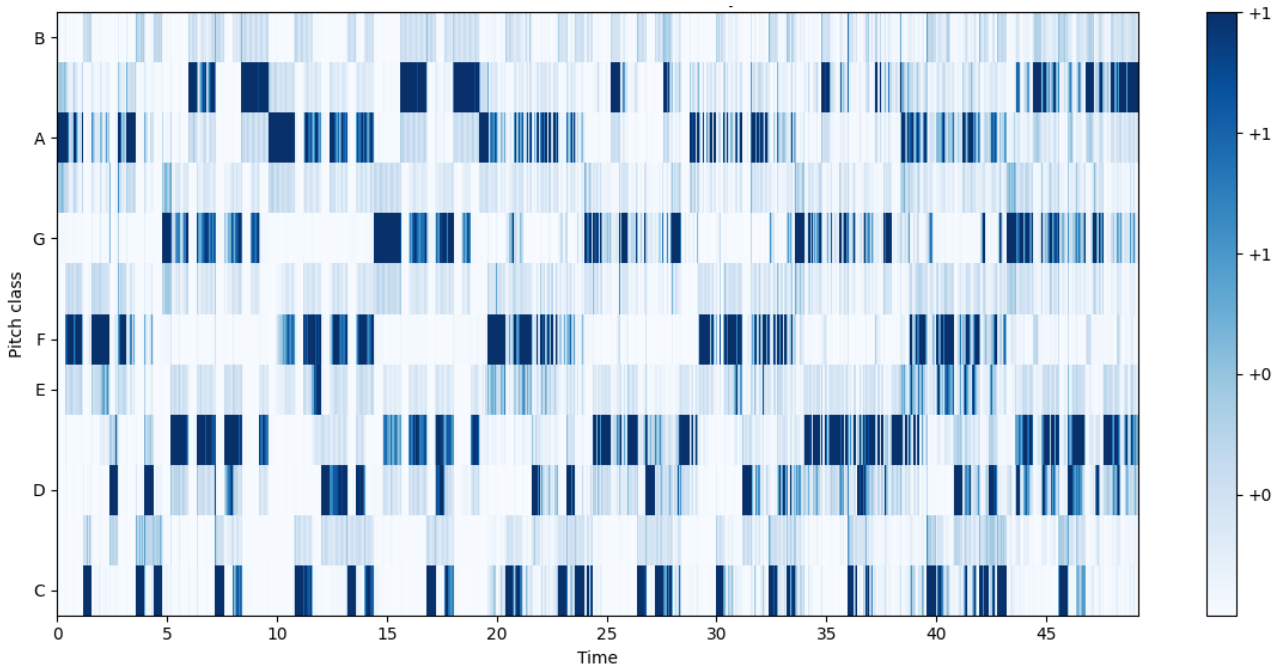

Рисунок 30 – Цветность аудиосигнала

Способы оценки качества звука (метрики).

Для оценки качества звука при его обработке используется два подхода:

– субъективная оценка, когда оценкой занимается человек-эксперт;

– объективная оценка.

Объективные методы оценки качества звука.

Объективные методы оценки качества звука можно разделить на две большие группы:

– метрики, основанные на искажениях (англ. Signal Distortion):

  – отношение сигнал/шум;

  – сегментное отношения сигнал/шум;

  – отношение сигнал/искажение;

  – масштабно-инвариантное отношение сигнал/искажение;

– метрики, основанные на перцептивной модели (англ. Perceptual Quality):

  – оценка спектрального расстояния, основанная на кодировании с линейным предсказанием;

  – искажение Барк-спектра;

  – объективная разборчивость в коротких кадрах;

  – перцептивная оценка качества речи;

– метрики на основе машинного обучения:

  – неинтрузивная оценка качества речи;

  – MOS-оценка подавления шума.

В общем случае, для объективных методов оценки качества звука предполагается, что сигнал $\hat{s}$ состоит из четырех отдельных компонентов:

$$\hat{s} = s_{target} + s_{interf} + s_{noise} + s_{artif} \quad (47)$$

где s_{target} – чистый (исходный) сигнал, s_{interf}, s_{noise} и s_{artif} – ошибки, связанные с помехами, шумом и добавленными артефактами соответственно (в децибелах). Поскольку фактические расчеты отдельных компонентов довольно сложны, в рамках лабораторной работы рассматривается их упрощенная версия – $\hat{s} = s_{target} + s_{noise}$, где s_{noise} включает в себя все искажения, независимо от их происхождения. Для точного расчета всех компонентов рекомендуется обратиться к статье [10].

Отношение сигнал/шум (англ. Signal-Noise Ratio, SNR) измеряет среднюю мощность полезного сигнала относительно средней мощности шума. Используется в различных системах передачи данных, в которых шум s_{noise} аддитивен:

$$SNR = 10 \cdot log_{10}\left(\frac{\left\|s_{target}\right\|^2}{\left\|s_{target} - \hat{s}\right\|^2}\right). \quad (48)$$

Сегментное отношения сигнал/шум во временной и в частотной областях. Отношение сигнал/шум можно оценить как во временной, так и в частотной области. Измерение во временной области является одним из простейших объективных показателей, используемых для оценки алгоритмов улучшения или кодирования речи. Для того, чтобы это измерение было значимым, важно, чтобы исходный и обработанный сигналы были выровнены во времени, а любые фазовые ошибки были исправлены. На практике, лучше коррелирует с человеческим восприятием, чем SNR, т.к. учитывает временную модуляцию шума.

Сегментное отношение сигнал/шум во временной области (SNR_{seg}) определяется как:

$$SNR_{seg} = \frac{1}{M}\sum_{m=0}^{M} SNR_m = \frac{10}{M}\sum_{i=0}^{K-1} log_{10}\frac{\sum_{n=N_i}^{N_{i+1}-1} s_{target}^2[n]}{\sum_{n=N_i}^{N_{i+1}-1}(\hat{s}[n] - s[n])^2}, \quad (49)$$

где N – число дискретных отсчетов (как правило выбирается 15–20 мс), K – количество сегментов.

Одна из проблем, связанных с этим методом во временной области, заключается в том, что энергия сигнала в интервалах тишины в речевом сигнале (которых много в разговорной речи) будет очень мала, что приведет к большим отрицательным значениям SNR, которые сместят общий показатель.

Сегментное отношение сигнал/шум в частотной области ($fwSNRseg$) определяется как [11]:

$$fwSNRseg = \frac{10}{M}\sum_{m=0}^{M-1}\frac{\sum_{j=1}^{K} B_j log_{10}\left[\frac{F^2(m,j)}{\left(F(m,j)-\hat{F}(m,j)\right)^2}\right]}{\sum_{j=1}^{K} B_j} \quad (50)$$

где B_j – вес, придаваемый j-й полосе частот, K – количество полос, M – общее количество кадров в сигнале, $F(m,j)$ – амплитуда банка фильтров (спектр возбуждения) чистого сигнала в j-й полосе частот в m-м кадре, а $\hat{F}(m,j)$ – амплитуда банка фильтров улучшенного сигнала в той же полосе. Основное преимущество использования сегментного SNR на основе частоты по сравнению с $SNRseg$ во временной области заключается в дополнительной гибкости в установке различных весов для различных частотных полос спектра.

Отношение сигнал/искажение (англ. Signal to Distortion Ratio, SDR) используется для количественной оценки качества сигнала по сравнению с его искаженной или зашумленной версией:

$$SDR = 10log_{10}\left(\frac{E_S}{E_d}\right) = 10log_{10}\left(\frac{\sum_{n=0}^{N-1}|s[n]|^2}{\sum_{n=0}^{N-1}|\hat{s}[n]-s[n]|^2}\right) \quad (51)$$

где E_S – энергия исходного или опорного сигнала, E_d – энергия искажения или шума в ухудшенном сигнале.

Данная метрика широко используется в различных областях, включая обработку звука, телекоммуникации и анализ сигналов, для оценки влияния искажений или шума на исходный сигнал. SDR выражается в децибелах (дБ) и показывает, насколько громче исходный сигнал по сравнению с искажением или шумом, присутствующим в ухудшенной версии.

Масштабно-инвариантное SDR (англ. Scale-Invariant Signal to Distortion Ratio, SI-SDR) [12] определяет отношение энергии чистого опорного сигнала к энергии искажений, внесённых в процессе разделения, при этом оставаясь инвариантным к масштабу как чистого, так и искажённого сигнала:

$$\text{SI-SDR} = 10log_{10}\left(\frac{\left\|s_{target}\right\|^2}{\|s_{noise}\|^2}\right) = 10log_{10}\left(\frac{\sum_{n=0}^{N-1}|\alpha s_{target}[n]|^2}{\sum_{n=0}^{N-1}|\hat{s}[n]-\alpha s_{target}[n]|^2}\right) \quad (52)$$

где $\|\cdot\|^2$ – энергия (квадрат нормы) соответствующего вектора, $\alpha = \frac{\langle \hat{s}, s_{target}\rangle}{\left\|s_{target}\right\|^2} = \frac{\sum_{n=0}^{N-1}(\hat{s}[n]s_{target}[n])}{\sum_{n=0}^{N-1}(s_{target}[n])^2}$, $\langle \hat{s}, s_{target}\rangle$ –скалярное произведение векторов.

На практике значение SI-SDR показывает, насколько хорошо разделённый сигнал соответствует опорному, исключая любые различия в масштабировании между двумя сигналами. Более высокие положительные значения SI-SDR соответствуют лучшему качеству разделения.

Основными преимуществами метрик, представленных выше, является их простота и легкость для программной реализации. Однако они не учитывают особенности человеческого слуха и, соответственно, того, как человек воспринимает звук:

– нелинейность восприятия (например, громкий звук на одной частоте может скрывать тихий на другой);

– неравномерность частотной чувствительности.

Метрики, основанные на перцептивной модели, исправляют данный недостаток.

Оценка спектрального расстояния, основанная на кодировании с линейным предсказанием (LPC), – это метод объективного сравнения двух спектров речевых сигналов, фокусирующийся на различиях в огибающих спектра мощности (англ. spectral envelope), которые моделируются с помощью LPC-фильтров.

Суть метода заключается в моделировании речевого сигнала, в котором текущий дискретный отсчет определяется как линейная комбинация предыдущих p отсчетов:

$$\hat{s}[n] = \sum_{k=1}^{p} a_k s[n-k]\,,$$

где $s[n]$ – исходный сигнал, $\hat{s}[n]$ – предсказанный отсчет, a_k – коэффициенты линейного предсказания (LPC-коэффициенты), p – порядок предсказания.

Для оценки порядка предсказания p можно воспользоваться эмпирическим правилом:

$$p \approx \frac{f_s}{1000} + 4,$$

где f_s – частота дискретизации в Гц.

Для вычисления LPC-коэффициентов a_k можно воспользоваться следующим алгоритмом:

– для текущего кадра $s[n]$ вычислить значения функции автокорреляции $R[k]$:

$$R[k] = \sum_{n=0}^{N-1-k} s[n]s[n+k]\,,$$

где $k = \overline{0, p-1}$, N – длина кадра.

– построить систему уравнений, которую необходимо решить для нахождения LPC-коэффициентов a:

$$\sum_{k=0}^{p-1} a_k R[|i-k|] = R[i],\ i = \overline{0, p-1}.$$

В матричной форме система уравнений выглядит следующим образом:

$$\begin{pmatrix} R[0] & R[1] & \dots & R[p-1] \\ R[1] & R[0] & \dots & R[p-2] \\ \vdots & \vdots & \ddots & \vdots \\ R[p-1] & R[p-2] & \dots & R[0] \end{pmatrix} \begin{pmatrix} a_1 \\ a_2 \\ \vdots \\ a_p \end{pmatrix} = \begin{pmatrix} R[1] \\ R[2] \\ \vdots \\ R[p] \end{pmatrix}.$$

Поскольку матрица автокорреляций R является матрицей Тёплица (англ. Toeplitz matrix), т.е. симметричная матрица, в которой все элементы на главной и параллельных ей диагоналях равны, для ее решения можно воспользоваться одним из подходов:

– алгоритм Левинсона-Дурбина;

– ковариационный методом.

После того, как LPC-коэффициенты a_k для эталонного и искаженного сигналов были вычислены, определяют фильтры, которые моделируют огибающую спектра мощности речевого сигнала, и передаточная функция $H(z)$ которых имеет вид:

$$H(z) = \frac{G}{1 - \sum_{k=1}^{p} a_k z^{-k}},$$

где G – коэффициент усиления.

Затем для оценки спектрального расстояния может использоваться одна из следующих метрик:

– логарифмическое спектральное расстояние (англ. Log Spectral Distance, LSD), которое измеряет среднеквадратическое отклонение двух спектральных огибающих m-го кадра в логарифмическом масштабе:

$$D_{\mathrm{LSD}}(m) = \sqrt{\frac{1}{F} \sum_{f=1}^{F} \left[10 \cdot \log_{10} \left|H_{\mathrm{ref}}\left(e^{j\omega_f}\right)\right|^2 - 10 \cdot \log_{10} \left|H_{\mathrm{test}}\left(e^{j\omega_f}\right)\right|^2\right]^2},$$

где $H_{\mathrm{ref}}\left(e^{j\omega_f}\right)$ и $H_{\mathrm{test}}\left(e^{j\omega_f}\right)$ – спектр мощности LPC-фильтра для эталонного и искаженного сигналов соответственно, вычисленные на частоте ω_f, F – количество точек для вычисления спектра;

– расстояние по линейным спектральным парам (англ. Line Spectral Pairs, LSP), являющееся среднеквадратическим отклонением частот LSP-коэффициентов:

$$D_{\mathrm{LSP}}(m) = \sqrt{\sum_{k=1}^{p} \left(\omega_{k,\mathrm{ref}} - \omega_{k,\mathrm{test}}\right)^2},$$

где $\omega_{k,\mathrm{ref}}$ и $\omega_{k,\mathrm{test}}$ – частоты k-й линейной спектральной пары для эталонного и искаженного сигналов.

– расстояние Итакуры-Сайто (англ. Itakura-Saito, IS), определяющее насколько хорошо один спектр аппроксимирует другой:

$$D_{\mathrm{IS}}(m) = \frac{1}{2\pi}\int_{-\pi}^{\pi}\left[\frac{\left|H_{\mathrm{test}}\left(e^{j\omega}\right)\right|^2}{|H_{\mathrm{ref}}(e^{j\omega})|^2} - \log\frac{\left|H_{\mathrm{test}}\left(e^{j\omega}\right)\right|^2}{|H_{\mathrm{ref}}(e^{j\omega})|^2} - 1\right] d\omega\,.$$

Поскольку все вышеперечисленные метрики вычисляются на каждом кадре m, для получения единой оценки качества необходимо провести объединение по времени:

$$D_{\mathrm{RMS}} = \sqrt{\frac{1}{M}\sum_{m=1}^{M} D(m)^2},$$

где M – общее число кадров.

Искажение Барк-спектра (англ. Bark Distortion, BSD) является одной из самых простых метрик для сравнения двух сигналов.

Шаг 1. Преобразовать частоты в шкалу Барка по формуле:

$$z = 13\arctan(0.00076f) + 3.5\arctan\left(\left(\frac{f}{7500}\right)^2\right),$$

где z – частота в Барках, f – частота в герцах, полученная после оконного Фурье-преобразования.

Шаг 2. Линейный частотный спектр $P_j(k)$ в кадре j сгруппировать в ограниченное число критических полос шкалы Барка (как правило, $K = 24$).

Для этого, используя формулу преобразования частоты в Барки, определить частотные границы $f_{i,\mathrm{low}}$ и $f_{i,\mathrm{high}}$ для каждой из K полос. Затем необходимо просуммировать спектральную мощность всех частотных компонент, которые попадают в границы i-й полосы:

$$E_j(i) = \sum_{k \in \text{Band } i} P_j(k)\,,$$

где $E_j(i)$ – суммарная энергия (мощность) в i-й критической полосе для кадра j.

Шаг 3. Для каждого Барк-спектра мощности $E_j(i)$, состоящего из K значений для каждого кадра, выполнить переход в логарифмический масштаб:

$$L_{\text{dB},j}(i) = 10\log_{10}\left(\frac{E_j(i)}{E_{\text{ref,min}}}\right),$$

где $E_{\text{ref,min}}$ – эталонное значение, соответствующее порогу слышимости.

Шаг 4. Скорректировать уровень $L_{\text{dB},j}(i)$ с помощью кривых равной громкости (изофон) или порога абсолютной слышимости и, при необходимости, преобразовать в шкалу громкости, измеряемую в Сон. В результате формируются Барк-спектр громкости $L_{\text{ref},j}(i)$ и $L_{\text{deg},j}(i)$.

Шаг 5. Вычислить искажение Барк-спектра:

$$\text{BSD} = \frac{1}{N}\sum_{j=1}^{N}\left[\frac{1}{K}\sum_{i=1}^{K}\left(L_{\text{ref},j}(i) - L_{\text{deg},j}(i)\right)^2\right].$$

Объективная разборчивость в коротких кадрах (англ. Short Time Objective Intelligibility, STOI) [13] оценивает разборчивость речи, анализируя сходство между чистым сигналом и его искаженной версией в логарифмическом мел-спектральном домене по коротким временным сегментам.

Далее приводится обобщенный алгоритм получения данной метрики:

Шаг 1. Предварительная обработка эталонного $x_{\text{ref}}(t)$ и искаженного $x_{\text{deg}}(t)$ сигналов.

Шаг 1.1. Оба сигнала пропустить через банк J полосовых фильтров, имитирующих частотное разрешение человеческого слуха, в результате чего формируются сигналы $x_{\text{ref},j}(t)$ и $x_{\text{deg},j}(t)$, где $j = 1, \dots, J$ – номер частотной полосы.

Шаг 1.2. Сигналы в каждой полосе j разделить на короткие, перекрывающиеся кадры $x_{\text{ref},j,m}(n)$ и $x_{\text{deg},j,m}(n)$. При этом длина кадра L выбирается равным 30–40 мс, перекрытие R составляет $L/2$. В результате формируется M кадров для каждой полосы.

Шаг 2. Для каждого кадра m и каждой полосы j рассчитать спектральную огибающую.

Шаг 2.1. Для каждого кадра m в полосе j вычислить модуль Фурье-преобразования (или огибающую мощности) $\mathbf{X}_{\text{rf}\mathbf{j},\mathbf{m}}$ и $\mathbf{X}_{\text{dg}\mathbf{j},\mathbf{m}}$:

$$X_{j,m} = \left|\text{FFT}\left(x_{j,m}\right)\right|.$$

Шаг 2.2. Пороговая Обработка. Для этого спектральная огибающая искаженного сигнала $\mathbf{X}_{\mathrm{dg}\mathbf{j},\mathbf{m}}$ ограничивается, чтобы избежать чрезмерного усиления неречевых артефактов, что может улучшить корреляцию с разборчивостью:

$$X'_{\mathrm{dg}j,m} = \min\left(X_{\mathrm{dg}j,m}, \mathrm{CLIP}_{\mathrm{val}}\right),$$

где $\mathrm{CLIP}_{\mathrm{val}}$ – пороговое значение, основанное на энергии эталонного кадра.

Шаг 2.3. Для лучшего сравнения огибающих (независимо от абсолютного уровня громкости), нормализовать спектральные огибающие:

$$\hat{X}_{j,m} = \frac{X_{j,m} - \mu_{X_{j,m}}}{\sigma_{X_{j,m}}},$$

где μ и σ – среднее значение и стандартное отклонение огибающей кадра $X_{j,m}$, соответственно.

Шаг 3. Вычислить STOI-коэффициент.

Шаг 3.1. Для каждого кадра m и полосы j вычислить коэффициент разборчивости $d_{j,m}$ как взвешенную корреляцию между нормализованными огибающими, т.е. коэффициент, который определяет, насколько хорошо модуляция огибающей искаженного сигнала совпадает с эталонной в данном кадре и полосе:

$$d_{j,m} = \frac{\left(\hat{X}_{\mathrm{ref},j,m}\right)^{\top} \hat{X}'_{\mathrm{deg},j,m}}{|\hat{X}_{\mathrm{ref},j,m}|_2 |\hat{\mathbf{X}}'_{\mathrm{deg},j,m}|_2},$$

где $\hat{X}_{\mathrm{ref}}$ и $\hat{X}'_{\mathrm{deg}}$ – нормализованные спектральные огибающие эталонного и искаженного сигналов, $\top$ – скалярное произведение (корреляция), $|\cdot|_2$ – евклидова норма (длина вектора).

Шаг 3.2. Вычислить среднее арифметическое всех коэффициентов разборчивости по всем полосам J и всем кадрам M:

$$\mathrm{STOI} = \frac{1}{J \cdot M} \sum_{j=1}^{J} \sum_{m=1}^{M} d_{j,m}\,.$$

Диапазон допустимых значений для данной метрики – от 0 до 1, где 1 показывает, что ухудшенный сигнал идентичен эталонному, а 0 – ухудшенный сигнал совершенно непонятен.

Перцептивная оценка качества речи (англ. Perceptual Evaluation of Speech Quality, PESQ) [14] является одной из самых сложных метрикой объективной оценки качества речи, которая, кроме того, использовалась в ITU-T P.862 для оценки речевых кодеков, систем передачи речи и алгоритмов обработки.

Полная схема получения метрики PESQ показана на рисунке 31. Поскольку метод является запатентованным, приводится лишь общее его описание.

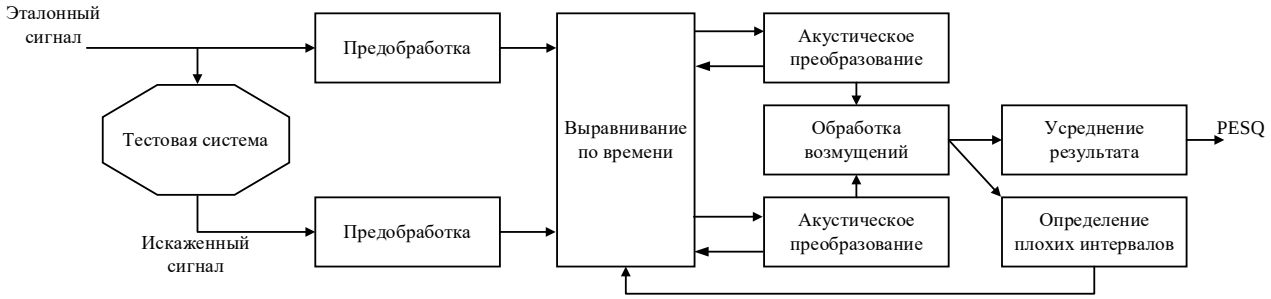

Рисунок 31 – Блок-диаграмма вычисления метрики PESQ

Шаг 1. Предварительная обработка и выравнивание.

На этом шаге эталонный $x(t)$ и искаженный $y(t)$ сигналы, пропускаются через полосовой фильтр, имитирующий телефонный канал (как правило, 300-3400 Гц), и нормируются по уровню.

Затем поскольку искаженный сигнал может иметь задержку по отношению к эталонному, алгоритм должен оценить и компенсировать ее.

Результатом работы шага 1 являются выровненные сигналы $x'(t)$ и $y'(t)$.

Шаг 2. Акустическое преобразование, которое моделирует реакцию человеческого уха на звук.

Для этого в начале к сигналу применяется оконное Фурье-преобразование.

Затем энергия сигнала преобразуется из линейной частотной шкалы в психоакустическую шкалу Барк, которая лучше соответствует тому, как человеческое ухо воспринимает частоту. Для этого для каждого кадра m и Барк-полосы k:

$$B_x(m,k) \propto \sum_f P_x(m,f) \cdot W(k,f),$$

где $P_x(m,f)$ – спектральная плотность мощности эталонного сигнала, $W(k,f)$ — весовая функция, представляющая Барк-полосу k.

После этого Барк-спектр преобразуется в шкалу громкости, выраженную в единицах Звон (англ. Sone), с использованием закона Цвикера (англ. Zwicker's law) для учета нелинейного восприятия интенсивности звука. Громкость в Барк-полосе $L(m,k)$ определяется по формуле:

$$L(m,k) = \frac{1}{\mathrm{Sl}}\left[\left(0.5 + 0.5 \cdot \frac{E(m,k)}{E_0(k)}\right)^{\gamma} - 1\right],$$

где $E_0(k)$ – опорная интенсивность, Sl – коэффициент масштабирования, $\gamma \approx 0.23$ (для телефонного диапазона), $E(m,k) = B_x(m,k) + T(k)$ – интенсивность в Барк-полосе, $T(k)$ – порог слышимости.

В результате формируются карты громкости $L_x(m,k)$ и $L_y(m,k)$ для эталонного и искаженного сигналов соответственно.

Шаг 3. Расчет возмущений, на котором сравниваются карты громкости для эталонного и искаженного сигналов.

На этом шаге вначале вычисляется симметричное возмущение, представляющее собой абсолютную разницу в громкости, ограниченную порогом, который учитывает эффекты маскирования:

$$d_{\text{sym}}(m,k) = \min\left[\left|L_x(m,k) - L_y(m,k)\right|, \text{max_dist}\right] - \text{Clip},$$

где Clip – пороговое значение, основанное на минимальной громкости в этой полосе.

Поскольку человеческое ухо более чувствительно к аддитивным искажениям (шум, введенный в тихих местах, или увеличение громкости) по сравнению с субтрактивными искажениями (потери сигнала), для учета этого вводится асимметричный весовой коэффициент $A(m,k)$:

$$d_{\text{asym}}(m,k) = d_{\text{sym}}(m,k) \cdot A(m,k),$$

где $A(m,k)$ значительно больше 1, когда $L_y(m,k) > L_x(m,k)$ (добавление шума), и примерно равен 1, когда $L_y(m,k) \leq L_x(m,k)$ (потеря сигнала).

Шаг 4. Полученные возмущения объединяются по частоте и времени.

Общее возмущение по частоте на кадре m вычисляется с использованием L_p нормы, которая больше акцентирует самые большие искажения:

$$D_{\text{sym}}(m) = \sqrt[p]{\sum_k \left|L_x(m,k) - L_y(m,k)\right|^p},$$

где $p = 2$ для симметричного возмущения и $p = 1$ для асимметричного, чтобы сделать его более чувствительным к большим ошибкам.

Суммарное возмущение по времени усредняется по всем кадрам с использованием нелинейной L_q нормы для учета наибольших искажений во времени:

$$D_{\text{PESQ}} = \sqrt[q]{\frac{1}{M}\sum_{m=1}^{M}\left(D(m)\right)^q},$$

где $D(m)$ – взвешенное возмущение кадра (с учетом энергии эталонного сигнала), M – общее число кадров, а q – значение, большее 1.

Шаг 5. Вычисление финального результата.

Финальный балл PESQ вычисляется как линейная комбинация среднего симметричного $\mathrm{mean_D_{sym}}$ и асимметричного $\mathrm{mean_D_{asym}}$ возмущений:

$$\mathrm{PESQ} = a_0 + a_1 \cdot \mathrm{mean_D_{sym}} + a_2 \cdot \mathrm{mean_D_{asym}},$$

где $a_0 = 4.5$, $a_1 = -0.1$, $a_2 = -0.0309$ – константы, определенные в стандарте, которые калибруют результат, чтобы он соответствовал шкале MOS.

Диапазон значений метрики PESQ составляет от 1,0 (плохое качество) до 4.5 (отличное качество).

Следует отметить, что на сегодняшний день практически полностью заменен более новым и точным алгоритмом POLQA (англ. Perceptual Objective Listening Quality Assessment), который используется в ITU-T P.863 и улучшает работу с HD-речью.

Несмотря на адаптацию метрик к психоакустическим особенностям человеческого уха, данная группа метрик также не лишена недостатков:

– плохая работа с нелинейными (не аддитивными) искажениями;

– для модели требуется безупречный эталонный сигнал, который в реальных условиях чаще всего отсутствует;

– перцептивные модели учитывают маскирование, критические полосы, громкость, но не учитывают когнитивные и семантические факторы (например, для речи модель не различает, искажен гласный звук или согласный несмотря на то, что потеря согласных катастрофически влияет на разборчивость);

– модель «замораживается» на момент ее появления и, как правило, отражает знания в психоакустике того времени.

Метрики, основанные на машинном обучении, в той или иной степени пытаются исправить данный недостаток.

Не интрузивная оценка качества речи (Non-Intrusive Speech Quality Assessment, NISQA) [15] – модель машинного обучения (нейронная сеть), обученная на больших базах данных субъективных оценок MOS. Понятие «не интрузивность» означает, что модели нужен только обработанный/искаженный сигнал $\hat{s}[n]$.

Далее приводится обобщенный алгоритм получения данной метрики:

Шаг 1. Извлечение признаков, описывающих входной сигнал.

Шаг 1.1. Создать мел-спектрограмму S для входного искаженного сигнала $x(t)$:

$$S(b,t) = \sum_k |\mathrm{FFT}(x_t)|^2 \cdot H_b(k)$$

где $S(b,t)$ – энергия в b-й мел-полосе в момент времени t, $H_b(k)$ – весовая функция b-го Мел-фильтра.

Шаг 1.2. Разделить мел-спектрограмму S на сегменты фиксированной ширины T_{seg} (например, 15 кадров или 150 мс), которые подаются в нейронную сеть.

Шаг 2. Применить сверточную нейронную сеть, которая извлекает локальные пространственно-временные признаки из каждого сегмента. Результат модели сглаживается, формируя последовательность векторов признаков кадра f_t, где t – номер кадра:

$$F = [f_1, f_2, \dots, f_T].$$

Шаг 3. Использовать механизм Self-Attention для учета долгосрочных временных зависимостей и выявления важных моментов в речи.

Шаг 3.1. Вычислить веса α_t, которые определяют важность каждого вектора признаков f_t для итоговой оценки. Для этого вычисляется вес для каждого кадра:

$$e_t = v^\top \tanh(Wf_t + b)\,,$$

где v, W, b – обучаемые параметры.

Затем полученное значения нормируется с помощью функции:

$$\alpha_t = \frac{\exp(e_t)}{\sum_{\tau=1}^{T} \exp(e_\tau)}.$$

Шаг 3.2. Сформировать финальный вектор признаков (англ. Utterance Feature Vector) z как взвешенную сумму всех векторов признаков кадра:

$$z = \sum_{t=1}^{T} \alpha_t f_t\,.$$

Шаг 4. Вектор $\mathbf{z}$ подать на вход полносвязный слой для предсказания итоговой оценки.

Шаг 4.1. Предсказание обще оценки MOS и нескольких параметров качества (например, Noisiness, Coloration, Discontinuity, Loudness):

$$y = \mathrm{FC}(z),$$

где $y \in R^D$ – вектор из D предсказаний.

Шаг 4.2. Минимизировать ошибку между предсказанными значениями y и субъективными оценками y_g с помощью Среднеквадратической Ошибки (MSE):

$$L(y, y_{\mathrm{g}}) = \frac{1}{D}\sum_{d=1}^{D}\left(y_d - y_{\mathrm{g},d}\right)^2 .$$

В результате работы модель возвращает общую оценку MOS по шкале от 1 до 5 и дополнительные оценки для каждого размера качества.

MOS-оценка подавления шума (англ. Deep Noise Suppression Mean Opinion Score, DNSMOS) [16] – это специализированная нейронная сеть, разработанная компанией Microsoft, для оценки качества речи после алгоритмов шумоподавления.

Далее приводится обобщенный алгоритм получения данной метрики:

Шаг 1. Преобразовать искаженный аудиосигнал $x_{\mathrm{deg}}(t)$ в Мел-спектрограмму:

$$S(b, t) = \text{Mel-Filter}\left(\text{STFT}\left(x_{\mathrm{deg}}(t)\right)\right),$$

где S – матрица мел-спектрограммы.

Шаг 2. Используя сверточные слои, извлечь локальные пространственно-временные признаки f_t из спектрограммы:

$$F = \text{CNN}(S).$$

Шаг 3. Обработать последовательность признаков F двунаправленным LSTM для моделирования долгосрочных зависимостей между кадрами:

$$H = \text{Bi-LSTM}(F).$$

Данный шаг помогает сети понять, как артефакты и искажения изменяются во времени.

Шаг 4. Для каждого кадра t, вычислить предсказание оценок $\mathrm{MOS}_{\mathrm{frame},t}$:

$$\mathrm{MOS}_{\mathrm{frame},t} = \mathrm{FC}(h_t),$$

где FC – отдельная полносвязная сеть для предсказания соответствующей оценки MOS.

Шаг 5. Сформировать финальную оценку MOS для всего аудиофайла путем усреднения покадровых предсказаний по времени T:

$$\mathrm{MOS} = \frac{1}{T}\sum_{t=1}^{T}\mathrm{MOS}_{\mathrm{frame},t} .$$

Шаг 6. Сформировать три финальные оценки:

$$\text{SIG (Signal Quality)} = \frac{1}{T}\sum_{t=1}^{T} \text{MOS}_{\text{SIG},t}\,,$$

$$\text{BAK (Background Quality)} = \frac{1}{T}\sum_{t=1}^{T} \text{MOS}_{\text{BAK},t}\,,$$

$$\text{OVRL (Overall Quality)} = \frac{1}{T}\sum_{t=1}^{T} \text{MOS}_{\text{OVRL},t}\,.$$

3. Задание

1. Ознакомиться с теоретической частью.

2. Для тестовых музыкальных файлов, выданных преподавателем, необходимо выполнить следующие задания:

– реализовать алгоритм вычисления спектрограммы или мел-спектрограммы (по варианту);

– реализовать алгоритмы вычисления спектрограммы и мел-спектрограммы с использованием готовых библиотек;

– объяснить полученный результат.

3. Вычислить спектральные признаки аудиосигнала:

– реализовать алгоритмы вычисления спектрального центроида, спектрального спада, спектральной ширины, частоты пересечения нуля, мел-частотных кепстральных коэффициентов и цветности с использованием готовых библиотек (для более качественного освоения материала рекомендуется выбрать несколько признаков и реализовать их самостоятельно);

– объяснить полученный результат.

4. Написать функцию, которая будет смешивать чистый голос и шум по заданному в децибелах SNR (диапазон значений SNR и шаг определяет преподаватель).

5. Сравнить методы оценки качества звука (метрики, которые необходимо реализовать самостоятельно, определяет преподаватель, для остальных метрик допускается использование библиотечных реализаций). В результат работы программы включить следующую информацию:

Тестовый файл	Объективная оценка						Субъективная оценка
	SNR	SDR	SI-SDR	PESQ	NISQA	DNSMOS	

Прим. 1. Рекомендуется опросить нескольких человек для субъективной оценки тестовых файлов.

Прим. 2. Сделать выводы о корреляции значений аналитических и перцептивных метрик.

6. Скачать с официального репозитория проект DeepFilterNet2 (по согласованию с преподавателем допускается использовать более актуальные проекты). Обработать с его помощью зашумленные файлы. Повторить тесты из п.5.

Прим. 1. Сравнение нескольких моделей приветствуется.

7. Оформить итоговый отчет с указанием исходных данных, результатов работы, построенных графиков, таблицей оценки качества звука, выводами о результатах работы.

4. Контрольные вопросы

1. Почему при анализе аудиосигнала применяется оконное преобразование (фрейминг) и каким образом выбирается длина шага H между окнами?

2. В чем заключается физический смысл шкалы мелов и почему зависимость между высотой звука в мелах и частотой в герцах является нелинейной?

3. Опишите алгоритм построения банка мел-фильтров. Каким образом располагаются центральные частоты этих фильтров на оси герц?

4. Чем отличается обычная спектрограмма от мел-спектрограммы, и почему именно последняя часто используется в качестве входных данных для нейронных сетей?

5. Дайте определение спектральному центроиду. Для каких типов звуков характерны высокие значения этого показателя, а для каких – низкие?

6. Что показывает параметр спектрального спада и как интерпретируется его высокое значение при анализе аудиосигнала?

7. Как вычисляется ширина полосы частот и о чем свидетельствует низкое значение этого параметра при анализе тембра звука?

8. Объясните принцип работы метрики «частота пересечения нуля». Как с помощью ZCR можно отличить вокальный/тональный сигнал от шумного?

9. Опишите последовательность действий для получения мел-частотных кепстральных коэффициентов.

10. Какую информацию о сигнале несет признак «Цветность» и почему он игнорирует информацию об октаве, в которой звучит нота?

11. В чем заключается основной недостаток использования обычного отношения сигнал/шум во временной области для оценки речи, и как этот недостаток устраняется в сегментном SNR?

12. Что такое масштабно-инвариантное отношение сигнал/искажение и в каких случаях его применение предпочтительнее, чем использование обычного SDR?

13. На какой модели восприятия основана метрика PESQ и какие преобразования сигнала происходят на этапе «Акустическое преобразование» в алгоритме PESQ?

14. Что оценивает метрика STOI и какой диапазон значений она может принимать?

15. В чем заключаются отличия неинтрузивных метрик на основе машинного обучения (например, NISQA) от классических метрик типа PESQ или SNR?

ЛАБОРАТОРНАЯ РАБОТА №4
ПРЕОБРАЗОВАНИЕ ТЕКСТА В РЕЧЬ

1. Цель работы

Изучение принципов работы современных систем синтеза речи и приобретение навыков работы с высокоуровневыми нейросетевыми архитектурами (CosyVoice3, kNN-VC) для решения задач синтеза и клонирования голоса.

2. Теоретические сведения

Основные компоненты голоса.

Речевой сигнал можно разложить на три основные группы признаков:

– содержание – это лингвистическая информация (фонемы, слова), которая инвариантна к задаче преобразования голоса и, соответственно, должна быть сохранена;

– тембр – это уникальные характеристики голоса (форма голосового тракта);

– просодия – это интонация, высота тона, ритм, ударения, громкость.

Общая архитектура системы преобразования текста в речь.

Система преобразования текста в речь (англ. Text-to-Speech, TTS) состоит из двух основных модулей:

– модуль лингвистической обработки;

– алгоритмы синтеза аудиосигнала.

Модуль лингвистической обработки преобразует входной текст в некоторое промежуточное акустическое представление (чаще всего в мел-спектрограмму). Как правило, данный модуль включает следующие этапы:

– нормализация текста (англ. Text Normalization), в результате которых выполняется преобразование чисел, аббревиатур и символов в слова (например, «1999» в «тысяча девятьсот девяносто девять», «кг» в «килограмм»);

– морфологический анализ и разметка, в результате которого определяются границы предложений, ударений и частей речи;

– преобразование графем в фонемы (англ. Grapheme-to-Phoneme, G2P), в результате которого выполняется преобразование слов (графем) в последовательность фонетических символов (фонем) с учётом правил орфоэпии;

– анализ просодии, в результате выполняется определение параметров интонации, длительности фонем и пауз;

– построение акустической модели (мел-спектрограммы) на основе последовательности фонем, их продолжительности и высоты тона (просодии).

Модуль синтеза аудиосигнала (вокодер) принимает мел-спектрограмму или другое промежуточное представление (например, фонетическую разметку) и синтезирует форму волны, которую можно проиграть.

Развитие алгоритмов синтеза аудиосигнала.

Поколение 1: синтез на основе конкатенации (англ. Concatenative TTS). Используя базы данных, в которых хранятся десятки тысяч небольших фрагментов речи (фонемы, слога, слова, фразы), записанных одним диктором, задачей алгоритма было выбрать подходящие фрагменты и соединить их так, чтобы получить естественное звучание.

Алгоритм синтеза, в общем случае, включает 3 этапа:

– поиск в базе данных лучшей последовательности сегментов, соответствующей входной фонетической разметке;

– объединение сегментов в единый сигнал;

– обработка сигнала, чтобы «сгладить» результат объединения сигнала (например, TD-PSOLA [17], который позволяет изменить просодию сегмента, не влияя на его тембр, путём наложения и сложения волновых форм в моменты, синхронизированные с основной частотой тона).

Основным достоинством первого поколения является максимальная естественность и качество.

Однако методы обладают существенными недостатками:

– большой объём базы данных;

– привязка к голосу диктора и, соответственно, сложно изменить голос или стиль;

– сложность сглаживания сигнала при объединении.

Примерами алгоритмов синтеза на основе конкатенации являются Festival TTS, ранние системы Microsoft Speech.

Поколение 2: параметрический синтез (англ. Statistical Parametric TTS). Этот подход предполагал, что аудиосигнал описывается набором параметров речи (например, MFCC, логарифмом частоты основного тона, коэффициентами возбуждения и др.), на основе которых строится математическая модель голосового тракта и параметров, извлечённых из речевых баз.

Алгоритм синтеза аудиосигнала:

– на основе входного текста и скрытых марковских моделей генерируется оптимальная траектория последовательности параметров;

– параметры передаются в вокодер, который реконструирует форму волны.

Основным достоинством второго поколения являются небольшой объём памяти и высокая гибкость (например, относительно легко поменять голос).

Недостатками, в свою очередь, являются:

– «синтетическое» звучание по сравнению с методами первого поколения;

– «роботизированный» или «смазанный» тембр из-за усреднения спектральных параметров.

Поколение 3: нейросетевой синтез (англ. Neural TTS, N-TTS). В основе третьего поколения методы, использующие глубокие нейронные сети для моделирования всего процесса синтеза, что значительно повышает естественность и сходство с человеческим голосом.

Как уже упоминалось, архитектура TTS делится на две части:

– построение акустической модели;

– вокодер.

При построении *акустической модели* по состоянию на 2025 год можно выделить следующие модели:

– модели на основе архитекуты Encoder-Decoder (например, Tacotron [18]);

– Non-Autoregressive модели (например, FastSpeech [19]).

Модели с архитектурой Encoder-Decoder включают три составные части:

– кодировщик, который принимает на вход последовательность фонем P и преобразует её в высокоуровневое векторное представление;

– механизм внимания (англ. Attention Mechanism), который сопоставляет каждый акустический признак с соответствующей фонемой, тем самым решая проблему выравнивания фонем с мел-спектрограммой;

– декодер, который использует механизм внимания для создания мел-спектрограммы $\boldsymbol{M}$ кадр за кадром:

$$M_t = Decoder\big(M_{t-1}, Attention(P, M_{t-1})\big).$$

В свою очередь, *Non-Autoregressive модели* ускоряют синтез, предсказывая всю Мел-спектрограмму за один шаг, используя модель длительности (англ. Duration Predictor), чтобы заранее определить, сколько кадров Мел-спектрограммы соответствует каждой фонеме.

Затем следует нейросетевой вокодер, который преобразуюет Мел-спектрограмму M в конечную форму волны $x[n]$. Примерами нейросетевого вокодера являются:

– WaveNet [20], разработанный компанией Google, и его преемники;

– Non-Autoregressive вокодеры (например, WaveGlow [21], MeIGAN [22], HiFi-GAN [23]).

Из вышеперечисленных моделей следует выделить модель WaveNet которая стала первой высококачественной авторегрессионной моделью, в котором каждый отсчёт формы волны x генерировался на основе предыдущих x_{t-1}, x_{t-2}, ... и условных акустических признаков M:

$$P(x_t|x_{t-1}, x_{t-2}, \dots, M) = SoftMax(DilatedConvNet).$$

В свою очередь, Non-Autoregressive вокодеры используют генеративные состязательные сети или потоковые нейронные сети (англ. Flow-based models) для синтеза аудиосигнала $\hat{x}$ из Мел-спектрограммы M за один шаг. Такой подход позволил значительно повысить скорость синтеза, что сделало их пригодными для использования в реальном времени.

В таблице 4 представлена сводная информация по всем поколениям TTS.

Таблица 4. Сводная информация по поколениям TTS

Характеристика	**Поколение 1**	**Поколение 2**	**Поколение 3**
Источник звука	Записанные сегменты	Математическая модель (вокодер)	Генеративная нейронная сеть (WaveNet/HiFi-GAN)
Естественность	Высокая	Низкая	Очень высокая
Гибкость	Низкая	Средняя	Высокая (легко внедрять эмоции, стили)
Скорость генерации	Средняя	Очень высокая	Высокая (благодаря Non-Autoregressive моделям)
Объём данных	Большая база сегментов	Параметры, модели	Большая база записей и разметки
Доминирующие алгоритмы	TD-PSOLA, Diphone	Скрытая марковская модель	Tacotron/FastSpeech, WaveNet/HiFi-GAN

Проект CosyVoice.

CosyVoice3 [24, 25] – это масштабируемая система синтеза речи, построенная на основе больших языковых моделей, позволяющая в рамках одной модели генерировать речь как в потоковом режиме с низкой задержкой, так и в непотоковом с максимальным качеством.

Особенностями проекта является:

– достижение качества речи, сопоставимого с человеческим, при сохранении высокой скорости генерации;

– поддержка клонирования голоса (в режиме zero-shot);

– точный контроль над интонацией, эмоциями и акцентами.

В архитектуре проекта выделяются следующие этапы:

– обработка текста и его кодирование;

– предсказание длительности и просодии;

– генерация латентных акустических признаков через Flow Matching;

– FSQ-квантование;

– восстановление волны вокодером.

На первом этапе с помощью BPE (англ. Byte Pair Encoding) токенизатора [26] выполняется преобразование входного необработанного текста в последовательность токенов. Затем токены кодируются, используя разработанную авторами алгоритма модель на основе трансформера, и формируют контекстное текстовое векторное представление (эмбединг, от англ. embedding).

На втором этапе для каждого текстового токена предсказывается его длительность и кодируется их интонация, ритм, логические ударения и эмоциональные характеристики.

На третьем этапе выполняется генерация реалистичной мел-спектрограммы на основе простого шума с помощью компоненты, получившей название Flow Matching.

На четвертом этапе выполняется дискретизация и квантование признаков без использования кодовый книги с помощью метода FSQ [27]. В соответствии с алгоритмом каждый латентный вектор $z \in \mathbb{R}^{\mathrm{D}}$ независимо квантуется в заданный диапазон (например, $[-L, L]$), а затем округляется до ближайшего целого числа:

$$q(z_i) = \mathrm{clip}(\mathrm{round}(z_i), -L, L).$$

На заключительном, пятом, этапе выполняется восстановление аудиосигнала с помощью какого-либо вокодера (авторы проекта экспериментировали с HiFi-GAN).

Рассмотрим более подробно некоторые из алгоритмов, используемые в проекте.

Алгоритм BPE является крайне простым и состоит из двух независимых этапов:

– обучение;

– токенизация (применение результатов обучения).

Алгоритм обучения состоит из трех шагов.

Шаг 1. Инициализация. На данном шаге выполняется инициализация словаря, который на начальном этапе состоит из всех уникальных символов (букв, цифр, знаков препинания) в корпусе. Затем корпус разбивается на слова, каждое слово рассматривается как последовательность символов, оканчивающаяся специальным маркером «_».

Шаг 2. Итеративное объединение. На данном шаге алгоритм циклически повторяет следующие действия N раз, где N – желаемый размер конечного словаря:

– сканируется весь корпус (или словарь слов) для нахождения наиболее часто встречающейся пары смежных байтов/символов (биграмм);

– наиболее частая пара объединяется в новый, один токен;

– все вхождения этой пары в корпусе заменяются новым токеном

Например, если пара ('a', 'b') встречается чаще всего, она заменяется на новый токен 'ab'.

Шаг 3. Формирование конечного словаря. После N итераций, конечный словарь токенов будет состоять из начальных символов и всех N новых токенов-подслов, созданных в процессе объединения.

После обучения BPE-словаря, процесс токенизации нового текста происходит в обратном порядке:

– текст разбивается на слова;

– к каждому слову последовательно применяются правила объединения, полученные на этапе обучения, от самых длинных токенов к самым коротким;

– слово разбивается на самые длинные возможные подслова, которые есть в обученном словаре BPE.

Задачей компоненты *Flow Matching* является генерация реалистичной мел-спектрограммы x_1 из простого шума $x_0 \sim \mathcal{N}(0, I)$, основываясь на условии c, определяемых с помощью семантических токенов. При этом простой, прямой путь от шума x_0 к данным x_1 определяется согласно выражению:

$$p_t(x|x_0, x_1) = (1 - t)x_0 + tx_1.$$

Так, в формуле при $t = 0$ получим, что $p_t = x_0$, т.е. является шумом. И наоборот при $t = 1$ получаем $p_t = x_1$, т.е. конечные данные. Желающим более подробно познакомиться с алгоритмом и процессом обучения рекомендуется обратиться к статье [28].

Преобразование голоса.

Преобразование голоса (англ. Voice Conversion, VC) – это задача в области синтеза речи, целью которой является изменение характеристик голоса исходного диктора (англ. Source Speaker, S) в речевом сигнале таким образом, чтобы он звучал так, будто его произнес целевой диктор (англ. Target Speaker, T), сохраняя при этом лингвистическое содержание исходной фразы.

В зависимости от доступности данных целевого диктора и способа преобразования, методы VC делятся на 2 подхода.

– подходы на основе признаков (англ. Feature-Based VC), которые напрямую манипулируют акустическими признаками (например, Гауссовы смешанные модели, проект StarGAN-VC);

– нейросетевые подходы (англ. Neural Network VC), основанные на глубоком обучении и позволяющие достичь более высокого качества и естественности.

Среди нейросетевых нашли практическое применение следующие подходы:

– на основе декомпозиции признаков (англ. Disentanglement-Based VC), использующие автокодировщик или генеративно-состязательные сети для разделения речевого сигнала на признаки, не зависящие от диктора, и признаки диктора (например, AutoVC [29]);

– на основе самостоятельно обученных признаков (англ. Self-Supervised VC), использующие большие, предварительно обученные модели (например, wav2vec [30] или HuBERT [31]) для извлечения устойчивых к голосу семантических признаков, не зависящих от тембра диктора, что упрощает задачу преобразования.

– на основе генеративных моделей (англ. Flow/Diffusion-Based VC), использующие генеративные модели для преобразования скрытого акустического представления, что обеспечивает высокую естественность и качество.

Zero-Shot преобразование голоса на примере проекта CosyVoice3 является одним из наиболее актуальных подходов. В отличии от модификации TTS, вместо текста на вход подается аудиофайл Source Speaker (S) и аудиофайл Target Speaker (T). В этом случае алгоритм сводится к следующей последовательности действий:

– с помощью акустического энкодера и FSQ-токенизатора извлекается последовательность семантических токенов C (последовательность дискретных кодов, которые полностью описывают лингвистическое содержание, но не содержат информацию о тембре S) из речи S;

– извлечение тембра, в рамках которого система извлекает векторный представление признаков для диктора E_T из речи T;

– сеть принимает последовательность семантических токенов C и векторные признаки E_T и генерирует на их основе новую мел-спектрограмму.

Метрики для оценки качества. Оценка качества алгоритмов озвучивания текстов является сложной задачей. Кроме субъективной оценки можно воспользоваться следующим множеством метрик:

– метрика MOS (англ. Mean Opinion Score) [32], позволяющая оценить, насколько естественно звучи речь;

– метрики CER/WER (англ. Character/Word Error Rate) [33], позволяющие оценить, насколько корректно сохранено содержание (например, имеются ли ошибки в словах);

– метрики SID (англ. Speaker Identification/Verification) [34] и EER (англ. Equal Error Rate) [35], позволяющая оценить схожесть голосов.

Проект kNN-VC.

Проект *kNN-VC (англ. k-Nearest Neighbors Voice Conversion)* [36, 37] – это современный метод непараметрического (примерно-ориентированного) преобразования голоса исходного диктора так, чтобы он звучал как целевой диктор, при этом сохранив лингвистическое содержание (слова) и просодию (интонацию, темп) исходного диктора. Модель отличается от традиционных параметрических и большинства нейросетевых методов тем, что не использует сложную нейронную сеть для моделирования отображения спектров. Вместо этого проект использует базу данных, извлекая и комбинируя акустические признаки ближайших соседей.

Основные компоненты kNN-VC включают:

– спектральный кодировщик, который извлекает высокоуровневые, инвариантные к диктору признаки из исходного аудио;

– базу данных, содержащую акустические признаки, извлечённые из записей целевого диктора;

– модуль kNN-поиска, который находит k ближайших векторов в датасторе для каждого входного вектора;

– вокодер, который генерирует конечную форму волны из полученного отображённого спектра.

Алгоритм работы проекта состоит из трех шагов.

Шаг 1. Спектральный кодировщик.

– аудио исходного диктора (S) подается на вход предварительно обученной Self-Supervised Learning модели (авторы проекта используют WavLM). На выходе формируется последовательность признаков-запросов (Query Sequence) Q.

– аудио целевого диктора (T) также подается на вход WavLM-модели. Все полученные кадры признаков целевого диктора объединяются в большую Базу Соответствия (Matching Set) M.

В основе проекта находится идея, что предварительно обученные модели (например, WavLM) извлекают из аудиоряда векторные представления речи, где информация о лингвистическом содержании отделена от информации о дикторе.

Пусть $\mathcal{A}_S$ – аудиосигнал исходного диктора S, а $\mathcal{A}_T$ – аудиосигнал целевого диктора T.

– Self-Supervised Learning модель $\Phi(\cdot)$ (авторы предлагаемой к использованию версии проекта использовали WavLM) преобразует аудиосигнал исходного диктора S в последовательность высокоразмерных акустических векторных признаков Q (сокращение от Query Sequence):

$$Q = \Phi(\mathcal{A}_S) = \{q_1, q_2, \dots, q_N\},$$

где $q_i \in R^D$ – вектор признаков для i-го кадра, N – общее количество кадров.

– аналогично преобразуется аудиосигнал целевого диктора T в базу соответствия M (сокращение от Matching Set):

$$M = \Phi(\mathcal{A}_T) = \{m_1, m_2, \dots, m_L\},$$

где $m_j \in R^D$, L – общее количество кадров в базе.

В результате кодирования для любых двух кадров q и m, если они представляют одну и ту же фонему (лингвистическое содержание), расстояние между ними $|q - m|$ должно быть минимальным, независимо от того, кто их произнес.

Для kNN-VC критически важным является качество инвариантных признаков, извлекаемых моделью $\Phi(\cdot)$, поэтому кодировщик должен уметь:

– удалить информацию о дикторе из исходного аудиосигнала S;

– сохранить просодию (ритм, длительность) и лингвистическое содержание;

– обеспечить сходство между признаками Q и M.

Шаг 2. Поиск наборов из k векторов в M, которые наиболее похожи на q_i, и усреднение их для создания преобразованного кадра $\hat{q}_i$.

Шаг 2.1. Для каждого кадра q_i в последовательности векторных признаков Q выполняется поиск k ближайших векторов в базе соответствия M целевого

диктора. Для определения схожести используется косинусное расстояние $D_{\cos}(q_i, m_j)$:

$$D_{\cos}(q_i, m_j) = 1 - S(q_i, m_j),$$

где $S(q_i, m_j) = \frac{q_i \cdot m_j}{|q_i||m_j|}$ – косинусное сходство (англ. Cosine Similarity), которое измеряет угол между двумя векторами в D-мерном пространстве и не зависит от их длины (нормы).

Маленькое значение $D_{\cos}$ означает, что q_i и m_j вероятно, представляют одну и ту же фонему или лингвистический элемент, даже если они были произнесены разными дикторами. И наоборот высокое значение $D_{\cos}$ означает, что они представляют разное лингвистическое содержание.

Шаг 2.2. Найденные k ближайших соседей усредняются, чтобы получить преобразованный кадр $\hat{q}_i$:

$$\hat{q}_i = \frac{1}{k}\sum_{j=1}^{k} m_j\,,$$

где m_j – j-й ближайший сосед q_i из M.

Шаг 3. Полученная преобразованная последовательность признаков $\hat{Q}$ подается на вход предварительно обученному вокодеру (например, HiFi-GAN), который синтезирует финальный аудиосигнал с голосом целевого диктора T, но с лингвистическим содержанием исходного диктора S.

Модель WavLM (англ. Waveform Language Model) [38] – это мощная модель, разработанная Microsoft, которая использует самообучение без учителя для создания универсальных векторных представлений речи. Ее основная цель – извлечь из аудиосигнала все многогранные признаки (содержание, тембр, просодию, шум) и эффективно использовать их для решения полного спектра задач обработки речи.

Архитектура WavLM построена на двух взаимосвязанных модулях:

– кодировщик признаков, который принимает необработанную звуковую волну и, используя нескольких одномерных сверточных блоков, преобразует ее в низкоуровневые признаки с пониженной частотой дискретизации;

– трансформер-кодировщик, который принимает признаки и использует механизм самовнимания (англ. self-attention) для захвата долгосрочных зависимостей и контекста в речи.

Преимуществами WavLM являются:

– универсальность, т.к. может применяться в задачах распознавания речи, верификации/идентификации диктора, распознавании эмоций и т.д.;

– генерация векторов-признаков, в которых лингвистическое содержание становится ключевым фактором, определяющим векторную близость, в результате чего два вектора, представляющие одну и ту же фонему, но произнесенные разными людьми, оказываются близко друг к другу.

3. Задание

1. Используя проект CosyVoice3 [25] (или любой другой по согласованию с преподавателем), озвучить текст. Оценить полученные результаты.

2. Используя проект kNN-VC [37] (или любой другой по согласованию с преподавателем), сконвертировать свой голос в любой другой.

2.1. Выполнить дообучение вокодера, используемого в проекте. Для этого рекомендуется воспользоваться ресурсами, которые предоставляются в Google Colab.

2.2. Оценить, насколько хорошо метод работает в условиях ограниченных ресурсов.

2.3. *Дополнительное задание 1*: провести эксперимент и установить минимальную длину файла для субъективно качественного преобразования, а также оценить, какие изменения происходят на выходе.

2.4. *Дополнительное задание 2*: сравнить результаты преобразования голоса в проектах CosyVoice3 (см. Zero-Shot синтез речи) и kNN-VC. Сделать выводы о качестве преобразования голоса, сложности работы с библиотекой.

3. Оформить итоговый отчет с указанием исходных данных, результатов работы, выводами о результатах работы.

Примечание. Рекомендуется взаимодействие с проектами на уровне исходного кода, включая обучение моделей нейронных сетей.

4. Контрольные вопросы

1. Перечислите основные группы признаков речевого сигнала и поясните, какая информация является инвариантной к задаче преобразования голоса, а какая – уникальной для диктора.

2. Опишите основные этапы работы модуля лингвистической обработки в системе TTS, начиная от нормализации текста и заканчивая построением акустической модели.

3. В чем заключается принципиальное различие между синтезом на основе конкатенации (1-е поколение) и параметрическим синтезом (2-е поколение)? Укажите основные достоинства и недостатки каждого подхода.

4. Сравните авторегрессионные (Encoder-Decoder) и Non-Autoregressive модели. За счет чего вторые обеспечивают более высокую скорость генерации?

5. Опишите вероятностный принцип генерации отсчётов формы волны в модели WaveNet. Как текущий отсчёт x_t зависит от предыдущих данных?

6. Объясните математическую суть прямого пути от шума к данным в алгоритме Flow Matching. Что представляют собой состояния системы при значениях параметра $t = 0$ и $t = 1$?

7. В чем заключается метод FSQ-квантования в проекте CosyVoice и как латентный вектор z преобразуется в дискретный код?

8. Опишите процесс итеративного объединения в ходе обучения BPE-словаря. Каким образом определяется пара символов для создания нового токена?

9. Как происходит процесс токенизации нового текста после того, как словарь BPE уже обучен?

10. Опишите различие между подходами на основе декомпозиции признаков и подходами на основе самостоятельно обученных признаков.

11. Каким образом в системе CosyVoice3 реализовано разделение лингвистического содержания и тембра диктора при работе с произвольными аудиофайлами?

12. Какие метрики используются для оценки естественности речи, а какие – для проверки сохранения содержания и идентификации диктора?

13. В чем заключается ключевое отличие метода kNN-VC от традиционных нейросетевых методов моделирования спектров? Какую роль здесь играет база соответствия (Matching Set)?

14. Как в алгоритме kNN-VC вычисляется косинусное сходство между векторами признаков и каким образом формируется итоговый преобразованный кадр $\hat{q}_i$?

15. Почему модель WavLM эффективна для задач преобразования голоса? Какое свойство векторов-признаков позволяет объединять аудио разных дикторов?

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Лайонс, Р. Цифровая обработка сигналов / Р. Лайонс ; пер. с англ. – 2-е изд. – Москва : Бином, 2015. – 656 с.

2. Айфичер, Э. Цифровая обработка сигналов : практический подход / Э. Айфичер, Б. Джервис ; пер. с англ. – 2-е изд. – Москва : Вильямс, 2016. – 992 с.

3. Оппенгейм, А. В. Цифровая обработка сигналов / А. В. Оппенгейм, Р. Шафер ; пер. с англ. – 3-е изд., испр. – Москва : Техносфера, 2019. – 1048 с.

4. Смит, С. Цифровая обработка сигналов : практическое руководство для инженеров и научных работников / С. Смит ; пер. с англ. – Москва : ДМК Пресс, 2018. – 718 с.

5. Cooley, J. An algorithm for the machine calculation of complex Fourier series / J. Cooley, J. Tukey // Mathematics of Computation. – 1965. – Volume 19. – Number 90. – P. 297-301. – DOI: 10.2307/2003354.

6. Peeters, G. A Large Set of Audio Features for Sound Description (Similarity and Classification) in the CUIDADO Project / G. Peeters // Technical Report; IRCAM: Paris, France, 2004.

7. Scheirer, E. Construction and Evaluation of a Robust Multifeature Speech/Music Discriminator / E. Scheirer, M. Slaney // IEEE International Conference on Acoustics, Speech, and Signal Processing. – 1997. – Volume 2. – P. 1221-1224. – DOI: 10.1109/ICASSP.1997.596192.

8. Bogert, B. The quefrency alanysis of time series for echoes: Cepstrum, pseudo-autocovariance, cross-cepstrum, and saphe cracking / B.P. Bogert, M.J.R. Healy, J.W. Tukey // Time Series Analysis. –1963. – Chapter 15. – P. 209-243.

9. Davis, S. Comparison of parametric representations for monosyllabic word recognition in continuously spoken sentences / S. Davis, P. Mermelstein / IEEE Transactions on Acoustics, Speech, and Signal Processing. – 1980. – Volume 28. – Issue 4. – P. 357-366. – DOI: 10.1109/TASSP.1980.1163420.

10. Vincent, E. Performance measurement in blind audio source separation / E. Vincent, R. Gribonval, C. Févotte / IEEE Transactions on audio, speech, and language processing. – 2006. – Volume 14. – Issue 4. – P.1462-1469. – DOI: 10.1109/TSA.2005.858005.

11. Tribolet, J. A study of complexity and quality of speech waveform coders / J. Tribolet, [etc.] // IEEE International Conference on Acoustics, Speech, and Signal Processing. – 1978. – P. 586-590. – DOI: 10.1109/ICASSP.1978.1170567.

12. Le Roux, J. SDR - half-baked or well done? / J. Le Roux, [etc.] // arXiv preprints. – 2018. – arXiv code: 1811.02508.

13. Taal, C. A short-time objective intelligibility measure for time-frequency weighted noisy speech / C. Taal, [etc.] // IEEE International Conference on Acoustics, Speech and Signal Processingю –2010. – DOI: 10.1109/ICASSP.2010.5495701.

14. Rix, A., Perceptual evaluation of speech quality (PESQ) – A new method for speech quality assessment of telephone net-works and codecs / A. Rix, [etc.] // IEEE

International Conference on Acoustics, Speech, and Signal Processing. – 2001. – Vol. 2. – P. 749-752. – DOI: 10.1109/ICASSP.2001.941023.

15. Mittag, G. NISQA: A Deep CNN-Self-Attention Model for Multidimensional Speech Quality Prediction with Crowdsourced Datasets / G. Mittag, [etc.] // arXiv preprints. – 2021. – arXiv code: 2104.09494.

16. K A Reddy, C. DNSMOS: A Non-Intrusive Perceptual Objective Speech Quality metric to evaluate Noise Suppressors / C. K A Reddy, V. Gopal, R. Cutler// arXiv preprints. – 2021. – arXiv code: 2010.15258.

17. Moulines, E. Pitch-synchronous waveform processing techniques for text-to-speech synthesis using diphones / E. Moulines, F. Charpentier // Speech Communication. – 1990. – Volume 9. – Issue 5-6. – P. 453-467. – DOI: 10.1016/0167-6393(90)90021-Z.

18. Shen, J. Natural TTS Synthesis by Conditioning WaveNet on Mel Spectrogram Predictions / J. Shen, [etc.] // arXiv preprints. – 2018. – arXiv code: 1712.05884.

19. Ren, Y. FastSpeech: Fast, Robust and Controllable Text to Speech / Y. Ren, [etc.] // arXiv preprints. – 2019. – arXiv code: 1905.09263.

20. van den Oord, A. WaveNet: A Generative Model for Raw Audio / A. van den Oord, [etc.] // arXiv preprints. – 2016. – arXiv code: 1609.03499.

21. Prenger, R. WaveGlow: A Flow-based Generative Network for Speech Synthesis / R. Prenger, R. Valle, B. Catanzaro // arXiv preprints. – 2018. – arXiv code: 1811.00002.

22. Sun, L. Multi-View Transformation via Mutual-Encoding InfoGenerative Adversarial Networks / L. Sun, [etc.] // IEEE Access. – 2018. – Volume 6. – P. 43315-43326. – DOI: 10.1109/ACCESS.2018.2845696.

23. Kong, J. HiFi-GAN: Generative Adversarial Networks for Efficient and High Fidelity Speech Synthesis / J. Kong, J. Kim, J. Bae // arXiv preprints. – 2020. – arXiv code: 2010.05646.

24. Du, Z. CosyVoice 3: Towards In-the-wild Speech Generation via Scaling-up and Post-training / Z. Du, [etc.] // arXiv preprints. – 2025. – arXiv code: 2505.17589.

25. CosyVoice [Электронный ресурс]. – Режим доступа: https://github.com/FunAudioLLM/CosyVoice. – Дата доступа: 01.12.2025.

26. Sennrich, R. Neural Machine Translation of Rare Words with Subword Units / R. Sennrich, B. Haddow, A. Birch // arXiv preprints. – 2015. – arXiv code: 1508.07909.

27. Chavent, M. From explained variance of correlated components to PCA without orthogonality constraints / M. Chavent, G. Chavent // arXiv preprints. – 2024. – arXiv code: 2402.04692.

28. Mehta, S. Matcha-TTS: A fast TTS architecture with conditional flow matching / S. Mehta, [etc.] // arXiv preprints. – 2024. – arXiv code: 2309.03199.

29. Qian, K. AUTOVC: Zero-Shot Voice Style Transfer with Only Autoencoder Loss / K. Qian, [etc.] // arXiv preprints. – 2019. – arXiv code: 1905.05879.

30. Schneider , S. wav2vec: Unsupervised Pre-training for Speech Recognition / S. Schneider, [etc.] // arXiv preprints. – 2019. – arXiv code: 1904.05862.

31. Hsu, W.-N. HuBERT: Self-Supervised Speech Representation Learning by Masked Prediction of Hidden Units / W.-N. Hsu, [etc.] // arXiv preprints. – 2021. – arXiv code: 2106.07447.

32. Mean opinion score (MOS) terminology / ITU-T Recommendation P.800.1 [Электронный ресурс]. – Режим доступа: https://www.itu.int/rec/T-REC-P.800.1. – Дата доступа: 01.12.2025.

33. Radha, K. Speech and speaker recognition using raw waveform modeling for adult and children's speech: A comprehensive review / K. Radha, M. Bansal, R.B. Pachori // Engineering Applications of Artificial Intelligence. – 2024. –Volume 131. – DOI: 10.1016/j.engappai.2023.107661.

34. Huggins, M. Confidence metrics for speaker identification / M.C. Huggins, J.J. Grieco / 7th International Conference on Spoken Language Processing. – 2002. – DOI: 10.21437/ICSLP.2002-418.

35. Zhang, L. Range-Based Equal Error Rate for Spoof Localization / L. Zhang, [etc.] / Interspeech. – 2023. – P.3212-3216. – DOI: 0.21437/Interspeech.2023-1214.

36. Baas, M. Voice Conversion With Just Nearest Neighbors / M. Baas, B. van Niekerk, H. Kamper // arXiv preprints. – 2023. – arXiv code: 2305.18975.

37. Voice Conversion With Just Nearest Neighbors (kNN-VC) [Электронный ресурс]. – Режим доступа: https://github.com/bshall/knn-vc. – Дата доступа: 01.12.2025.

38. Chen, S. WavLM: Large-Scale Self-Supervised Pre-Training for Full Stack Speech Processing / S. Chen, [etc.] // arXiv preprints. – 2021. – arXiv code: 2110.13900.

Св. план 2025/2026, поз. 40

Учебное издание

Перцев Дмитрий Юрьевич
Куприянова Диана Вячеславовна

ЦИФРОВАЯ ОБРАБОТКА СИГНАЛОВ И ИЗОБРАЖЕНИЙ. ЛАБОРАТОРНЫЙ ПРАКТИКУМ

ПОСОБИЕ

Редактор *Е. С. Юрец*
Корректор _____
Компьютерная правка, оригинал-макет

Подписано в печать . . . Формат 60x84 1/16. Бумага офсетная. Гарнитура «Таймс».
Отпечатано на ризографе. Усл. печ. л. . Уч.-изд. л. 4,3. Тираж 40 экз. Заказ ___.

Издатель и полиграфическое исполнение: Учреждение образования
«Белорусский государственный университет информатики и радиоэлектроники».
Свидетельство о государственной регистрации издателя, изготовителя, распространителя
печатных изданий №1/238 от 24.03.2014, №2/113 от 07.04.2014, №3/615 от 07.04.2014.
Ул. П. Бровки, 6, 220013, г. Минск.